

ĐẠI HỌC HUẾ
TRƯỜNG ĐẠI HỌC KHOA HỌC
KHOA CÔNG NGHỆ THÔNG TIN

BÁO CÁO HỌC PHẦN NLP

Tên đề tài

TÓM TẮT VĂN BẢN TIẾNG VIỆT TỰ ĐỘNG BẰNG
TEXTRANK KẾT HỢP viT5



Giảng viên	TS. Đoàn Thị Hồng Phước
Nhóm thực hiện	Nhóm 1
Nhóm trưởng	Hoàng Kim Thiên

Huế, tháng 1 năm 2025

Mục lục

1	Cơ sở lý thuyết	6
1.1	Tổng quan bài toán tóm tắt văn bản	6
1.2	Nhóm phương pháp Extractive Summarization	8
1.2.1	Các phương pháp tiếp cận chính	10
1.2.2	Đánh giá ưu và nhược điểm	11
1.2.3	TextRank	12
1.3	Nhóm phương pháp Abstractive Summarization	14
1.3.1	Ý tưởng chung	14
1.3.2	Kiến trúc Transformer encoder–decoder	14
1.3.3	Mô hình BART	16
1.3.4	Mô hình BARTpho	18
1.3.5	Mô hình T5	20
1.3.6	Mô hình ViT5 (T5 cho tiếng Việt)	22
1.4	So sánh Extractive và Abstractive (định hướng lựa chọn hybrid)	24
1.5	Độ đo đánh giá tóm tắt văn bản	26
1.5.1	ROUGE (đánh giá dựa trên chồng lấp n-gram)	26
1.5.2	BERTScore (đánh giá theo tương đồng ngữ nghĩa)	27
1.5.3	CR/RR và kiểm soát độ dài	27
1.5.4	Đánh giá thủ công	28
2	Phương pháp đề xuất	29
2.1	Ý tưởng tổng thể	29

2.2	Pipeline hệ thống	29
2.2.1	Bước 1: Tiền xử lý và tách câu	30
2.2.2	Bước 2: Biểu diễn câu bằng Word2Vec trung bình	30
2.2.3	Bước 3: Xây dựng đồ thị tương đồng câu và chạy TextRank	31
2.2.4	Bước 4: Tạo pseudo-document	31
2.2.5	Bước 5: Tạo sinh bằng ViT5	31
2.2.6	Bước 6: Hậu xử lý và xuất kết quả	32
2.3	Thiết kế tham số và biến thể (ablation)	32
2.3.1	Tham số TextRank	32
2.3.2	Tham số tạo sinh	32
2.3.3	Các cấu hình so sánh	32
2.4	Tiêu chí lựa chọn cấu hình cuối	33
3	Thực nghiệm và kết quả	34
3.1	Dữ liệu	34
3.2	Thiết lập thí nghiệm	36
3.2.1	Các mô hình so sánh	36
3.2.2	Cấu hình TextRank	36
3.2.3	Cấu hình mô hình tạo sinh	36
3.3	Chỉ số đánh giá	37
3.3.1	ROUGE	37
3.3.2	BERTScore	37
3.3.3	Compression Ratio (CR)	37
3.3.4	Đánh giá thủ công	37
3.4	Kết quả và phân tích	37
3.4.1	Kết quả tổng quan	37
3.4.2	Phân tích ablation	39
3.4.3	Minh hoạ định tính	41
3.4.4	Phân tích lỗi và ảnh hưởng của giới hạn token	45
3.5	Thảo luận	47

3.5.1	Nhận xét tổng quan	47
3.5.2	Hạn chế	47
3.5.3	Hướng phát triển	48
	Tài liệu tham khảo	49

Mở đầu

Bối cảnh và động lực: Trong những năm gần đây, khối lượng văn bản tiếng Việt trên Internet và trong các hệ thống nội bộ (tin tức, báo cáo, tài liệu chuyên môn, văn bản hành chính, ...) tăng nhanh, kéo theo nhu cầu nắm bắt ý chính trong thời gian ngắn ngày càng lớn. Tuy nhiên, việc tóm tắt thủ công thường tốn nhiều thời gian, phụ thuộc vào người thực hiện và khó mở rộng khi số lượng tài liệu tăng mạnh. Vì vậy, tóm tắt văn bản tự động trở thành một bài toán quan trọng, giúp giảm thời gian đọc, hỗ trợ tìm kiếm thông tin và ra quyết định hiệu quả hơn.

Vấn đề nghiên cứu: Bài toán tóm tắt tự động tiếng Việt đặt ra nhiều thách thức, đặc biệt khi văn bản đầu vào có độ dài lớn, chứa nhiều nhiễu, dễ lặp ý và đòi hỏi tính mạch lạc của bản tóm tắt. Hai hướng tiếp cận phổ biến là *trích xuất* (extractive) và *trích sinh* (abstractive). Trong khi mô hình trích xuất có ưu điểm bám sát nội dung nguồn, thì tóm tắt tạo ra thường mang tính “cắt-dán”, dễ rời rạc [1]. Ngược lại, mô hình trích sinh có khả năng diễn đạt tự nhiên hơn nhưng có nguy cơ tạo ra thông tin không có trong văn bản gốc (hallucination) [2], đặc biệt khi đầu vào dài hoặc nhiễu và thiếu cơ chế kiểm soát. Từ đó, đề tài định hướng tiếp cận kết hợp (hybrid) nhằm tận dụng ưu điểm của cả hai hướng [1].

Mục tiêu đề tài: Đề tài hướng tới xây dựng một phương pháp tóm tắt tiếng Việt theo hướng *hybrid* bằng cách kết hợp TextRank ở tầng trích xuất và ViT5-small ở tầng trích sinh. Các mục tiêu cụ thể bao gồm:

- Xây dựng pipeline kết hợp TextRank và ViT5-small để tạo tóm tắt ngắn gọn, có kiểm soát độ dài và hạn chế lặp.
- Đánh giá và so sánh với các mô hình nền (baseline) như TextRank-only, ViT5-small-only (và tùy chọn Lead-3 trong miền tin tức).
- Phân tích ảnh hưởng của các tham số quan trọng: số câu top- k của TextRank, cấu hình sinh của mô hình (ví dụ max length/beam search) và cách đo tương đồng giữa câu.

Phạm vi và đối tượng nghiên cứu: Trong phạm vi báo cáo này, đề tài tập trung vào:

- **Bài toán:** tóm tắt **đơn văn bản** (single-document summarization).
- **Ngôn ngữ:** tiếng Việt.
- **Miền dữ liệu:** 'Bất động sản', 'Xã hội', 'Lao Động cuối tuần', 'Kinh doanh', 'Thời sự', 'Bạn đọc', 'Công đoàn', 'Pháp luật', 'Thể thao', 'Sự kiện Bình luận', 'Xe +', 'Thế giới', 'Văn hóa - Giải trí', 'Sổ tay kinh tế', 'Lao Động và Đời sống', 'Phóng sự', 'Lưu trữ', 'Tin địa phương', 'Tin bài liên quan', 'Giáo dục', 'Sức khỏe', 'Media' 'Video' 'Công nghệ' 'Diễn đàn' 'Tâm Lòng Vàng', 'Thông tin doanh nghiệp', 'Tin bài nổi bật', 'Gia đình - Hôn nhân'.
- **Đầu ra mong muốn:** bản tóm tắt ngắn gọn, đúng độ dài mục tiêu, hạn chế lặp và hạn chế sai lệch thông tin.

Đóng góp dự kiến

Các đóng góp chính của đề tài gồm:

- Đề xuất pipeline kết hợp trong đó TextRank đóng vai trò lọc ý chính/giảm độ dài đầu vào, giúp ViT5-small sinh tóm tắt mạch lạc hơn và giảm nhiễu.
- Thiết kế thực nghiệm so sánh và các thí nghiệm ablation để kiểm chứng hiệu quả của mô hình kết hợp so với các baseline.
- Phân tích định tính theo ví dụ (case study) và thảo luận các lỗi thường gặp để rút ra nhận xét và hướng cải thiện.

Cấu trúc báo cáo: Báo cáo được tổ chức gồm 3 chương: (1) Cơ sở lý thuyết, (2) Phương pháp đề xuất, (3) Thực nghiệm & kết quả.


Chương 1

Cơ sở lý thuyết


1.1 Tổng quan bài toán tóm tắt văn bản

Tóm tắt văn bản là bài toán tạo ra một văn bản ngắn hơn từ văn bản nguồn nhưng vẫn giữ lại phần thông tin quan trọng và giảm bớt chi tiết thừa. Nói cách khác, mục tiêu là nén thông tin nhưng không làm mất “ý chính”. Lượng thông tin trực tuyến hàng ngày đều tăng nhanh, khiến cho nhu cầu cần một công cụ "đọc nhanh hiểu đúng" [3]. Đó cũng chính là động lực mà định nghĩa tóm tắt văn bản được nhắc đến một cách phổ biến xem như một công cụ đáp ứng nhu cầu thông tin [3].

Trong lĩnh vực xử lý ngôn ngữ tự nhiên, các phương pháp tóm tắt văn bản thường được phân loại dựa trên cách thức tiếp cận và tái tạo thông tin. Có ba hướng tiếp cận chủ đạo: Tóm tắt trích xuất (Extractive), Tóm tắt tóm lược (Abstractive) và Tóm tắt lai (Hybrid). Phương pháp trích xuất thực hiện việc lựa chọn và ghép nối nguyên văn các câu quan trọng từ văn bản gốc (Hình 1.1). Tóm tắt tóm lược sử dụng các mô hình học sâu để "hiểu" và diễn đạt lại nội dung bằng ngôn ngữ tự nhiên mới (Hình 1.2). Phương thức này cải thiện đáng kể sự trôi chảy và cấu trúc ngữ pháp, trong khi đó tóm tắt trích xuất giúp đảm bảo tính trung thực của thông tin và tối ưu chi phí tính toán. Lúc này, Tóm tắt lai là sự kết hợp giữa khả năng chọn lọc nội dung chính xác của phương pháp trích xuất và khả năng diễn đạt mượt mà của phương pháp tóm lược. Phương thức này nhằm cân bằng giữa tính chính xác và sự mạch lạc.



Hình 1.1: Pipeline tóm tắt *extractive*: văn bản nguồn được phân tích bằng thống kê (tần suất/độ quan trọng) và đối sánh mẫu, rồi kết hợp các tín hiệu để chọn những câu quan trọng và trích chúng tạo thành bản tóm tắt. [4]



Hình 1.2: Pipeline tóm tắt *abstractive*: văn bản nguồn được phân tích cú pháp và ngữ nghĩa (cây cú pháp + cơ sở tri thức), sau đó nén cấu trúc/nén ý và cuối cùng sinh ra bản tóm tắt (có thể viết lại câu mới). [4]

Dựa trên hệ thống phân loại trong khảo sát của Nnadi và Bertini [5], chất lượng của một văn bản tóm tắt được đánh giá đa chiều thông qua ba khía cạnh: mức độ chồng lấp ngữ nghĩa (semantic overlap), chất lượng ngôn ngữ (linguistic quality) và tính nhất quán nội dung (consistency). Cụ thể, nghiên cứu này tập trung vào 5 tiêu chí cốt lõi sau:

- **Độ bao phủ thông tin (Coverage/Informativeness):** Tiêu chí này đo lường mức độ văn bản tóm tắt lưu giữ được các thông tin quan trọng (salient information) từ văn bản gốc. Trong thực nghiệm, độ bao phủ thường được ước lượng thông qua chỉ số ROUGE (đo độ chồng lấp n-gram) hoặc phương pháp Pyramid (đo đơn vị

nội dung).

- **Tính mạch lạc (Coherence):** Phản ánh chất lượng liên kết logic và sự chuyển tiếp tự nhiên giữa các câu trong bản tóm tắt. Một bản tóm tắt mạch lạc phải tạo thành một thể thống nhất về mặt ngữ nghĩa, tránh hiện tượng rời rạc thường thấy khi ghép nối các câu trích xuất ngẫu nhiên.
- **Sự dư thừa (Redundancy):** Đánh giá mức độ lặp lại thông tin (repetition) trong văn bản đầu ra. Đây là vấn đề thường gặp ở các mô hình sinh (Abstractive); do đó, tóm tắt chất lượng cao cần tối thiểu hóa sự trùng lặp từ ngữ hoặc ý tưởng để đảm bảo tính cô đọng.
- **Tính xác thực (Factuality/Consistency):** Yêu cầu mọi thông tin trong bản tóm tắt phải được suy diễn (entailed) trực tiếp từ văn bản nguồn. Theo Maynez và cộng sự [2], đây là thách thức lớn nhất của các mô hình học sâu do hiện tượng "ảo giác" (hallucination) — tức việc sinh ra thông tin sai lệch hoặc không tồn tại trong nguồn.
- **Kiểm soát độ dài (Length Control):** Đảm bảo bản tóm tắt tuân thủ các ràng buộc về dung lượng (số từ, số câu) để phù hợp với mục đích sử dụng. Tỷ lệ nén (Compression Ratio - CR) được sử dụng như thước đo định lượng để đánh giá khả năng thu gọn thông tin của mô hình.

1.2 Nhóm phương pháp Extractive Summarization

Phương pháp tóm tắt trích rút hoạt động dựa trên việc xác định và lựa chọn các đơn vị ngôn ngữ quan trọng (thường là các câu hoặc đoạn văn) trực tiếp từ văn bản gốc để tạo thành bản tóm tắt [6]. Quá trình này không tạo ra văn bản mới mà chỉ trích xuất (copy-paste) các thành phần có sẵn.

Dựa trên mô hình kiến trúc chung được đề xuất bởi El-Kassas et al. [6], quy trình hoạt động của một hệ thống tóm tắt trích rút điển hình bao gồm 7 bước chính, được minh họa như trong Hình 1.3 và chi tiết dưới đây:




Fig. 4. The architecture of an extractive text summarization system.

Hình 1.3: Kiến trúc chung của hệ thống tóm tắt văn bản trích rút (Theo El-Kassas et al. [6])

1. **Tài liệu nguồn (Source Document):** Đầu vào của hệ thống là văn bản gốc cần tóm tắt. Văn bản này có thể ở nhiều định dạng khác nhau (tin tức, báo cáo khoa học, v.v.).
2. **Tiền xử lý (Pre-processing):** Đây là bước chuẩn bị dữ liệu thô để máy tính có thể xử lý hiệu quả. Các thao tác thường gặp bao gồm: phân tách câu (sentence segmentation), tách từ (tokenization), loại bỏ từ dừng (stop-word removal), và chuẩn hóa từ (stemming hoặc lemmatization).
3. **Biểu diễn văn bản (Creating a Representation of Text):** Chuyển đổi văn bản đã qua tiền xử lý thành các cấu trúc dữ liệu máy tính hiểu được. Các mô hình phổ biến bao gồm mô hình không gian vector (Vector Space Model - VSM) sử dụng TF-IDF, hoặc mô hình dựa trên đồ thị (Graph-based models) nơi các câu là đỉnh và độ tương đồng là cạnh.
4. **Đánh giá câu (Scoring of Sentences):** Gán trọng số (điểm số) cho từng câu dựa trên các đặc trưng đã trích xuất. Các đặc trưng này có thể là vị trí câu, độ dài,

từ khóa, hoặc độ tương đồng ngữ nghĩa với tiêu đề/các câu khác. Mục tiêu là định lượng mức độ quan trọng của từng câu.

5. **Trích xuất câu điểm cao (Extraction of High-scored Sentences):** Dựa trên bảng xếp hạng điểm số ở bước trước, hệ thống sẽ chọn ra k câu có điểm cao nhất để làm ứng viên cho bản tóm tắt.
6. **Hậu xử lý (Post-processing):** Đây là bước quan trọng để tinh chỉnh kết quả thô. Các kỹ thuật thường dùng bao gồm: sắp xếp lại câu theo trật tự xuất hiện gốc, giải quyết vấn đề đồng tham chiếu (anaphora resolution) để câu văn rõ nghĩa, và đặc biệt là loại bỏ sự dư thừa (redundancy removal) để đảm bảo thông tin không bị lặp lại [7, 8].
7. **Bản tóm tắt đích (Target Summary):** Kết quả cuối cùng của hệ thống là một văn bản tóm tắt hoàn chỉnh được đưa ra cho người dùng.

1.2.1 Các phương pháp tiếp cận chính

Các kỹ thuật tóm tắt trích rút rất đa dạng, từ các phương pháp thống kê đơn giản đến các mô hình học sâu phức tạp. Dựa trên khảo sát của El-Kassas et al. [6], có thể phân loại thành các nhóm chính sau:

- **Phương pháp dựa trên thống kê (Statistical-based):** Sử dụng các đặc trưng như tần suất từ (TF-IDF), vị trí của câu trong đoạn văn, hoặc độ dài câu để tính toán độ quan trọng.
- **Phương pháp dựa trên đồ thị (Graph-based):** Đây là phương pháp quan trọng và được ứng dụng rộng rãi (ví dụ: TextRank). Trong mô hình này, văn bản được biểu diễn dưới dạng đồ thị, trong đó các đỉnh (nodes) đại diện cho các câu và các cạnh (edges) biểu thị độ tương đồng giữa các câu (dựa trên sự trùng lặp từ ngữ hoặc độ tương đồng ngữ nghĩa). Thuật toán xếp hạng (như PageRank) được chạy trên đồ thị để tìm ra các đỉnh quan trọng nhất [6]. Ưu điểm của phương pháp này là không cần dữ liệu huấn luyện (unsupervised) và có khả năng nắm bắt cấu trúc toàn cục của văn bản.

- **Phương pháp dựa trên học máy (Machine Learning-based):** Coi việc tóm tắt như một bài toán phân lớp nhị phân (câu được chọn hoặc không được chọn) dựa trên các đặc trưng thủ công (hand-crafted features). Các mô hình truyền thống như Naive Bayes, Decision Trees, và Support Vector Machines (SVM) thường được sử dụng để học mối quan hệ giữa các đặc trưng và nhãn của câu từ dữ liệu huấn luyện.
- **Phương pháp dựa trên học sâu (Deep Learning-based):** Khác với các mô hình học máy truyền thống, phương pháp này sử dụng các mạng nơ-ron sâu (Deep Neural Networks) để tự động học các đặc trưng phức tạp từ dữ liệu. Các kiến trúc phổ biến bao gồm Convolutional Neural Networks (CNN) và Recurrent Neural Networks (RNN) giúp nắm bắt tốt hơn ngữ cảnh và cấu trúc ngữ nghĩa của văn bản.

1.2.2 Đánh giá ưu và nhược điểm

Theo nghiên cứu thực nghiệm của Giarelis et al. [9], phương pháp trích rút có những đặc điểm nổi bật so với phương pháp trùu tượng:


- **Ưu điểm:** Các bản tóm tắt trích rút đảm bảo tính chính xác về mặt cú pháp và ngữ nghĩa so với văn bản gốc, vì chúng sử dụng nguyên văn câu từ của tác giả. Việc triển khai các hệ thống này thường đơn giản hơn và ít tốn kém tài nguyên tính toán hơn so với các mô hình trùu tượng dựa trên Transformer [9].
- **Nhược điểm:** Hạn chế lớn nhất của phương pháp này là thiếu sự liên kết mạch lạc (coherence) giữa các câu được chọn, do chúng bị tách khỏi ngữ cảnh gốc. Ngoài ra, phương pháp trích rút không thể tổng hợp thông tin từ nhiều câu thành một câu ngắn gọn hơn, dẫn đến bản tóm tắt có thể vẫn còn dài dòng hoặc chứa thông tin dư thừa [9].

Việc kết hợp phương pháp trích rút (để lọc thông tin quan trọng) với phương pháp trùu tượng (để viết lại câu văn mượt mà) là một hướng đi tiềm năng để khắc phục các nhược điểm trên, đây cũng là cơ sở cho mô hình đề xuất trong khóa luận này.

1.2.3 TextRank

TextRank là một thuật toán xếp hạng dựa trên đồ thị (graph-based ranking algorithm) cho bài toán xử lý ngôn ngữ tự nhiên, được giới thiệu lần đầu bởi Mihalcea và Tarau vào năm 2004 [10]. Thuật toán này được lấy cảm hứng từ PageRank, thuật toán xếp hạng trang web nổi tiếng của Google, nhưng được điều chỉnh để áp dụng cho các đơn vị văn bản (từ khóa hoặc câu).

Cơ chế hoạt động: Trong bài toán tóm tắt văn bản, TextRank mô hình hóa văn bản dưới dạng một đồ thị, giúp trực quan hóa mối quan hệ giữa các câu như trong Hình 1.4.



Đồ thị liên kết câu

Hình 1.4: Mô phỏng đồ thị văn bản trong thuật toán TextRank: Các đỉnh là câu (Sentence), các cạnh biểu thị độ tương đồng (Similarity Weight).

Hệ thống hoạt động dựa trên các thành phần chính sau:

- **Đỉnh (Vertices):** Đại diện cho các câu trong văn bản.
- **Cạnh (Edges):** Biểu thị mối quan hệ tương đồng (similarity) giữa hai câu.

Độ tương đồng giữa hai câu S_i và S_j thường được tính dựa trên sự trùng lặp nội dung (content overlap), tức là số lượng từ chung giữa chúng. Công thức tính độ tương đồng được đề xuất bởi Mihalcea và Tarau [10] như sau:

$$\text{Similarity}(S_i, S_j) = \frac{|\{w_k | w_k \in S_i \cap w_k \in S_j\}|}{\log(|S_i|) + \log(|S_j|)} \quad (1.1)$$

Trong đó, S_i là tập hợp các từ trong câu i và $|S_i|$ là độ dài của câu (tổng số từ).

Sau khi xây dựng đồ thị, thuật toán sẽ tính toán điểm số (ranking score) cho mỗi đỉnh (câu) một cách đệ quy dựa trên điểm số của các đỉnh lân cận liên kết với nó. Điểm số của đỉnh V_i tại lần lặp thứ $k + 1$ được tính theo công thức [10]:

$$WS(V_i) = (1 - d) + d * \sum_{V_j \in In(V_i)} \frac{w_{ji}}{\sum_{V_k \in Out(V_j)} w_{jk}} WS(V_j) \quad (1.2)$$

Trong đó:

- d là hệ số damping (thường đặt là 0.85).
- $In(V_i)$ là tập hợp các đỉnh trỏ đến V_i .
- $Out(V_j)$ là tập hợp các đỉnh mà V_j trỏ tới.
- w_{ji} là trọng số của cạnh nối giữa V_j và V_i .

Thuật toán sẽ lặp lại quá trình tính toán cho đến khi điểm số của các đỉnh hội tụ (thay đổi không đáng kể qua các vòng lặp). Cuối cùng, các câu có điểm số cao nhất sẽ được chọn để đưa vào bản tóm tắt.

TextRank sở hữu nhiều ưu điểm vượt trội giúp nó trở thành một trong những thuật toán phổ biến nhất trong tóm tắt văn bản. Đầu tiên, đây là một phương pháp không giám sát (unsupervised), nghĩa là nó không yêu cầu dữ liệu huấn luyện đã được gán nhãn thủ công – một quá trình thường tốn kém và mất nhiều công sức. Điều này giúp TextRank linh hoạt và tiết kiệm chi phí xây dựng tài nguyên đáng kể [10]. Thứ hai, TextRank có tính độc lập ngôn ngữ (language-independent) cao. Do hoạt động dựa trên sự trùng lặp từ vựng và cấu trúc đồ thị thay vì phụ thuộc vào các quy tắc ngữ pháp phức tạp, thuật toán này có thể dễ dàng áp dụng cho nhiều ngôn ngữ khác nhau mà không cần thay đổi lớn về kiến trúc, miễn là có sẵn bộ tách từ phù hợp. Cuối cùng, một ưu điểm quan trọng khác là khả năng nắm bắt tính toàn cục (global context) của văn bản. Thay vì chỉ đánh giá câu dựa trên các đặc trưng thống kê cục bộ, TextRank xem xét mối quan hệ liên kết giữa các câu trong toàn bộ văn bản để xác định mức độ quan trọng, từ đó trích xuất được những thông tin cốt lõi nhất [11]

1.3 Nhóm phương pháp Abstractive Summarization

1.3.1 Ý tưởng chung

Sau nhóm phương pháp *extractive* (trích chọn), nhóm phương pháp *abstractive* hướng đến việc **tạo sinh** một bản tóm tắt ngắn gọn, mạch lạc, giữ đúng ý chính và diễn đạt gần với cách con người viết. Mục tiêu chung của tóm tắt văn bản là tạo ra một tài liệu ngắn hơn nhưng vẫn **mạch lạc, đọc được và nhất quán về mặt sự thật** so với văn bản nguồn [5]. Nhờ các mô hình học sâu, đặc biệt là Transformer, tóm tắt *abstractive* có thể **diễn giải (paraphrase)** các phần của văn bản nguồn thay vì chỉ sao chép nguyên câu [5].

Trong thực tế, quá trình tóm tắt *abstractive* thường có thể nhìn như hai bài toán con:

- **chọn/định vị nội dung quan trọng** (content selection)
- **hiện thực hoá bề mặt bằng ngôn ngữ tự nhiên** (surface realization) để tạo ra bản tóm tắt cuối cùng [12].


Điều này cũng gợi mở các hướng *hybrid* (kết hợp) giữa trích chọn và tạo sinh, đặc biệt hữu ích khi đầu vào dài hoặc cần kiểm soát nội dung được đưa vào mô hình tạo sinh [5].

Một thách thức đi kèm với phương pháp *abstractive* là chất lượng đầu ra không chỉ phụ thuộc vào mức độ bao phủ ý chính, mà còn liên quan đến các tiêu chí như mạch lạc, trôi chảy, không lặp, và đặc biệt là **tính đúng sự thật**. Các nghiên cứu cũng chỉ ra rằng một số thước đo phổ biến dựa trên trùng khớp bề mặt có thể chưa phản ánh đầy đủ lỗi sai sự thật trong tóm tắt [12]. Vì vậy, ở các phần tiếp theo, báo cáo sẽ tiếp tục trình bày nền tảng mô hình hoá (Transformer encoder–decoder) và các mô hình tiêu biểu (BART, T5 và các biến thể cho tiếng Việt), làm cơ sở cho thiết kế hệ thống và đánh giá thực nghiệm.

1.3.2 Kiến trúc Transformer encoder–decoder

Trong bài toán tóm tắt *abstractive*, các mô hình hiện đại thường sử dụng kiến trúc **Transformer encoder–decoder**, trong đó **encoder** tạo biểu diễn ngữ cảnh cho văn bản

nguồn và **decoder** sinh chuỗi tóm tắt dựa trên biểu diễn đó [12]. Luồng xử lý tổng quát của mô hình được minh hoạ ở Hình 1.5.



Hình 1.5: Luồng xử lý của Transformer encoder–decoder dùng trong bài toán tạo sinh: embedding + positional encoding → encoder (self-attention, feed-forward, layer norm) → decoder (masked self-attention, encoder–decoder attention) → linear + softmax.

(1) Embedding và Positional Encoding

Đầu vào (văn bản nguồn) và đầu ra mục tiêu (chuỗi tóm tắt khi huấn luyện) trước hết được ánh xạ sang vector thông qua **embedding**. Do Transformer không xử lý tuần tự như RNN, mô hình bổ sung **positional encoding** để nắm được vị trí tương đối của token, giúp quan hệ giữa các từ và ngữ cảnh tổng thể được mô hình hoá tốt hơn [5, 12].

(2) Encoder: tạo biểu diễn ngữ cảnh cho văn bản nguồn

Encoder được tạo bởi nhiều lớp xếp chồng; trong mỗi lớp có **multi-head self-attention** và **feed-forward network**. Encoder có vai trò tạo ra một biểu diễn ngữ cảnh (context representation) tóm lược thông tin của chuỗi đầu vào để phục vụ giai đoạn sinh ở decoder. Cơ chế self-attention xuất hiện trong encoder cho phép mô hình học phụ thuộc xa và nắm bắt ngữ nghĩa hiệu quả.

(3) Decoder: sinh tóm tắt tự hồi quy và chú ý sang encoder

Decoder cũng gồm các lớp xếp chồng, nhưng được thiết kế để sinh chuỗi đầu ra theo cơ chế **tự hồi quy**. Trong decoder có hai cơ chế attention quan trọng:

- **Masked self-attention**: che các vị trí tương lai để decoder không “nhìn trước” trong quá trình huấn luyện, đảm bảo đúng bản chất tự hồi quy [5, 13].
- **Encoder-decoder attention (cross-attention)**: decoder chú ý đến đầu ra encoder để lấy đúng thông tin từ văn bản nguồn tại mỗi bước sinh [12, 13].


Sau khi đi qua các lớp decoder, biểu diễn cuối được đưa qua **linear layer** và **softmax** để tạo phân phối xác suất trên từ vựng cho token tiếp theo [5, 12].

Kiến trúc Transformer giúp mô hình học phụ thuộc xa hiệu quả thông qua cơ chế *self-attention*, nhờ đó cải thiện khả năng nắm bắt ngữ nghĩa tổng thể khi tóm tắt. Tuy nhiên, với văn bản dài, việc xử lý toàn bộ đầu vào có thể gặp hạn chế về độ dài ngữ cảnh và chi phí tính toán, từ đó thúc đẩy các chiến lược như rút gọn đầu vào, chọn câu quan trọng, hoặc dùng biến thể Transformer cho chuỗi dài. Những đặc điểm này liên hệ trực tiếp đến các quyết định thiết kế pipeline ở các chương sau (đặc biệt khi cần cân bằng giữa bao phủ nội dung và giới hạn độ dài đầu vào của mô hình tạo sinh).

1.3.3 Mô hình BART

Trong nhóm mô hình tạo sinh theo kiến trúc encoder-decoder, BART (*Bidirectional and Auto-Regressive Transformers*) là một mô hình **pretrained seq2seq** tiêu biểu. Điểm cốt lõi của BART nằm ở việc kết hợp **encoder hai chiều** (bidirectional) và **decoder tự**

hồi quy (autoregressive) trong cùng một kiến trúc Transformer [14]. Cách kết hợp này được minh hoạ trực quan trong Hình 1.6: encoder có thể khai thác ngữ cảnh hai phía của mỗi token trong văn bản nguồn, còn decoder sinh văn bản đầu ra theo hướng trái→phải dựa trên các token đã sinh trước đó [14].



Hình 1.6: Minh hoạ BART: encoder hai chiều (bidirectional) và decoder tự hồi quy (autoregressive) [14].

BART đặc biệt phù hợp với các bài toán **text generation** như tóm tắt, vì mô hình được tiền huấn luyện theo hướng *denoising autoencoder*: đầu vào được **làm nhiễu** và mô hình học cách **khôi phục** lại văn bản gốc, từ đó có thể *fine-tune* cho tác vụ tóm tắt *abstractive* [14].

(1) Kiến trúc encoder–decoder

BART sử dụng kiến trúc Transformer encoder–decoder. Ở phía encoder, mô hình mã hoá văn bản đầu vào theo kiểu hai chiều để tạo biểu diễn ngữ cảnh giàu thông tin. Ở phía decoder, mô hình sinh chuỗi đầu ra theo cơ chế tự hồi quy; tại mỗi bước, decoder dự đoán token kế tiếp dựa trên các token đã sinh và thông tin từ encoder thông qua attention. Thiết kế này giúp BART vừa “hiểu” tốt nội dung nguồn, vừa “viết lại” đầu ra trôi chảy trong khuôn khổ seq2seq.

(2) Tiền huấn luyện theo hướng denoising

Khác với các mô hình chỉ huấn luyện ngôn ngữ một chiều hoặc chỉ mã hoá, BART được tiền huấn luyện bằng cách **làm nhiễu** văn bản đầu vào rồi yêu cầu mô hình **tái**

tạo lại văn bản gốc. Các dạng nhiễu được thiết kế để phù hợp với mục tiêu học biểu diễn mạnh cho tác vụ tạo sinh, ví dụ: *text infilling* (che một đoạn liên tiếp và yêu cầu mô hình điền lại), *sentence permutation* (xáo trộn thứ tự câu), hoặc các dạng biến đổi tài liệu khác. Nhờ đó, mô hình học được khả năng khôi phục và tái cấu trúc nội dung, tạo nền tảng tốt cho các tác vụ sinh như tóm tắt.

(3) Fine-tuning cho bài toán tóm tắt

Sau tiền huấn luyện, BART được *fine-tune* cho tóm tắt bằng cách đưa văn bản nguồn vào encoder và huấn luyện decoder sinh ra bản tóm tắt tham chiếu. Trong bài báo gốc, BART được báo cáo đạt kết quả mạnh trên các tác vụ tạo sinh như tóm tắt, cho thấy tính phù hợp của kiến trúc “encoder hai chiều + decoder tự hồi quy” kết hợp với mục tiêu *denoising* đối với các bài toán cần đầu ra tự nhiên.

Kiến trúc BART khai thác khung Transformer encoder-decoder và được tiền huấn luyện theo hướng *denoising autoencoder*, nhờ đó mô hình học đồng thời khả năng “hiểu” ngữ cảnh ở encoder và khả năng “tạo sinh” tự hồi quy ở decoder, rất phù hợp cho các tác vụ sinh như tóm tắt. Tuy nhiên, tương tự các mô hình Transformer khác, BART vẫn chịu ảnh hưởng bởi giới hạn độ dài đầu vào và chi phí tính toán do cơ chế self-attention tăng theo bậc hai theo độ dài chuỗi, đặc biệt bất lợi khi xử lý văn bản dài. Vì vậy, trong thực tế thường cần các chiến lược như rút gọn/chọn lọc nội dung quan trọng trước khi đưa vào mô hình tạo sinh hoặc sử dụng các biến thể/thiết kế phù hợp cho chuỗi dài để cân bằng giữa mức độ bao phủ thông tin và giới hạn ngữ cảnh của mô hình.

1.3.4 Mô hình BARTpho

BARTpho kế thừa trực tiếp khung **BART** (Transformer encoder-decoder và mục tiêu tiền huấn luyện theo hướng *denoising*) nhưng điểm nổi bật so với BART gốc là mô hình được **tiền huấn luyện đơn ngữ cho tiếng Việt** nhằm phù hợp hơn với đặc thù ngôn ngữ và bài toán tạo sinh tiếng Việt (dịch, tóm tắt, sinh văn bản) [15]. Tác giả nhấn mạnh trước BARTpho, tiếng Việt chưa có một mô hình **monolingual seq2seq pretrained** quy mô lớn theo hướng BART [15].

Một khác biệt quan trọng khiến BARTpho “khác BART” là cách xử lý **đơn vị đầu vào** của tiếng Việt. Trong tiếng Việt, khoảng trắng vừa có thể phân tách **từ** vừa có thể phân tách **âm tiết** cấu thành từ, do đó BARTpho được xây dựng với **hai biến thể** để thích nghi hai cách biểu diễn này. Cả hai biến thể đều dùng cấu hình **large** (12 lớp encoder và 12 lớp decoder), nhưng khác nhau ở pipeline dữ liệu và tokenizer:

- **BARTpho_{syllable}**: làm việc trên văn bản theo mức **âm tiết** (dạng viết thông thường). Mô hình được tiền huấn luyện trên biến thể **detokenized** của PhoBERT corpus với quy mô khoảng **4B syllable tokens**, và sử dụng **SentencePiece** (tương tự thiết lập của mBART) để tách thành các đơn vị *sub-syllable* với từ vựng khoảng **40K**.
- **BARTpho_{word}**: làm việc trên văn bản đã **tách từ** (tác giả minh hoạ các từ đa âm tiết bằng dấu gạch dưới, ví dụ “Chúng_tôi”). Phiên bản này dùng **PhoBERT pre-training corpus** khoảng **20GB** (xấp xỉ **145M** câu đã tách từ), đồng thời **tái sử dụng tokenizer BPE của PhoBERT** với từ vựng **64K subword types**.


Nhờ được tiền huấn luyện chuyên biệt cho tiếng Việt và xét đến khác biệt giữa biểu diễn mức âm tiết và mức từ, BARTpho được báo cáo đạt kết quả mạnh trên các tác vụ tạo sinh tiếng Việt; trong bài toán tóm tắt tiếng Việt, BARTpho **vượt mBART** trong thiết lập thí nghiệm của tác giả. Vì vậy, BARTpho thường được xem là một mốc tham chiếu quan trọng khi đánh giá các mô hình encoder–decoder cho tóm tắt tiếng Việt, và đồng thời gợi ý rằng bước **chuẩn hoá đầu vào/tách từ** có thể ảnh hưởng đáng kể đến chất lượng mô hình trong các pipeline tiếng Việt.

Tuy nhiên, BARTpho cũng có một số hạn chế khi áp dụng trong thực tế. Thứ nhất, do vẫn dựa trên kiến trúc Transformer encoder–decoder, mô hình chịu ràng buộc về **độ dài ngữ cảnh** và **chi phí tính toán** khi xử lý văn bản dài, khiến việc đưa toàn bộ tài liệu vào mô hình không phải lúc nào cũng khả thi và thường cần các chiến lược rút gọn/chọn lọc nội dung. Thứ hai, BARTpho tồn tại dưới hai biến thể đầu vào (*syllable* và *word*), nên kết quả phụ thuộc đáng kể vào **pipeline tiền xử lý** (đặc biệt là bước tách từ đối với BARTpho_{word}); nếu chuẩn hoá dữ liệu không nhất quán với tokenizer thì chất lượng

có thể suy giảm. Cuối cùng, giống các mô hình tóm tắt *abstractive*, BARTpho vẫn có thể gặp rủi ro về **sai lệch nội dung/độ đúng sự thật** do cơ chế tạo sinh, đây là thách thức chung được ghi nhận trong các khảo sát về tóm tắt *abstractive*.

1.3.5 Mô hình T5

T5 (*Text-to-Text Transfer Transformer*) đề xuất một cách nhìn thống nhất cho NLP: **mọi tác vụ đều được đưa về dạng “text vào → text ra”** bằng cách thêm **tiền tố tác vụ** (task prefix) vào đầu chuỗi đầu vào, ví dụ “**summarize:** ...”, “**translate English to German:** ...” [13]. Với cách biểu diễn này, mô hình có thể dùng cùng một kiến trúc seq2seq, cùng hàm mất mát và quy trình huấn luyện/giải mã cho nhiều bài toán, trong đó có *abstractive summarization* [13]. Minh hoạ cơ chế *text-to-text* và task prefix được thể hiện ở Hình 1.7.



Hình 1.7: Minh hoạ *text-to-text framework* của T5: thêm tiền tố tác vụ vào đầu vào và huấn luyện mô hình sinh ra chuỗi đích tương ứng (dịch, phân loại, tóm tắt, ...) [13].

(1) Bài toán hoá tóm tắt theo dạng *text-to-text*

Trong thiết lập của T5, tóm tắt được viết lại thành một bài toán sinh có điều kiện: đầu vào là “**summarize:**” kèm theo văn bản nguồn, và đầu ra là chuỗi tóm tắt cần sinh [13]. Cách chuẩn hoá này đặc biệt hữu ích trong pipeline tóm tắt *abstractive* vì: (i) giúp mô hình “hiểu rõ” mục tiêu sinh thông qua tiền tố tác vụ, và (ii) tạo điều kiện tái sử dụng cùng một mô hình cho các bước liên quan khác (ví dụ: chuẩn hoá/diễn đạt lại, sinh tiêu đề, ...).

(2) Kiến trúc nền: Transformer encoder–decoder

Về tổng thể, T5 vẫn dựa trên kiến trúc **Transformer encoder–decoder** cho bài toán seq2seq [13]. Encoder tạo biểu diễn ngữ cảnh của văn bản nguồn, còn decoder sinh chuỗi đầu ra theo cơ chế tự hồi quy. Điểm quan trọng là: trong khi Transformer gốc là một khung tổng quát, T5 **đóng gói** khung đó thành một “mẫu triển khai” tối ưu cho *transfer learning* và các tác vụ tạo sinh, trong đó có tóm tắt .

(3) Các khác biệt chính so với Transformer encoder–decoder “chuẩn”

Dù bám sát kiến trúc Transformer ban đầu, T5 có một số điều chỉnh ở mức triển khai để phù hợp hơn với mục tiêu tiền huấn luyện và mở rộng quy mô [13]. Bảng 1.1 tóm tắt các khác biệt chính.

Bảng 1.1: So sánh một số khác biệt triển khai giữa Transformer encoder–decoder “chuẩn” và T5 [13].

Thành phần	Transformer “chuẩn”	T5
Vị trí LayerNorm	Thường theo kiểu <i>post-norm</i> : <i>Add & Norm</i> sau mỗi sub-layer	Dùng <i>pre-norm</i> : LayerNorm đặt ở đầu vào mỗi sub-layer
Bias trong các lớp tuyến tính	Có bias trong các phép chiếu tuyến tính	Loại bỏ bias trong các phép chiếu tuyến tính để đơn giản hoá triển khai
Mã hoá vị trí	Positional encoding tuyệt đối (sinusoidal hoặc learned)	Dùng relative position bias (mã hoá vị trí tương đối dưới dạng bias)

Nhìn từ bài toán tóm tắt, các điều chỉnh trên không làm thay đổi luồng xử lý encoder–decoder, nhưng giúp tạo một nền tảng kiến trúc/thực thi ổn định hơn cho **tiền huấn luyện quy mô lớn** và **fine-tune sinh văn bản**.

(4) Tiền huấn luyện, giải mã và liên hệ ưu/nhược trong tóm tắt

T5 được thiết kế gắn với hướng **transfer learning** quy mô lớn: mô hình được huấn luyện trước trên một tập văn bản sạch kích thước rất lớn (C4, hàng trăm GB) và đánh giá trên nhiều tác vụ, trong đó có tóm tắt. Trong thực nghiệm, tác giả cũng cho thấy với

các tác vụ sinh có đầu ra dài (như tóm tắt), **beam search** có thể cải thiện chất lượng so với giải mã tham lam (greedy). Về ưu/nhược điểm khi áp dụng cho tóm tắt *abstractive*: T5 thuận lợi ở chỗ khung *text-to-text* tạo ra một cách tiếp cận thống nhất và dễ chuyển giao giữa các nhiệm vụ sinh, từ đó hỗ trợ thiết kế pipeline linh hoạt (ví dụ mở rộng từ “tóm tắt” sang các biến thể sinh khác chỉ bằng thay đổi prefix). Tuy nhiên, hiệu năng theo các độ đo tự động (như ROUGE) không luôn đồng nghĩa với tóm tắt mạch lạc, và các mô hình sinh huấn luyện theo maximum likelihood có thể gặp vấn đề lặp (repetition). Vì vậy, khi triển khai cho bài toán của chúng tôi (tóm tắt tiếng Việt), phần tiếp theo sẽ tập trung vào các biến thể T5 được **thích nghi theo ngôn ngữ/dữ liệu**, đồng thời cân nhắc các lựa chọn pipeline để cân bằng giữa **chất lượng diễn đạt** và các rủi ro thường gặp của mô hình tạo sinh.

1.3.6 Mô hình ViT5 (T5 cho tiếng Việt)

ViT5 được đề xuất như một mô hình **text-to-text Transformer encoder-decoder** chuyên biệt cho tiếng Việt, được *pretrain* theo phong cách T5 và sau đó *fine-tune* cho nhiều tác vụ tạo sinh (trong đó có tóm tắt) [16]. Nếu T5 ban đầu hướng tới một khung **thống nhất text-to-text** trên các bài toán NLP [13], thì ViT5 giữ lại công thức đó nhưng điều chỉnh những thành phần then chốt (dữ liệu, tokenizer/vocabulary, độ dài ngữ cảnh khi pretrain) để phù hợp hơn với đặc thù tiếng Việt và bài toán tóm tắt tiếng Việt [16].

(1) Giữ khung T5: *text-to-text* và *span corruption*

Về mặt ý tưởng, ViT5 kế thừa trực tiếp cách tiếp cận của T5: mọi tác vụ được đưa về dạng **chuỗi-vào** $\rightarrow$ **chuỗi-ra**, giúp cùng một kiến trúc encoder-decoder có thể dùng cho dịch máy, hỏi-đáp, phân loại (dưới dạng sinh nhãn), và đặc biệt là **tóm tắt** [13]. Ở giai đoạn tiền huấn luyện, ViT5 cũng sử dụng mục tiêu tự giám sát kiểu **denoising/span corruption** (làm nhiễu bằng cách che các đoạn rồi học khôi phục), tương thích với tinh thần “corrupt-reconstruct” mà T5 khảo sát và sử dụng trong thiết lập encoder-decoder.

(2) Khác biệt dữ liệu và tokenizer giữa T5 và ViT5

Khác biệt quan trọng nhất của ViT5 so với T5 nằm ở **nguồn dữ liệu tiền huấn luyện** và **cách xây dựng tokenizer/vocabulary** cho tiếng Việt. Bảng 1.2 tóm tắt các điểm chính.

Bảng 1.2: So sánh dữ liệu tiền huấn luyện và tokenizer/vocabulary giữa T5 và ViT5.

Thành phần	T5	ViT5
Ngôn ngữ mục tiêu	Chủ yếu tiếng Anh	Tiếng Việt (mô hình đơn ngữ)
Nguồn dữ liệu tiền huấn luyện	C4 (Corpus of Colossal Clean Crawled)	Vietnamese corpus trích từ CC100
Quy mô dữ liệu (thô)	Hàng trăm GB văn bản sạch (C4)	138GB (dạng thô)
Tách dữ liệu theo độ dài ngữ cảnh	Không nêu theo dạng 256/1024 trong mô tả này	69GB cho cấu hình 256-length và 71GB cho cấu hình 1024-length
Tokenizer	SentencePiece (khung text-to-text)	SentencePiece huấn luyện từ tập con dữ liệu tiếng Việt
Xây dựng vocabulary	Vocabulary dùng chung theo thiết lập T5	Huấn luyện vocab trên 5GB dữ liệu đã tiền xử lý; kích thước vocab 36K sub-words

(3) Hai trục biến thể của ViT5: kích cỡ mô hình và độ dài ngữ cảnh khi pretrain

ViT5 được huấn luyện theo hai trục biến thể chính:

- **kích cỡ mô hình** gồm **ViT5_{base} (310M)** và **ViT5_{large} (866M)**;
- **độ dài chuỗi** trong tiền huấn luyện gồm **256-length** và **1024-length**.

Về mục tiêu nhiễu, tác giả đặt **corruption rate = 15%** trong thiết lập span corruption, tương thích với các thảo luận/tiền lệ mà T5 sử dụng khi khảo sát tỉ lệ làm nhiễu và corruption theo span.

(4) Ưu điểm và hạn chế khi áp dụng cho tóm tắt tiếng Việt

Ưu điểm. Trên các tác vụ tóm tắt tiếng Việt, tác giả báo cáo một xu hướng nhất quán: từ baseline Transformer $\rightarrow$ các biến thể dựa BERT $\rightarrow$ mô hình đa ngữ (mBART, mT5) $\rightarrow$ mô hình **đơn ngữ** (BARTpho, ViT5) thì điểm ROUGE tăng dần; trong đó nhóm mô hình đơn ngữ nổi bật hơn mô hình đa ngữ, được lý giải bởi giai đoạn tiền huấn luyện tập trung và “hẹp” hơn theo ngôn ngữ. Đáng chú ý, dù ViT5 được pretrain trên corpus khá **tổng quát** (CC100), mô hình vẫn có thể vượt các mô hình được huấn luyện trên corpus hướng tin tức trong thiết lập đánh giá của tác giả. Ngoài ra, việc **1024-length nhỉnh hơn 256-length** gợi ý rằng tóm tắt văn bản dài (ví dụ >512 tokens) cần ngữ cảnh dài hơn ngay từ giai đoạn pretrain, từ đó giúp downstream summarization tốt hơn.

Hạn chế. Đổi lại, việc mở rộng **độ dài ngữ cảnh** (như 1024 tokens) và/hoặc dùng mô hình lớn hơn thường kéo theo chi phí tính toán cao hơn khi huấn luyện và suy luận, đặc biệt ở các pipeline tóm tắt có đầu vào dài. Ngoài ra, tác giả cũng ghi nhận không phải mọi tác vụ đều luôn hưởng lợi từ mô hình lớn nhất; ví dụ trong thiết lập NER của họ, một số cấu hình *large* có thể kém hơn cấu hình *base*. Điều này gợi ý khi triển khai thực tế, cần cân bằng giữa **chất lượng** và **chi phí**, đồng thời lựa chọn cấu hình (base/large, 256/1024) phù hợp với đặc thù dữ liệu và độ dài văn bản.

Trong bài toán của chúng tôi (tóm tắt tiếng Việt), các kết quả trên củng cố lựa chọn ViT5 như một mô hình tạo sinh phù hợp cho pha *abstractive*. Đặc biệt, việc nhấn mạnh vai trò **context length** liên hệ trực tiếp tới thiết kế pipeline ở các phần sau: khi văn bản nguồn quá dài so với giới hạn đầu vào, có thể cần chiến lược rút gọn/chọn lọc nội dung trước, nhằm vừa đảm bảo bao phủ thông tin quan trọng vừa phù hợp với giới hạn độ dài của mô hình tạo sinh.

1.4 So sánh Extractive và Abstractive (định hướng lựa chọn hybrid)

Để làm rõ lý do chọn hướng *hybrid* trong đề tài, Bảng 1.3 tổng hợp các tiêu chí so sánh chính giữa hai nhóm phương pháp *extractive* và *abstractive*.

Bảng 1.3: So sánh Extractive và Abstractive và định hướng lựa chọn hybrid [5].

Tiêu chí	Extractive	Abstractive
Bản chất phương pháp	Chọn các câu/đoạn quan trọng trực tiếp từ văn bản nguồn; tóm tắt là tập con của đầu vào	Sinh tóm tắt mới, có thể diễn đạt lại (paraphrase), khái quát hoá, kết hợp thông tin [5]
Yêu cầu dữ liệu nhân / huấn luyện	Có thể không cần nhãn (ví dụ TextRank); một số phương pháp học máy cần nhãn	Thường dựa trên mô hình học sâu; cần <i>pretrain</i> mạnh và/hoặc <i>fine-tune</i> trên dữ liệu tóm tắt [5]
Chất lượng ngôn ngữ	Dễ giữ đúng câu gốc nhưng có thể rời rạc, thiếu liên kết giữa các câu (coherence thấp)	Thường trôi chảy và mạch lạc hơn do mô hình sinh trực tiếp văn bản đầu ra [5]
Bao phủ và cô đọng thông tin	Có thể bỏ sót ý nếu câu quan trọng bị xếp hạng thấp; khó “nén” ý vì phụ thuộc câu gốc	Có khả năng cô đọng và hợp nhất nhiều câu thành một câu tóm tắt ngắn hơn (tính khái quát cao) [5]
Rủi ro sai sự thật (<i>factuality</i>)	Thấp hơn vì chủ yếu trích từ nguồn (gần như không “bịa” nội dung mới)	Cao hơn do cơ chế tạo sinh; có thể <i>hallucination</i> hoặc sai chi tiết nếu đầu vào dài/nhiều hoặc thiếu kiểm soát [5]
Xử lý văn bản dài	Nhẹ hơn; có thể chạy trên văn bản dài vì chủ yếu tính điểm/xếp hạng	Bị giới hạn độ dài đầu vào và chi phí self-attention; văn bản dài làm tăng chi phí và có thể mất ngữ cảnh [5]
Chi phí tính toán	Thường thấp; phù hợp triển khai nhanh hoặc chạy trên tài nguyên hạn chế	Thường cao hơn (huấn luyện + suy luận), đặc biệt ở bước giải mã khi sinh tóm tắt [5]
Khi nào phù hợp	Khi cần độ an toàn cao về nội dung, cần tốc độ, hoặc dữ liệu nhãn hạn chế	Khi ưu tiên chất lượng diễn đạt, tóm tắt tự nhiên, cần khả năng paraphrase và cô đọng [5]

Từ các đặc điểm trên, đề tài lựa chọn hướng **hybrid** để tận dụng ưu điểm của cả hai nhóm

- Dùng **TextRank** (extractive) để **lọc ý chính và giảm nhiễu** trước, giúp rút gọn đầu vào và giảm áp lực độ dài ngữ cảnh;
- Dùng mô hình sinh **ViT5-small** (abstractive) để **diễn đạt lại mạch lạc** và tạo bản tóm tắt cuối.

Cách tiếp cận này phù hợp với nhận định chung rằng hybrid có thể kết hợp bước *content selection* và bước *generation/paraphrasing* nhằm cân bằng giữa **bao phủ thông tin, tính mạch lạc và độ đúng sự thật** trong tóm tắt *abstractive* [5].

1.5 Độ đo đánh giá tóm tắt văn bản

Đánh giá hệ thống tóm tắt thường cần kết hợp nhiều góc nhìn, vì chất lượng tóm tắt không chỉ phụ thuộc vào mức độ bao phủ nội dung mà còn liên quan đến tính trôi chảy, mạch lạc và mức độ phù hợp với tham chiếu. Do đó, báo cáo sử dụng các độ đo tự động (ROUGE, BERTScore, CR/RR) và đánh giá thủ công để phản ánh tương đối đầy đủ các khía cạnh của bản tóm tắt [17–19].

1.5.1 ROUGE (đánh giá dựa trên chồng lấp n-gram)

ROUGE (*Recall-Oriented Understudy for Gisting Evaluation*) là bộ độ đo phổ biến trong tóm tắt, đánh giá chất lượng bằng mức độ trùng khớp giữa tóm tắt hệ thống và tóm tắt tham chiếu theo n-gram hoặc theo chuỗi [17]. Các biến thể thường sử dụng gồm:

- **ROUGE-1**: trùng khớp unigram, phản ánh mức bao phủ nội dung ở mức từ.
- **ROUGE-2**: trùng khớp bigram, phản ánh mức đúng cụm từ và liên kết cục bộ.
- **ROUGE-L**: dựa trên *Longest Common Subsequence (LCS)*, phản ánh mức tương đồng theo chuỗi dài.

ROUGE thường được báo cáo theo Precision/Recall/F1. Với ROUGE-N:

$$P = \frac{|G_N \cap R_N|}{|G_N|}, \quad R = \frac{|G_N \cap R_N|}{|R_N|}, \quad F1 = \frac{2PR}{P + R},$$

trong đó G_N và R_N lần lượt là tập n-gram của tóm tắt hệ thống và tóm tắt tham chiếu [17]. Hạn chế đáng chú ý của ROUGE là nhạy với khác biệt diễn đạt (paraphrase), vì dựa trên trùng khớp bề mặt [19].

1.5.2 BERTScore (đánh giá theo tương đồng ngữ nghĩa)

BERTScore đánh giá chất lượng sinh văn bản bằng cách biểu diễn mỗi token dưới dạng embedding ngữ cảnh (từ mô hình kiểu BERT), sau đó so khớp token giữa tóm tắt hệ thống và tham chiếu theo cosine similarity để tính Precision/Recall/F1 ở mức biểu diễn [18]. Do không yêu cầu trùng khớp chính xác theo chuỗi, BERTScore thường phù hợp hơn với tóm tắt *abstractive* khi mô hình có thể diễn đạt khác nhưng vẫn giữ nghĩa [18]. Tuy nhiên, BERTScore phụ thuộc vào mô hình embedding và có thể không phản ánh đầy đủ các lỗi chất lượng như sai lệch thông tin hoặc thiếu nhất quán so với văn bản nguồn [19].

1.5.3 CR/RR và kiểm soát độ dài

Bên cạnh chất lượng nội dung, tóm tắt cần đạt mức cô đọng nhất định. **Compression Ratio (CR)** là một chỉ số trực quan:

$$CR = \frac{\text{Length}(S)}{\text{Length}(T)},$$

trong đó S là tóm tắt và T là văn bản gốc; $\text{Length}(\cdot)$ có thể tính theo số từ hoặc số token. CR càng nhỏ thì mức nén càng mạnh.

Retention Ratio (RR) thường được hiểu như mức giữ lại thông tin so với tóm tắt tham chiếu R :

$$RR = \frac{\text{Information}(S)}{\text{Information}(R)}.$$

Tuy nhiên, khái niệm “Information” cần được định nghĩa theo một cách đo lường cụ thể (ví dụ dựa trên các đơn vị nội dung hoặc dựa trên độ khớp với tham chiếu). Vì vậy, trong thực nghiệm báo cáo này ưu tiên CR để kiểm soát độ dài, và sử dụng ROUGE/BERTScore để phản ánh chất lượng nội dung.

1.5.4 Đánh giá thủ công

Các nghiên cứu đánh giá quy mô lớn cho thấy độ đo tự động có thể chưa phản ánh đầy đủ các khía cạnh như mạch lạc, trôi chảy, và mức độ phù hợp tổng thể của tóm tắt; do đó đánh giá thủ công thường được khuyến nghị như một bước bổ sung quan trọng [19]. Trong báo cáo, nhóm sử dụng thang điểm 1–5 theo các tiêu chí:

- **Đúng ý/Bao phủ:** mức độ giữ lại các ý quan trọng so với văn bản nguồn.
- **Mạch lạc & trôi chảy:** tính tự nhiên của câu văn và liên kết logic giữa các câu.
- **Không lặp:** mức độ dư thừa, lặp từ hoặc lặp ý.
- **Tính đúng sự thật:** mức độ nhất quán của nội dung tóm tắt với văn bản nguồn.

Cách đánh giá đa tiêu chí giúp phân tách rõ các khía cạnh chất lượng thay vì chỉ dựa trên một điểm tổng [19].

Chương 2

Phương pháp đề xuất

2.1 Ý tưởng tổng thể

Báo cáo đề xuất một hướng tiếp cận *hybrid* gồm hai tầng:


- Tầng *extractive* dùng TextRank để chọn các câu quan trọng từ văn bản nguồn;
- Tầng *abstractive* dùng mô hình sinh ViT5 để tạo tóm tắt từ phần nội dung đã được rút gọn.

Thay vì đưa toàn bộ văn bản dài vào mô hình tạo sinh (dễ vượt giới hạn độ dài hoặc làm giảm hiệu quả suy luận), hệ thống trước hết tạo một **pseudo-document** bằng cách ghép các câu quan trọng nhất, sau đó mới thực hiện tạo sinh. Cách thiết kế này hướng tới hai mục tiêu:

- (1) tăng mức độ bao phủ ý chính do đầu vào của mô hình sinh đã được lọc nhiễu;
- (2) giảm nguy cơ sinh lan man bằng cách giới hạn mô hình trong một ngữ cảnh ngắn gọn và tập trung.

2.2 Pipeline hệ thống

Hình 2.1 mô tả luồng xử lý tổng quát của hệ thống. Các bước được hiện thực trực tiếp trong notebook thực nghiệm.



Hình 2.1: Pipeline hệ thống hybrid: TextRank rút gọn đầu vào và ViT5 sinh tóm tắt.

2.2.1 Bước 1: Tiền xử lý và tách câu

Văn bản đầu vào được tách câu bằng bộ tách câu (ưu tiên `nltk.sent_tokenize`, có cơ chế dự phòng bằng regex khi cần). Sau đó, mỗi câu được chuẩn hoá để phục vụ tính toán tương đồng: chuyển về chữ thường, loại dấu câu, loại chữ số và chuẩn hoá khoảng trắng. Trong hiện thực, hệ thống **giữ ánh xạ (mapping)** giữa danh sách câu gốc và danh sách câu đã làm sạch, nhằm đảm bảo câu được chọn bởi TextRank luôn được khôi phục đúng theo văn phong gốc khi tạo pseudo-document.

2.2.2 Bước 2: Biểu diễn câu bằng Word2Vec trung bình

Để tính tương đồng giữa các câu, mỗi câu sau tiền xử lý được đưa qua `ViTokenizer` để tách từ/ghép âm tiết theo dạng từ nhiều âm tiết. Sau đó, với mô hình Word2Vec tiếng Việt (`vi.vec`), hệ thống lấy vector cho từng token (nếu tồn tại trong từ điển) và biểu diễn câu bằng trung bình cộng:

$$\mathbf{s} = \frac{1}{m} \sum_{i=1}^m \mathbf{w}_i,$$

trong đó $\mathbf{w}_i$ là vector Word2Vec của token thứ i và m là số token có vector hợp lệ. Nếu một câu không có token nào khớp từ điển, vector câu được gán về vector không.

2.2.3 Bước 3: Xây dựng đồ thị tương đồng câu và chạy TextRank

Từ các vector câu, hệ thống tính ma trận tương đồng cosine:

$$\text{sim}(i, j) = \cos(\mathbf{s}_i, \mathbf{s}_j),$$

và đặt đường chéo chính bằng 0 để loại tự tương đồng. Một đồ thị vô hướng được xây dựng với mỗi nút là một câu, trọng số cạnh là $\text{sim}(i, j)$. Trên đồ thị này, thuật toán PageRank được áp dụng để xếp hạng mức độ quan trọng của câu. Các câu có điểm PageRank cao nhất được chọn làm **top- k** .

2.2.4 Bước 4: Tạo pseudo-document

Các câu được chọn bởi TextRank được **ghép lại theo thứ tự xuất hiện trong văn bản gốc** (thay vì theo thứ tự điểm số), nhằm giữ tính tự nhiên của mạch nội dung. Kết quả là một **pseudo-document** ngắn hơn, tập trung hơn so với văn bản nguồn.

2.2.5 Bước 5: Tạo sinh bằng ViT5

Pseudo-document được đưa vào mô hình ViT5 dạng encoder-decoder để sinh tóm tắt. Trong hiện thực, đầu vào được **cắt ngắn có kiểm soát** bằng **truncation** với giới hạn độ dài (`max_length=512`) để phù hợp với khả năng tiếp nhận của mô hình. Quá trình giải mã sử dụng beam search và các tham số nhằm giảm lặp:

- **Beam search:** `num_beams = 4`
- **Độ dài sinh tối đa:** `max_new_tokens = 128`
- **Chống lặp:** `no_repeat_ngram_size = 3`
- **Length penalty:** `length_penalty = 1.0`

Lưu ý rằng trong thiết lập đang dùng, mô hình ViT5 là một checkpoint đã được huấn luyện cho tóm tắt, vì vậy hệ thống không bắt buộc phải thêm tiền tố (**prefix**) cho đầu vào.

2.2.6 Bước 6: Hậu xử lý và xuất kết quả

Sau khi sinh, tóm tắt được chuẩn hoá ở mức cơ bản (loại khoảng trắng thừa, strip). Hệ thống ghi lại kết quả theo từng mẫu gồm: văn bản nguồn, tóm tắt tham chiếu, tóm tắt TextRank (baseline) và tóm tắt Hybrid, đồng thời xuất ra file CSV để tiện phân tích và đánh giá thủ công.

2.3 Thiết kế tham số và biến thể (ablation)

Trong pipeline, một số tham số có ảnh hưởng trực tiếp đến chất lượng và chi phí tính toán:

2.3.1 Tham số TextRank

- **Số câu top- k :** tham số KEEP_SENTENCES. Đây là nút điều chỉnh mức rút gọn đầu vào (pseudo-document).
- **Mức tài nguyên Word2Vec:** tham số W2V_LIMIT có thể giới hạn số lượng vector nạp vào RAM khi cần.

2.3.2 Tham số tạo sinh

- **Giới hạn đầu vào:** max_length của tokenizer (ví dụ 512) quyết định lượng ngữ cảnh tối đa được đưa vào encoder.
- **Giải mã:** num_beams, max_new_tokens, length_penalty ảnh hưởng tới chất lượng và thời gian suy luận.
- **Chống lặp:** no_repeat_ngram_size giúp giảm hiện tượng lặp cụm từ trong tóm tắt.

2.3.3 Các cấu hình so sánh

Trong thực nghiệm, hệ thống xuất đồng thời:

- **TextRank-only:** tóm tắt bằng cách ghép top- k câu.
- **Hybrid (TextRank $\rightarrow$ ViT5):** sinh tóm tắt từ pseudo-document.

Ngoài ra, có thể mở rộng thêm biến thể **ViT5-only** (đưa trực tiếp văn bản nguồn vào mô hình và để truncation xử lý) để quan sát riêng tác động của tầng extractive trong pipeline.

2.4 Tiêu chí lựa chọn cấu hình cuối

Việc lựa chọn cấu hình cuối cùng dựa trên sự cân bằng giữa chất lượng tóm tắt và tính khả thi khi triển khai:

- **Chất lượng nội dung theo độ đo tự động:** ưu tiên cấu hình cho điểm ROUGE/BERTScore tốt trên tập đánh giá.
- **Mức độ cô đọng:** theo dõi **Compression Ratio (CR)** để đảm bảo tóm tắt đủ ngắn, đúng mục tiêu độ dài.
- **Đánh giá định tính:** kiểm tra thủ công một phần mẫu để xác nhận tóm tắt không rời rạc, không lặp và hạn chế sai lệch thông tin.
- **Tài nguyên và tốc độ:** cân nhắc cấu hình decoding (beam size, độ dài sinh) và giới hạn đầu vào để phù hợp môi trường chạy (ví dụ Kaggle GPU).

Chương 3



Thực nghiệm và kết quả

3.1 Dữ liệu

Tập dữ liệu sử dụng trong báo cáo gồm các cặp (*văn bản, tóm tắt tham chiếu*) tiếng Việt, trong đó văn bản nguồn được lấy từ cột **Contents** và tóm tắt tham chiếu từ cột **Summary**. Sau bước làm sạch và loại bỏ các mẫu rỗng, tập dữ liệu còn lại **48,971** mẫu.

Để thống nhất với thiết lập suy luận của các mô hình tạo sinh, độ dài được thống kê theo **số token** của tokenizer (cùng hệ quy chiếu với giới hạn độ dài đầu vào/đầu ra của mô hình). Kết quả cho thấy văn bản nguồn có độ dài trung bình khoảng **637.7** tokens (trung vị **543** tokens), trong khi tóm tắt tham chiếu có độ dài trung bình khoảng **52.5** tokens (trung vị **48** tokens). Tỷ lệ nén theo token của tóm tắt tham chiếu so với văn bản nguồn (Compression Ratio) có giá trị trung bình khoảng **0.12**, phản ánh mức độ cô đọng tương đối cao của bài toán.

Phân bố độ dài trong Hình 3.1 cho thấy độ dài văn bản nguồn lệch phải mạnh (tồn tại một số mẫu rất dài), trong khi độ dài tóm tắt tham chiếu tập trung chủ yếu quanh khoảng 40–70 tokens và đuôi dài đến xấp xỉ 250 tokens. Đáng chú ý, có khoảng **53.86%** văn bản vượt quá **512 tokens** và khoảng **10.74%** vượt quá **1024 tokens**. Điều này cho thấy việc đưa trực tiếp toàn bộ văn bản vào mô hình tạo sinh có thể gặp hạn chế do *ngữ cảnh đầu vào* và chi phí tính toán, từ đó củng cố động cơ sử dụng các chiến lược rút gọn đầu vào (như TextRank) trong pipeline hybrid ở các phần sau.



Hình 3.1: Phân bố độ dài (theo token) của văn bản nguồn và tóm tắt tham chiếu trong tập dữ liệu.

3.2 Thiết lập thí nghiệm

3.2.1 Các mô hình so sánh

Nhóm thực hiện so sánh giữa các cấu hình:

- **TextRank-only** (tóm tắt trích xuất bằng cách chọn câu quan trọng);
- **Mô hình tạo sinh** (*ViT5* hoặc *BARTpho*) theo thiết lập suy luận;
- **Hybrid** kết hợp TextRank để rút gọn đầu vào và mô hình tạo sinh để sinh tóm tắt.

3.2.2 Cấu hình TextRank

TextRank được triển khai theo quy trình: tách câu $\rightarrow$ vector hoá câu $\rightarrow$ tính tương đồng cosine $\rightarrow$ xây đồ thị $\rightarrow$ chạy PageRank để xếp hạng. Nhóm thử nghiệm các giá trị $\text{top-}k \in \{3, 5, 7\}$; các câu được ghép lại theo thứ tự xuất hiện trong văn bản để tạo *pseudo-document*. Bên cạnh biến thể $\text{top-}k$, nhóm cũng xét thiết lập **giới hạn theo số token** nhằm phù hợp với ngữ cảnh đầu vào của mô hình tạo sinh: *pseudo-document* được bổ sung lần lượt các câu có điểm TextRank cao (giữ thứ tự xuất hiện) cho đến khi đạt ngưỡng tối đa **512 tokens** hoặc **1024 tokens** (tính theo tokenizer của mô hình). Thiết lập này giúp kiểm soát độ dài đầu vào, đồng thời cho phép khai thác nhiều nội dung hơn khi ngữ cảnh cho phép.

3.2.3 Cấu hình mô hình tạo sinh

Trong báo cáo, nhóm sử dụng checkpoint `VietAI/vit5-base-vietnews-summarization` cho ViT5 (hoặc `lyng148/bartpho-vietnews-sum` cho BARTpho). Độ dài đầu vào được giới hạn bởi `max_length` (512 hoặc 1024 tokens tùy thiết lập), và đầu ra được sinh bằng beam search với các tham số: `num_beams=4`, `max_new_tokens=128`, `no_repeat_ngram_size=3`, `length_penalty=1.0`. Toàn bộ thí nghiệm được thực hiện trên môi trường Kaggle với GPU.

3.3 Chỉ số đánh giá

3.3.1 ROUGE

Nhóm sử dụng ROUGE để đo mức độ trùng khớp n-gram giữa tóm tắt hệ thống và tóm tắt tham chiếu, báo cáo theo ROUGE-1, ROUGE-2 và ROUGE-L. Trong thực nghiệm, nhóm báo cáo điểm F1 trung bình trên tập đánh giá.

3.3.2 BERTScore

BERTScore được sử dụng để đánh giá mức tương đồng ngữ nghĩa giữa tóm tắt sinh ra và tóm tắt tham chiếu dựa trên embedding ngữ cảnh. Nhóm báo cáo Precision, Recall và F1 trung bình.

3.3.3 Compression Ratio (CR)

Để phản ánh mức độ cô đọng, nhóm sử dụng tỉ lệ nén $CR = \frac{|S|}{|T|}$, trong đó $|S|$ là độ dài tóm tắt và $|T|$ là độ dài văn bản nguồn.

3.3.4 Đánh giá thủ công

Bên cạnh các độ đo tự động, nhóm tiến hành đánh giá thủ công trên một tập con ngẫu nhiên gồm M mẫu. Mỗi tóm tắt được chấm theo thang 1–5 trên bốn tiêu chí: (i) bao phủ ý chính, (ii) mạch lạc và trôi chảy, (iii) hạn chế lặp, và (iv) đúng sự thật (không bịa).

3.4 Kết quả và phân tích

3.4.1 Kết quả tổng quan

Bảng 3.1 và Bảng 3.2 trình bày kết quả đánh giá trên tập thử nghiệm cho hai cấu hình mô hình tạo sinh (ViT5 và BARTpho) khi kết hợp với tầng rút gọn đầu vào bằng TextRank. Nhìn chung, so với **TextRank-only**, cấu hình **Hybrid** (TextRank $\rightarrow$ mô hình

tạo sinh) cải thiện rõ rệt các chỉ số ROUGE và BERTScore, đồng thời tạo ra tóm tắt có độ nén lớn hơn (CR nhỏ hơn). Điều này cho thấy việc rút gọn đầu vào giúp mô hình tạo sinh tập trung vào các câu quan trọng, từ đó cải thiện cả mức độ bao phủ theo n-gram (ROUGE) lẫn mức tương đồng ngữ nghĩa (BERTScore).

Với **ViT5**, Hybrid đạt ROUGE-1 khoảng **58–60** và ROUGE-L khoảng **38–41** tùy theo k ; đồng thời BERTScore-F1 tăng từ khoảng **0.85** (TextRank-only) lên khoảng **0.86–0.87**. Trong các giá trị top- k được thử nghiệm, $k = 7$ cho kết quả ROUGE tốt nhất (ROUGE-1 **59.66**, ROUGE-2 **31.55**, ROUGE-L **40.89**), trong khi $k = 3$ cho CR của Hybrid thấp nhất (xấp xỉ **0.1007**), phản ánh tóm tắt ngắn hơn. Ngoài biến thể top- k , chiến lược **giới hạn theo token** cho đầu vào (TextRank-limit) đạt hiệu quả cao và ổn định: giới hạn **512 tokens** cho ROUGE-1 **60.33**, ROUGE-2 **32.10**, ROUGE-L **41.22** và BERTScore-F1 **0.8731**; giới hạn **1024 tokens** cho ROUGE-1 **59.72**, ROUGE-2 **31.19**, ROUGE-L **40.74** và BERTScore-F1 **0.8727**. Kết quả này gợi ý rằng trong thiết lập hiện tại, việc kiểm soát đầu vào theo token (thay vì cố định số câu) giúp tận dụng ngữ cảnh tốt hơn mà vẫn phù hợp giới hạn mô hình.

Với **BARTpho**, Hybrid cũng cải thiện so với TextRank-only (ROUGE-L tăng từ khoảng **19–26** lên **32–34**), và BERTScore-F1 tăng từ khoảng **0.845–0.849** lên **0.850–0.855**. Tuy nhiên, điểm ROUGE của BARTpho thấp hơn ViT5 trong cùng thiết lập: ROUGE-1 khoảng **48.89–50.20** và ROUGE-L khoảng **32.48–34.22**. Đổi lại, CR của Hybrid với BARTpho nhỏ hơn (khoảng **0.065**), cho thấy mô hình có xu hướng sinh tóm tắt ngắn hơn.

Bảng 3.1: Kết quả với ViT5 (điểm ROUGE-F1, BERTScore-F1 và CR trung bình).

Cấu hình	R-1	R-2	R-L	BERT-F1	CR
TextRank-only ($k = 3$)	38.34	21.57	26.47	0.8488	0.4062
TextRank-only ($k = 5$)	29.14	18.50	21.84	0.8462	0.5947
TextRank-only ($k = 7$)	24.69	17.00	19.37	0.8451	0.4062
Hybrid (TextRank→ViT5, $k = 3$)	58.16	28.06	37.92	0.8633	0.1007
Hybrid (TextRank→ViT5, $k = 5$)	58.87	30.08	39.39	0.8673	0.1002
Hybrid (TextRank→ViT5, $k = 7$)	59.66	31.55	40.89	0.8701	0.1007
Hybrid (TextRank-limit 512→ViT5)	60.33	32.10	41.22	0.8731	–
Hybrid (TextRank-limit 1024→ViT5)	59.72	31.19	40.74	0.8727	–

Bảng 3.2: Kết quả với BARTpho (điểm ROUGE-F1, BERTScore-F1 và CR trung bình).

Cấu hình	R-1	R-2	R-L	BERT-F1	CR
TextRank-only ($k = 3$)	38.34	21.57	26.47	0.8488	0.4062
TextRank-only ($k = 5$)	29.14	18.50	21.84	0.8462	0.5947
TextRank-only ($k = 7$)	24.69	17.00	19.37	0.8451	0.4062
Hybrid (TextRank→BARTpho, $k = 3$)	48.89	20.78	32.48	0.8503	0.0651
Hybrid (TextRank→BARTpho, $k = 5$)	49.59	22.37	33.38	0.8531	0.0654
Hybrid (TextRank→BARTpho, $k = 7$)	50.20	23.12	34.22	0.8548	0.0657

3.4.2 Phân tích ablation

(1) Ảnh hưởng của top- k

Bảng 3.1 và Bảng 3.2 cho thấy khi tăng top- k (từ 3 lên 5 và 7), *pseudo-document* chứa nhiều thông tin hơn, nhờ đó chất lượng tóm tắt của cấu hình hybrid có xu hướng được cải thiện. Với ViT5, các chỉ số ROUGE tăng đều theo k : ROUGE-1 tăng từ **58.16** ($k = 3$) lên **59.66** ($k = 7$), ROUGE-2 tăng từ **28.06** lên **31.55**, và ROUGE-L tăng từ **37.92** lên **40.89**. BERTScore-F1 cũng tăng nhẹ từ **0.8633** lên **0.8701**, cho thấy đầu ra không chỉ khớp n-gram tốt hơn mà còn gần nghĩa hơn với tóm tắt tham chiếu. Xu hướng tương tự xuất hiện với BARTpho: ROUGE-1 tăng từ **48.89** lên **50.20** và ROUGE-L tăng từ **32.48** lên **34.22** khi k tăng từ 3 lên 7. Như vậy, trong dải thử nghiệm hiện tại, tăng k giúp mô hình tạo sinh có thêm manh mối nội dung để bao phủ tốt hơn các ý chính.

(2) So sánh top- k với giới hạn theo token

Bên cạnh top- k cố định, chiến lược **TextRank-limit** lựa chọn câu theo điểm TextRank nhưng dừng khi đạt ngưỡng độ dài đầu vào (tính theo token). Với ViT5, cấu hình giới hạn theo token cho kết quả cao và ổn định: **512 tokens** đạt ROUGE-1 **60.33**, ROUGE-2 **32.10**, ROUGE-L **41.22**, cao hơn các cấu hình top- k tương ứng; trong khi **1024 tokens** đạt ROUGE-1 **59.72**, ROUGE-2 **31.19**, ROUGE-L **40.74**. Điều này gợi ý rằng việc cố định số câu đôi khi chưa tận dụng hết dung lượng ngữ cảnh của mô hình; ngược lại, giới hạn theo token có thể linh hoạt “nhét” thêm các câu quan trọng khi còn dư ngữ cảnh, nhờ đó tăng mức độ bao phủ và cải thiện ROUGE.

(3) So sánh ViT5 và BARTpho trong cấu hình hybrid

Trong cùng thiết lập rút gọn đầu vào bằng TextRank, ViT5 consistently đạt ROUGE cao hơn BARTpho. Chẳng hạn ở $k = 7$, ViT5 đạt ROUGE-1/2/L lần lượt là **59.66/31.55/40.89**, trong khi BARTpho đạt **50.20/23.12/34.22**. BERTScore-F1 của ViT5 cũng nhỉnh hơn (khoảng **0.863–0.873** so với **0.850–0.855** ở BARTpho). Tuy nhiên, BARTpho có xu hướng sinh tóm tắt ngắn hơn thể hiện qua CR nhỏ hơn (khoảng **0.065** so với khoảng **0.100** của ViT5 trong các cấu hình top- k), tức là mô hình nén mạnh hơn nhưng đánh đổi bằng mức độ bao phủ theo ROUGE.

(4) So sánh giới hạn token 512 và 1024

Trong thí nghiệm với ViT5, giới hạn **512 tokens** cho kết quả hơi tốt hơn **1024 tokens** trên cả ROUGE và BERTScore (ROUGE-L **41.22** so với **40.74**; BERTScore-F1 **0.8731** so với **0.8727**). Sự khác biệt không lớn, nhưng gợi ý rằng việc tăng ngưỡng cảnh lên 1024 tokens không tự động mang lại cải thiện, có thể do phần nội dung bổ sung chưa đủ “đậm đặc” về thông tin hoặc làm tăng nhiễu. Ở góc nhìn thực tiễn, cấu hình 512 tokens cũng có ưu thế về tốc độ và tài nguyên tính toán, nên là lựa chọn hợp lý nếu mục tiêu là cân bằng hiệu quả và chi phí.

(5) So sánh TextRank-only và Hybrid

Kết quả cho thấy tăng tạo sinh đem lại cải thiện đáng kể so với trích xuất thuần túy. Ví dụ với ViT5 ở $k = 3$, TextRank-only đạt ROUGE-1/2/L là **38.34/21.57/26.47**, trong khi Hybrid đạt **58.16/28.06/37.92**; điều này phản ánh mô hình tạo sinh có khả năng **diễn đạt lại** và **kết nối thông tin** tốt hơn so với việc ghép câu trực tiếp. Xu hướng tương tự cũng xuất hiện ở các giá trị k khác và với BARTpho. Về độ dài, Hybrid tạo ra tóm tắt ngắn hơn đáng kể (ví dụ CR của ViT5 Hybrid khoảng **0.10** so với CR của TextRank-only khoảng **0.41–0.59**), cho thấy mô hình tạo sinh thực sự “nén” và tái diễn đạt nội dung thay vì giữ nguyên câu gốc. Tổng hợp lại, các kết quả ủng hộ lựa chọn hướng **hybrid** như một cách cân bằng giữa việc chọn lọc nội dung quan trọng và đảm bảo đầu ra trôi chảy, cô đọng.

3.4.3 Minh hoạ định tính

Để bổ sung cho các chỉ số tự động, phần này trình bày một số ví dụ minh hoạ nhằm quan sát trực tiếp sự khác biệt về *độ mạch lạc*, *mức độ bao phủ ý chính* và xu hướng *diễn đạt lại* giữa các cấu hình. Bảng 3.3–3.5 lần lượt minh hoạ ba trường hợp với độ dài văn bản tăng dần (tương đối ngắn, dài và rất dài), qua đó cho phép so sánh đồng thời hai chiến lược rút gọn đầu vào: (i) chọn top- k câu và (ii) giới hạn theo số token (512/1024).

Từ các ví dụ có thể quan sát rằng **TextRank** giữ nguyên các câu trích xuất từ văn bản gốc nên thường bám sát nội dung và ít sai lệch thông tin, nhưng do chỉ là phép ghép câu, đầu ra dễ rời rạc và thiếu liên kết mạch văn. Ngược lại, **mô hình tạo sinh** (khi dùng đầu vào đã rút gọn) cho bản tóm tắt trôi chảy hơn và có khả năng gộp ý, diễn đạt lại tự nhiên; tuy nhiên trong một số trường hợp vẫn có thể lược bỏ chi tiết hoặc diễn đạt khái quát hơn so với tham chiếu. Cấu hình **hybrid** cân bằng hai đặc điểm này bằng cách đưa vào mô hình tạo sinh một *pseudo-document* đã được TextRank lọc và tập trung vào các câu quan trọng, từ đó cải thiện tính mạch lạc trong khi vẫn giữ được các ý chính của văn bản nguồn.

Bảng 3.3: Ví dụ minh họa (văn bản tương đối ngắn), độ dài nguồn = 359 tokens

Mục	Nội dung
Văn bản (rút gọn)	Nghệ sĩ Hồng Tơ bị công an bắt quả tang đang tổ chức đánh bạc và tạm giữ từ ngày 5-5. Theo kết quả điều tra ban đầu, trưa 5-5, đội cảnh sát hình sự Công an huyện Bình Chánh (TP.HCM) bắt quả tang Hồng Tơ tổ chức đánh bạc và đánh bạc tại nhà riêng. Thời điểm này, ngoài nghệ sĩ Hồng Tơ còn có 5 người khác gồm: Nguyễn Văn C (62 tuổi), Võ Thị L (59 tuổi), Trần Quốc T (58 tuổi), Nguyễn Văn H (62 tuổi), Nguyễn Thị N (55 tuổi) cùng ở TP.HCM. Tang vật thu giữ gồm nhiều bộ bài tây, 9,4 triệu đồng cùng nhiều tang vật khác. Nghệ sĩ Hồng Tơ bị tạm giữ để phục vụ công tác điều tra. Trước đó, nhiều nghệ sĩ Việt Nam cũng bị bắt vì liên quan đến hoạt động cờ bạc.
Reference	Nghệ sĩ Hồng Tơ bị bắt quả tang đang tổ chức đánh bạc tại nhà riêng ở huyện Bình Chánh (TP.HCM) cùng 5 người khác, công an thu giữ 9,4 triệu đồng và nhiều tang vật, hiện bị tạm giữ điều tra.
TextRank (top- $k=7$)	Nghệ sĩ Hồng Tơ bị công an bắt quả tang đang tổ chức đánh bạc và tạm giữ từ ngày 5-5. Theo kết quả điều tra ban đầu, trưa 5-5, đội cảnh sát hình sự Công an huyện Bình Chánh (TP.HCM) bắt quả tang Hồng Tơ tổ chức đánh bạc và đánh bạc tại nhà riêng. Tang vật thu giữ gồm nhiều bộ bài tây, 9,4 triệu đồng cùng nhiều tang vật khác. Nghệ sĩ Hồng Tơ bị tạm giữ để phục vụ công tác điều tra. Trước đó, nhiều nghệ sĩ Việt Nam cũng bị bắt vì liên quan đến hoạt động cờ bạc.
Hybrid (top- $k \rightarrow$ model)	Nghệ sĩ Hồng Tơ bị công an huyện Bình Chánh bắt quả tang tổ chức đánh bạc tại nhà riêng cùng 5 người khác. Công an thu giữ nhiều bộ bài tây, 9,4 triệu đồng và nhiều tang vật, hiện nghệ sĩ này bị tạm giữ để điều tra.
TextRank (limit 512)	Nghệ sĩ Hồng Tơ bị công an bắt quả tang đang tổ chức đánh bạc và tạm giữ từ ngày 5-5. Theo kết quả điều tra ban đầu, trưa 5-5, đội cảnh sát hình sự Công an huyện Bình Chánh (TP.HCM) bắt quả tang Hồng Tơ tổ chức đánh bạc và đánh bạc tại nhà riêng. Thời điểm này, ngoài nghệ sĩ Hồng Tơ còn có 5 người khác gồm: Nguyễn Văn C (62 tuổi), Võ Thị L (59 tuổi), Trần Quốc T (58 tuổi), Nguyễn Văn H (62 tuổi), Nguyễn Thị N (55 tuổi) cùng ở TP.HCM. Tang vật thu giữ gồm nhiều bộ bài tây, 9,4 triệu đồng cùng nhiều tang vật khác.
Hybrid (limit 512 $\rightarrow$ model)	Nghệ sĩ Hồng Tơ bị công an huyện Bình Chánh bắt quả tang tổ chức đánh bạc tại nhà riêng trưa 5-5 cùng 5 người khác. Công an thu giữ nhiều bộ bài tây, 9,4 triệu đồng và nhiều tang vật, hiện ông bị tạm giữ để điều tra.
TextRank (limit 1024)	Nghệ sĩ Hồng Tơ bị công an bắt quả tang đang tổ chức đánh bạc và tạm giữ từ ngày 5-5. Theo kết quả điều tra ban đầu, trưa 5-5, đội cảnh sát hình sự Công an huyện Bình Chánh (TP.HCM) bắt quả tang Hồng Tơ tổ chức đánh bạc và đánh bạc tại nhà riêng. Thời điểm này, ngoài nghệ sĩ Hồng Tơ còn có 5 người khác gồm: Nguyễn Văn C (62 tuổi), Võ Thị L (59 tuổi), Trần Quốc T (58 tuổi), Nguyễn Văn H (62 tuổi), Nguyễn Thị N (55 tuổi) cùng ở TP.HCM. Tang vật thu giữ gồm nhiều bộ bài tây, 9,4 triệu đồng cùng nhiều tang vật khác. Nghệ sĩ Hồng Tơ bị tạm giữ để phục vụ công tác điều tra. Trước đó, nhiều nghệ sĩ Việt Nam cũng bị bắt vì liên quan đến hoạt động cờ bạc.
Hybrid (limit 1024 $\rightarrow$ model)	Nghệ sĩ Hồng Tơ bị công an huyện Bình Chánh bắt quả tang tổ chức đánh bạc tại nhà riêng cùng 5 người khác. Công an thu giữ nhiều bộ bài tây, 9,4 triệu đồng và nhiều tang vật, hiện nghệ sĩ này bị tạm giữ để điều tra.

Bảng 3.4: Ví dụ minh họa (văn bản dài), độ dài nguồn = 693 tokens

Mục	Nội dung
Văn bản (rút gọn)	Ngày 26-3, Ban Chỉ đạo phòng, chống dịch COVID-19 tỉnh Quảng Nam cho biết, đã phát hiện 5 người có kết quả xét nghiệm dương tính với SARS-CoV-2. Các trường hợp này đều là F1 của các ca bệnh đã được công bố trước đó. Trong 5 ca mắc mới có 1 trường hợp là nhân viên y tế làm việc tại Bệnh viện đa khoa khu vực miền núi phía Bắc Quảng Nam. Qua điều tra dịch tễ, trường hợp này có tiếp xúc gần với bệnh nhân COVID-19 điều trị tại bệnh viện. Địa phương đã phong tỏa khu vực liên quan, truy vết các F1, F2 và tổ chức lấy mẫu xét nghiệm diện rộng. Ban Chỉ đạo yêu cầu người dân tuân thủ 5K, hạn chế tụ tập, khai báo y tế đầy đủ và thực hiện nghiêm các biện pháp phòng dịch.
Reference	Quảng Nam ghi nhận thêm 5 ca dương tính SARS-CoV-2, đều là F1 của các ca trước; trong đó có một nhân viên y tế bệnh viện miền núi. Tỉnh đã phong tỏa khu vực, truy vết F1/F2 và lấy mẫu xét nghiệm diện rộng.
TextRank (top- $k=7$)	Ngày 26-3, Ban Chỉ đạo phòng, chống dịch COVID-19 tỉnh Quảng Nam cho biết, đã phát hiện 5 người có kết quả xét nghiệm dương tính với SARS-CoV-2. Các trường hợp này đều là F1 của các ca bệnh đã được công bố trước đó. Trong 5 ca mắc mới có 1 trường hợp là nhân viên y tế làm việc tại Bệnh viện đa khoa khu vực miền núi phía Bắc Quảng Nam. Địa phương đã phong tỏa khu vực liên quan, truy vết các F1, F2 và tổ chức lấy mẫu xét nghiệm diện rộng.
Hybrid (top- $k \rightarrow$ model)	Quảng Nam phát hiện thêm 5 ca dương tính SARS-CoV-2, đều là F1 của các ca bệnh trước đó; trong số này có một nhân viên y tế tại Bệnh viện đa khoa khu vực miền núi phía Bắc tỉnh. Địa phương đã phong tỏa khu vực liên quan, truy vết F1/F2 và lấy mẫu xét nghiệm diện rộng.
TextRank (limit 512)	Ngày 26-3, Ban Chỉ đạo phòng, chống dịch COVID-19 tỉnh Quảng Nam cho biết, đã phát hiện 5 người có kết quả xét nghiệm dương tính với SARS-CoV-2. Các trường hợp này đều là F1 của các ca bệnh đã được công bố trước đó. Trong 5 ca mắc mới có 1 trường hợp là nhân viên y tế làm việc tại Bệnh viện đa khoa khu vực miền núi phía Bắc Quảng Nam. Qua điều tra dịch tễ, trường hợp này có tiếp xúc gần với bệnh nhân COVID-19 điều trị tại bệnh viện. Địa phương đã phong tỏa khu vực liên quan, truy vết các F1, F2 và tổ chức lấy mẫu xét nghiệm diện rộng.
Hybrid (limit 512 $\rightarrow$ model)	Quảng Nam ghi nhận thêm 5 ca dương tính SARS-CoV-2, đều là F1 của các ca bệnh trước đó; trong đó có một nhân viên y tế Bệnh viện đa khoa khu vực miền núi phía Bắc tỉnh. Địa phương đã phong tỏa khu vực liên quan, truy vết F1/F2 và lấy mẫu xét nghiệm diện rộng.
TextRank (limit 1024)	Ngày 26-3, Ban Chỉ đạo phòng, chống dịch COVID-19 tỉnh Quảng Nam cho biết, đã phát hiện 5 người có kết quả xét nghiệm dương tính với SARS-CoV-2. Các trường hợp này đều là F1 của các ca bệnh đã được công bố trước đó. Trong 5 ca mắc mới có 1 trường hợp là nhân viên y tế làm việc tại Bệnh viện đa khoa khu vực miền núi phía Bắc Quảng Nam. Qua điều tra dịch tễ, trường hợp này có tiếp xúc gần với bệnh nhân COVID-19 điều trị tại bệnh viện. Địa phương đã phong tỏa khu vực liên quan, truy vết các F1, F2 và tổ chức lấy mẫu xét nghiệm diện rộng. Ban Chỉ đạo yêu cầu người dân tuân thủ 5K, hạn chế tụ tập, khai báo y tế đầy đủ và thực hiện nghiêm các biện pháp phòng dịch.
Hybrid (limit 1024 $\rightarrow$ model)	Quảng Nam phát hiện 5 người dương tính SARS-CoV-2, đều là F1 của các ca bệnh trước đó; trong đó có một nhân viên y tế tại Bệnh viện đa khoa khu vực miền núi phía Bắc tỉnh. Tỉnh đã phong tỏa khu vực liên quan, truy vết F1/F2 và lấy mẫu xét nghiệm diện rộng.

Bảng 3.5: Ví dụ minh hoạ (văn bản rất dài), độ dài nguồn = 1735 tokens

Mục	Nội dung
Văn bản (rút gọn)	Chỉ trong 2 ngày 24 và 25-7, tỉnh Phú Yên ghi nhận tổng cộng 247 ca mắc COVID-19 mới, trong đó nhiều ca ở TP Tuy Hòa và huyện Đông Hòa. Tỉnh đã áp dụng các biện pháp giãn cách xã hội, thiết lập nhiều chốt kiểm soát và tăng cường xét nghiệm diện rộng. Các lực lượng chức năng xử phạt nhiều trường hợp vi phạm quy định phòng dịch. Ngành y tế tiếp tục truy vết các trường hợp F1, F2 và yêu cầu người dân thực hiện nghiêm 5K.
Reference	Phú Yên ghi nhận 247 ca COVID-19 trong hai ngày 24-25/7, tập trung tại Tuy Hòa và Đông Hòa; tỉnh siết giãn cách, lập chốt kiểm soát, xét nghiệm diện rộng và xử phạt vi phạm phòng dịch.
TextRank (top- $k=7$)	Chỉ trong 2 ngày 24 và 25-7, tỉnh Phú Yên ghi nhận tổng cộng 247 ca mắc COVID-19 mới, trong đó nhiều ca ở TP Tuy Hòa và huyện Đông Hòa. Tỉnh đã áp dụng các biện pháp giãn cách xã hội, thiết lập nhiều chốt kiểm soát và tăng cường xét nghiệm diện rộng. Các lực lượng chức năng xử phạt nhiều trường hợp vi phạm quy định phòng dịch. Ngành y tế tiếp tục truy vết các trường hợp F1, F2 và yêu cầu người dân thực hiện nghiêm 5K.
Hybrid (top- $k \rightarrow$ model)	Phú Yên ghi nhận 247 ca COVID-19 mới trong hai ngày 24 và 25-7, chủ yếu tại TP Tuy Hòa và huyện Đông Hòa. Tỉnh tăng cường giãn cách, lập chốt kiểm soát, xét nghiệm diện rộng và xử phạt các trường hợp vi phạm quy định phòng dịch.
TextRank (limit 512)	Chỉ trong 2 ngày 24 và 25-7, tỉnh Phú Yên ghi nhận tổng cộng 247 ca mắc COVID-19 mới, trong đó nhiều ca ở TP Tuy Hòa và huyện Đông Hòa. Tỉnh đã áp dụng các biện pháp giãn cách xã hội, thiết lập nhiều chốt kiểm soát và tăng cường xét nghiệm diện rộng.
Hybrid (limit 512 $\rightarrow$ model)	Phú Yên ghi nhận 247 ca COVID-19 trong hai ngày 24-25/7, tập trung tại TP Tuy Hòa và huyện Đông Hòa. Tỉnh tăng cường giãn cách, lập chốt kiểm soát và xét nghiệm diện rộng để kiểm soát dịch.
TextRank (limit 1024)	Chỉ trong 2 ngày 24 và 25-7, tỉnh Phú Yên ghi nhận tổng cộng 247 ca mắc COVID-19 mới, trong đó nhiều ca ở TP Tuy Hòa và huyện Đông Hòa. Tỉnh đã áp dụng các biện pháp giãn cách xã hội, thiết lập nhiều chốt kiểm soát và tăng cường xét nghiệm diện rộng. Các lực lượng chức năng xử phạt nhiều trường hợp vi phạm quy định phòng dịch. Ngành y tế tiếp tục truy vết các trường hợp F1, F2 và yêu cầu người dân thực hiện nghiêm 5K.
Hybrid (limit 1024 $\rightarrow$ model)	Phú Yên ghi nhận 247 ca COVID-19 trong hai ngày 24-25/7, tập trung tại TP Tuy Hòa và huyện Đông Hòa. Tỉnh tăng cường giãn cách, lập chốt kiểm soát, xét nghiệm diện rộng và xử phạt các trường hợp vi phạm quy định phòng dịch.

3.4.4 Phân tích lỗi và ảnh hưởng của giới hạn token

Trong nhóm thí nghiệm *TextRank-limit*, kết quả cho thấy giới hạn **512 tokens** cho điểm ROUGE/BERTScore nhỉnh hơn **1024 tokens** dù chênh lệch không lớn. Hiện tượng này phù hợp với quan sát trong các nghiên cứu về mô hình ngôn ngữ trên ngữ cảnh dài: khi độ dài ngữ cảnh tăng, mô hình không nhất thiết khai thác thông tin tốt hơn, và hiệu năng có thể suy giảm do vị trí/thành phần thông tin trong chuỗi đầu vào thay đổi [20,21].

Thứ nhất, khi tăng ngưỡng lên **1024 tokens**, *pseudo-document* thường được bổ sung thêm các câu có độ “quan trọng” thấp hơn so với phần lõi ban đầu (do ràng buộc ngân sách token được nới rộng). Các câu bổ sung này có thể đóng vai trò bối cảnh phụ hoặc mang tính chi tiết rời rạc, làm giảm **mật độ thông tin quan trọng** của đầu vào. Các nghiên cứu về độ bền của mô hình tóm tắt trước nhiễu cho thấy việc đưa thêm nhiễu/đoạn ít liên quan vào đầu vào có thể làm suy giảm đáng kể chất lượng tóm tắt [22]. Vì vậy, trong thiết lập của nhóm, 1024 tokens có thể vô tình đưa thêm phần “ít salient”, khiến mô hình tạo sinh phân tán chú ý và sinh ra tóm tắt khái quát hơn.

Thứ hai, “ngữ cảnh dài hơn” không chỉ tăng lượng thông tin mà còn làm thay đổi **vị trí tương đối** của các chi tiết quan trọng trong chuỗi đầu vào. Hiện tượng *lost-in-the-middle* chỉ ra rằng mô hình thường khai thác thông tin tốt hơn khi các manh mối quan trọng nằm ở đầu/cuối chuỗi, và suy giảm khi thông tin nằm ở vùng giữa của ngữ cảnh dài [20]. Do đó, khi mở rộng từ 512 lên 1024 tokens, các câu quan trọng có thể bị “đẩy” vào vùng giữa chuỗi, làm mô hình sử dụng kém ổn định hơn, dẫn đến bỏ sót ý hoặc giảm mức độ cụ thể.

Thứ ba, trong bối cảnh tóm tắt văn bản dài, việc nới giới hạn độ dài đầu vào thường đi kèm các đánh đổi về hiệu quả và chất lượng do giới hạn xử lý chuỗi dài của Transformer và các biến thể tiền huấn luyện phổ biến [23]. Vì vậy, việc chọn ngân sách token phù hợp (như 512) đôi khi giúp giữ đầu vào cô đọng, giảm nhiễu và tăng tính tập trung, từ đó cải thiện điểm số so với việc “nhồi” thêm nội dung lên 1024 tokens.

Tóm lại, kết quả $512 > 1024$ trong thí nghiệm hiện tại có thể xem như một đánh đổi giữa **bao phủ** và **độ tập trung**: giới hạn 1024 đưa thêm nội dung, nhưng cũng làm tăng nhiễu và làm thay đổi vị trí manh mối quan trọng theo cách bất lợi cho mô hình [20–22].

Hướng cải thiện là thiết kế chiến lược chọn câu tối ưu theo ngân sách token (ưu tiên đa dạng ý, giảm trùng lặp), và tinh chỉnh decoding để giảm lặp và duy trì tính cụ thể của tóm tắt.

Bằng chứng thực nghiệm cho việc 512 tokens cho kết quả tốt hơn 1024. Để kiểm tra giả thuyết rằng ngữ cảnh dài hơn không nhất thiết cải thiện tóm tắt, nhóm thực hiện hai phép kiểm định dựa trên đặc trưng của *pseudo-document* (TextRank-limit) trên 200 mẫu.

(A) Mật độ thông tin quan trọng (salience density). Với mỗi văn bản, nhóm tính điểm PageRank của từng câu trong đồ thị TextRank và thống kê điểm của các câu được chọn theo ngân sách token. Kết quả cho thấy điểm PageRank trung bình của tập câu được chọn ở cấu hình 512 tokens cao hơn nhẹ so với 1024 ($\Delta\bar{s} = \bar{s}_{512} - \bar{s}_{1024} = +0.0066$), đồng thời tỷ lệ câu “điểm thấp” (nhỏ hơn median của toàn văn) tăng đáng kể khi chuyển sang 1024 ($\Delta r_{\text{low}} = r_{\text{low},1024} - r_{\text{low},512} = +0.1233$). Điều này cho thấy khi nới ngân sách lên 1024, *pseudo-document* có xu hướng thu nạp thêm các câu kém quan trọng hơn, làm giảm mật độ ý chính và tăng “nhiều” đầu vào; hiện tượng này phù hợp với các kết quả cho thấy nhiều đầu vào có thể làm suy giảm chất lượng tóm tắt [22].

(B) Hiệu ứng *lost-in-the-middle*. Nhóm tiếp tục kiểm tra vị trí tương đối (theo token) của các câu quan trọng nhất trong *pseudo-document*. Cụ thể, với mỗi mẫu, nhóm lấy top-3 câu có điểm PageRank cao nhất trong tập câu được chọn và ghi nhận chúng rơi vào vùng *đầu/giữa/cuối* của chuỗi token. Kết quả cho thấy tỷ lệ top-3 câu rơi vào vùng “giữa” tăng từ 0.3378 (512 tokens) lên 0.3598 (1024 tokens). Quan sát này nhất quán với hiện tượng *lost-in-the-middle*, theo đó mô hình khai thác ngữ cảnh kém ổn định hơn khi mạnh mỗi quan trọng nằm sâu trong phần giữa của chuỗi dài [20].

Từ hai kiểm định trên, có thể lý giải rằng cấu hình 512 tokens tạo *pseudo-document* cô đọng hơn, ít câu “đuôi” hơn và giữ vị trí thông tin quan trọng thuận lợi hơn, nhờ đó điểm ROUGE/BERTScore nhỉnh hơn so với 1024 tokens trong thiết lập hiện tại.

3.5 Thảo luận

3.5.1 Nhận xét tổng quan

Nhìn chung, các kết quả định lượng và quan sát định tính cho thấy hướng tiếp cận **hybrid** (TextRank $\rightarrow$ mô hình tạo sinh) là phù hợp trong bối cảnh tóm tắt tiếng Việt với đầu vào dài. Trong nhiều mẫu văn bản, **TextRank** đóng vai trò “làm sạch” và cô đọng nội dung bằng cách chọn các câu giàu thông tin, giúp giảm tải cho mô hình tạo sinh và hạn chế hiện tượng lan man khi phải xử lý toàn văn bản. Sau đó, **mô hình encoder-decoder** (ViT5/BARTpho) chuyển đổi *pseudo-document* thành bản tóm tắt trôi chảy hơn, có khả năng gộp ý và diễn đạt lại tự nhiên.

Tuy nhiên, hiệu quả của hybrid phụ thuộc mạnh vào chất lượng tầng trích xuất. Trong các trường hợp **văn bản dài hoặc nhiều nhiễu**, lợi ích của hybrid thể hiện rõ: tầng TextRank lọc bỏ các đoạn rườm rà và giữ lại các câu mang ý chính, qua đó cải thiện mức độ tập trung của đầu vào, từ đó giúp mô hình tạo sinh cho tóm tắt gọn và đúng trọng tâm hơn. Ngược lại, với các **văn bản ngắn** hoặc vốn đã rất “sạch” (ít câu thừa), bước trích xuất có thể không mang lại nhiều lợi ích, thậm chí làm mất một số chi tiết quan trọng nếu chọn câu không tối ưu.

Một điểm đáng chú ý là trong thiết lập *token-limit*, cấu hình giới hạn đầu vào **512 tokens** có xu hướng nhỉnh hơn **1024 tokens**. Kết quả thực nghiệm A/B cho thấy khi tăng ngân sách lên 1024, *pseudo-document* thường thu nạp thêm các câu có mức “quan trọng” thấp hơn và làm mất đi mối quan trọng dịch vào vùng giữa chuỗi, từ đó có thể làm suy giảm hiệu quả khai thác ngữ cảnh của mô hình tạo sinh. Quan sát này nhất quán với các nghiên cứu gần đây về tác động bất lợi của độ dài ngữ cảnh và hiện tượng *lost-in-the-middle* [20, 21], cũng như các phân tích về ảnh hưởng của nhiều đầu vào đối với tóm tắt [22].

3.5.2 Hạn chế

Mặc dù đạt kết quả tích cực, hệ thống vẫn tồn tại một số hạn chế.

- **Phụ thuộc vào tách câu và biểu diễn câu:** TextRank nhạy với chất lượng tách

câu; nếu câu bị tách sai hoặc quá dài/quá ngắn, chất lượng đồ thị tương đồng và thứ hạng PageRank sẽ bị ảnh hưởng. Ngoài ra, chất lượng biểu diễn câu (Word2Vec avg / TF-IDF / embedding) quyết định mạnh khả năng chọn đúng ý quan trọng.

- **Rủi ro hallucination vẫn tồn tại:** Dù hybrid giúp giảm bớt “bịa” bằng cách rút gọn đầu vào, mô hình tạo sinh vẫn có thể suy diễn sai hoặc làm mờ chi tiết (đặc biệt với số liệu, thực thể, mốc thời gian). Đây là hạn chế phổ biến của tóm tắt *abstractive* và cần cơ chế kiểm soát bổ sung.
- **Hạn chế của thước đo tự động:** ROUGE thiên về chồng lấp n-gram nên không phản ánh đầy đủ mức đúng sự thật và độ mạch lạc; BERTScore phản ánh ngữ nghĩa tốt hơn nhưng vẫn có thể cao dù câu “nghe hợp lý” mà không được suy ra trực tiếp từ nguồn. Vì vậy, đánh giá thủ công vẫn cần thiết để nhận diện lỗi factuality và coherence.
- **Giới hạn tài nguyên và thời gian suy luận:** Mô hình tạo sinh làm tăng chi phí tính toán so với extractive-only. Trong môi trường Kaggle, việc suy luận trên tập lớn hoặc thử nhiều cấu hình (top- k , token-limit, decoding) có thể tốn thời gian và phụ thuộc GPU.

3.5.3 Hướng phát triển

Từ các kết quả và hạn chế trên, có thể mở rộng theo một số hướng sau:

- **Fine-tune theo miền dữ liệu:** Fine-tune ViT5/BARTpho trên miền cụ thể (ví dụ tin tức, y tế, pháp luật) có thể giúp mô hình học phong cách diễn đạt và thuật ngữ đúng ngữ cảnh hơn, qua đó tăng mức độ chính xác và giảm diễn đạt chung chung.
- **Dùng sentence embedding mạnh hơn cho tầng trích xuất:** Thay Word2Vec avg/TF-IDF bằng embedding dựa trên PhoBERT hoặc SBERT cho tiếng Việt có thể cải thiện độ phân biệt ngữ nghĩa khi tính tương đồng câu, giúp TextRank chọn câu đúng trọng tâm và đa dạng ý hơn.

- **Giảm lặp và kiểm chứng thông tin:** Có thể bổ sung cơ chế giảm trùng lặp (MMR, trừ điểm các câu gần trùng; hoặc ràng buộc *no_repeat_ngram* mạnh hơn ở decoding), và hướng tới kiểm chứng factuality bằng cách so khớp thực thể/số liệu với nguồn hoặc dùng mô hình kiểm tra nhất quán (*fact-checking*).
- **Hướng tới triển khai thực tế:** Xây dựng demo (web/app), đo latency và tối ưu pipeline (giảm thời gian TextRank, batch inference, quantization) là các bước cần thiết để đánh giá khả năng triển khai trên môi trường thực tế.

Tài liệu tham khảo

- [1] O. Tas and F. Kiyani, “A survey automatic text summarization,” (2007). *A survey automatic text summarization. PressAcademia Procedia*, vol. 5, pp. 205–213, 2025.
- [2] J. Maynez, S. Narayan, B. Bohnet, and R. McDonald, “On faithfulness and factuality in abstractive summarization,” *arXiv preprint arXiv:2005.00661*, 2020.
- [3] D. Radev and K. McKeown, “Introduction to the special issue on summarization,” (2002). *Introduction to the special issue on summarization. Computational linguistics*, vol. 28, pp. 399–408, 2025.
- [4] U. Hahn and I. Mani, “The challenges of automatic summarization,” (2000). *The challenges of automatic summarization. Computer*, vol. 33, pp. 29–36, 2025.
- [5] G. O. Nnadi and F. Bertini, “Survey on abstractive text summarization: Dataset, models, and metrics,” *arXiv preprint arXiv:2412.17165*, 2024.
- [6] W. S. El-Kassas, C. R. Salama, A. A. Rafea, and H. K. Mohamed, “Automatic text summarization: A comprehensive survey,” *Expert systems with applications*, vol. 165, p. 113679, 2021.
- [7] N. Rahman and B. Borah, “Redundancy removal method for multi-document query-based text summarization,” in *2021 International Symposium on Electrical, Electronics and Information Engineering*, pp. 568–574, 2021.
- [8] J. Antunes, R. D. Lins, R. Lima, H. Oliveira, M. Riss, and S. J. Simske, “Automatic cohesive summarization with pronominal anaphora resolution,” *Computer Speech & Language*, vol. 52, pp. 141–164, 2018.

- [9] N. Giarelis, C. Mastrokostas, and N. Karacapilidis, “Abstractive vs. extractive summarization: An experimental review,” *Applied Sciences*, vol. 13, no. 13, p. 7620, 2023.
- [10] R. Mihalcea and P. Tarau, “Textrank: Bringing order into text,” in *Proceedings of the 2004 conference on empirical methods in natural language processing*, pp. 404–411, 2004.
- [11] S. Zaware, D. Patadiya, A. Gaikwad, S. Gulhane, and A. Thakare, “Text summarization using tf-idf and textrank algorithm,” in *2021 5th International conference on trends in electronics and informatics (ICOEI)*, pp. 1399–1407, IEEE, 2021.
- [12] S. Nair, Y. S. Rao, and R. Shankarmani, “Assessment of transformer-based encoder-decoder model for human-like summarization,” *arXiv preprint arXiv:2410.16842*, 2024.
- [13] C. Raffel, N. Shazeer, A. Roberts, K. Lee, S. Narang, M. Matena, Y. Zhou, W. Li, and P. J. Liu, “Exploring the limits of transfer learning with a unified text-to-text transformer,” *Journal of Machine Learning Research*, 2020.
- [14] M. Lewis, Y. Liu, N. Goyal, M. Ghazvininejad, A. Mohamed, O. Levy, V. Stoyanov, and L. Zettlemoyer, “Bart: Denoising sequence-to-sequence pre-training for natural language generation, translation, and comprehension,” *arXiv preprint arXiv:1910.13461*, 2019.
- [15] N. L. Tran, D. M. Le, and D. Q. Nguyen, “Bartpho: Pre-trained sequence-to-sequence models for vietnamese,” *arXiv preprint arXiv:2109.09701*, 2021.
- [16] L. Phan, H. Tran, H. Nguyen, and T. H. Trinh, “Vit5: Pretrained text-to-text transformer for vietnamese language generation,” *arXiv preprint arXiv:2205.06457*, 2022.

- [17] C.-Y. Lin, “Rouge: A package for automatic evaluation of summaries,” in *Text Summarization Branches Out*, pp. 74–81, Association for Computational Linguistics, 2004.
- [18] T. Zhang, V. Kishore, F. Wu, K. Q. Weinberger, and Y. Artzi, “Bertscore: Evaluating text generation with bert,” *CoRR*, vol. abs/1904.09675, 2019.
- [19] A. R. Fabbri, W. Kryściński, B. McCann, C. Xiong, R. Socher, and D. Radev, “Summeval: Re-evaluating summarization evaluation,” *Transactions of the Association for Computational Linguistics*, vol. 9, pp. 391–409, 2021.
- [20] N. F. Liu, K. Lin, J. Hewitt, A. Paranjape, M. Bevilacqua, F. Petroni, and P. Liang, “Lost in the middle: How language models use long contexts,” *Transactions of the Association for Computational Linguistics*, 2024.
- [21] M. Tian *et al.*, “Context length alone hurts llm performance despite perfect retrieval,” in *Findings of EMNLP*, 2025.
- [22] K. Krishna *et al.*, “Improving the robustness of summarization models by detecting and removing input noise,” in *Findings of EMNLP*, 2023.
- [23] J. Phang *et al.*, “Investigating efficiently extending transformers for long input summarization,” in *EMNLP*, 2023.

Phân công thành viên

Bảng 3.6: Phân công công việc (nhóm 1).

STT	Nội dung	Người phụ trách
Chương 1. Mở đầu		
1.1	Bối cảnh, động lực; phát biểu bài toán tóm tắt văn bản tiếng Việt; mục tiêu và phạm vi	Diệu
1.2	Đóng góp dự kiến và cấu trúc báo cáo	Thiên
Chương 2. Cơ sở lý thuyết		
2.1	Tổng quan tóm tắt văn bản; phân loại Extractive/Abstractive/Hybrid; tiêu chí chất lượng (coverage, coherence, redundancy, factuality)	Diệu
2.2	Nhóm phương pháp Extractive: quy trình chung; TextRank (xây đồ thị câu, PageRank, chọn top- k); (tùy chọn) Bayesian sentence classification	Diệu
2.3	Nhóm phương pháp Abstractive: Transformer encoder-decoder; BART; BARTpho (word/syllable); T5; ViT5	Thiên
2.4	So sánh Extractive vs Abstractive và định hướng Hybrid (lý do kết hợp TextRank + mô hình sinh)	ThiênThiên
2.5	Độ đo đánh giá: ROUGE, BERTScore, CR/RR và đánh giá thủ công	Thiên
Chương 3. Phương pháp đề xuất		
3.1	Ý tưởng tổng thể hệ thống Hybrid: TextRank rút gọn → tạo pseudo-document → mô hình sinh (ViT5/BARTpho)	Thiên
3.2	Mô tả pipeline (tiền xử lý, TextRank, nối câu theo thứ tự gốc, giới hạn token 512/1024, sinh tóm tắt, hậu xử lý)	Diệu

STT	Nội dung	Người phụ trách
3.3	Thiết kế tham số/ablation: top- k (3/5/7/9), token limit (512 vs 1024), similarity (Word2Vec avg), decoding (beam/no-repeat/length penalty)	Thiên
3.4	Tiêu chí chọn cấu hình cuối: cân bằng ROUGE/BERTScore, độ dài (CR), và kiểm tra định tính	Diệu
Chương 4. Thực nghiệm và kết quả		
4.1	Dữ liệu: mô tả dataset, thống kê độ dài (tokens), phân bố; mô tả thiết lập chọn mẫu đánh giá	Diệu
4.2	Thiết lập thí nghiệm trên Kaggle: mô hình (checkpoint, tham số sinh), TextRank (Word2Vec avg, top- k , giới hạn 512/1024)	Thiên
4.3	Chỉ số đánh giá: ROUGE/BERTScore/CR(RR) và rubric đánh giá thủ công (1–5)	Diệu
4.4	Kết quả tổng quan + bảng so sánh: TextRank-only vs Hybrid; ViT5 vs BARTpho; top- k ; limit 512 vs 1024	ThiênThiên
4.5	Phân tích ablation và thảo luận theo từng yếu tố (top- k , token limit, ViT5 vs BARTpho)	Diệu
4.6	Minh hoạ định tính (case study) + phân tích lỗi (bỏ sót, lặp, chung chung, sai lệch/hallucination; giải thích vì sao 512 có thể tốt hơn 1024)	Thiên
Chương 5. Thảo luận và hướng phát triển		
5.1	Nhận xét tổng quan: khi nào hybrid hiệu quả/kém hiệu quả	Thiên
5.2	Hạn chế: phụ thuộc tách câu/biểu diễn câu, hallucination, hạn chế của ROUGE, tài nguyên suy luận	Diệu

STT	Nội dung	Người phụ trách
5.3	Hướng phát triển: fine-tune theo domain, sentence embedding mạnh hơn, giảm lặp/kiểm chứng factuality, demo	Diệu