

ĐẠI HỌC HUẾ
TRƯỜNG ĐẠI HỌC KHOA HỌC
KHOA CÔNG NGHỆ THÔNG TIN

BÁO CÁO NIÊN LUẬN

Tên đề tài:

*[Phát hiện và phân loại rác thải tái chế bằng YOLOv8 kết hợp
Active Learning]*

Sinh viên thực hiện: [Hoàng Kim Thiên]

Mã số sinh viên: [22T1020444]

Lớp: [Thị giác máy tính]

Giáo viên hướng dẫn: [TS. Lê Quang Chiến]

Huế, tháng [1] năm [2026]

Lời cảm ơn

Lời đầu tiên, em xin trân trọng cảm ơn Thầy/Cô [**Tên giáo viên hướng dẫn**] đã tận tình hướng dẫn em trong suốt quá trình thực hiện niên luận.

Em xin gửi lời cảm ơn đến quý Thầy Cô trong Khoa Công nghệ Thông tin, gia đình, và bạn bè đã luôn động viên và hỗ trợ em trong suốt quá trình học tập và nghiên cứu.

Mục lục

Lời cảm ơn	1
Tóm tắt	4
1 Giới thiệu	6
1.1 Lý do chọn đề tài	6
1.2 Mục tiêu nghiên cứu	7
1.3 Phạm vi nghiên cứu	7
1.4 Cấu trúc báo cáo	8
2 Cơ sở lý thuyết	10
2.1 Tổng quan bài toán phát hiện và phân loại rác tái chế	10
2.1.1 Định nghĩa bài toán	10
2.1.2 Các thách thức đặc thù của dữ liệu rác thải	11
2.1.3 Học sâu cho phát hiện đối tượng	12
2.1.4 Faster R-CNN	21
2.1.5 Các họ YOLO cho bài toán phát hiện rác tái chế và giới thiệu YOLOv8	23
2.1.6 Họ mô hình YOLO (You Only Look Once)	23
2.2 Học chủ động (Active Learning)	25
2.2.1 Khái niệm và bài toán Active Learning	26
2.2.2 Quy trình (pipeline) Active Learning cho Object Detection	26
2.2.3 Các chiến lược chọn mẫu (Query Strategies)	26
2.2.4 Hàm ý cho bài toán phát hiện rác tái chế	28
3 Phương pháp đề xuất	29
3.1 Kiến trúc hệ thống tổng thể	29
3.2 Thiết kế lớp đối tượng và bộ dữ liệu	30
3.2.1 Danh sách lớp rác tái chế	30
3.2.2 Quy ước bounding box và hướng dẫn gán nhãn	31
3.2.3 Quản lý dữ liệu cho Active Learning	31
3.3 Mô hình nền (Baseline) YOLOv8	32
3.3.1 Lựa chọn biến thể YOLOv8	32
3.3.2 Cấu hình huấn luyện	32

3.3.3	Thiết lập suy luận và NMS	32
3.4	Chiến lược Active Learning đề xuất	32
3.4.1	Uncertainty sampling	32
3.4.2	Diversity sampling	33
3.4.3	Hybrid: kết hợp uncertainty và diversity	33
3.5	Quy trình gán nhãn và kiểm soát chất lượng	33
3.5.1	Công cụ gán nhãn và quy trình human-in-the-loop	33
3.5.2	Kiểm soát chất lượng nhãn (QA)	33
3.6	Tiêu chí dừng và tiêu chí đánh giá	33
3.6.1	Tiêu chí dừng	33
3.6.2	Tiêu chí đánh giá	34
4	Thực nghiệm	35
4.1	Thiết lập môi trường và dữ liệu	35
4.1.1	Môi trường thực nghiệm	35
4.1.2	Dữ liệu và định dạng nhãn	35
4.1.3	Kết quả theo lớp trên tập validation (Round 0)	36
4.2	Kịch bản và cấu hình huấn luyện	36
4.2.1	Round 0 (Baseline)	36
4.2.2	Các vòng Active Learning (Round 1–3)	36
4.3	Chiến lược chọn mẫu	37
4.3.1	Uncertainty Sampling	37
4.3.2	Random Sampling (đối chứng)	37
4.4	Quản lý thí nghiệm và lưu trạng thái	37
4.5	Đánh giá và ghi log	37
4.5.1	Chỉ số đánh giá	37
4.5.2	Biểu đồ huấn luyện	38
5	Kết quả, thảo luận và kết luận	39
5.1	Kết quả định lượng	39
5.1.1	Thiết lập thực nghiệm	39
5.1.2	Baseline Round 0	39
5.1.3	Active Learning (Uncertainty Sampling): Round 1–3	39
5.1.4	Random Sampling: Round 1–3 (đối chứng)	40
5.1.5	So sánh Active Learning và Random Sampling	40
5.1.6	So sánh trực quan bằng đồ thị	41
5.2	Phân tích lỗi: Hiện tượng Cold-Start trong Active Learning	42
5.3	Kết luận chương	43
	Tài liệu tham khảo	44

Tóm tắt

Báo cáo này trình bày đề tài *Phát hiện và phân loại rác thải tái chế bằng YOLOv8 kết hợp Active Learning* với mục tiêu xây dựng mô hình phát hiện rác theo thời gian thực và đề xuất quy trình học chủ động nhằm giảm chi phí gán nhãn khi mở rộng dữ liệu. Phương pháp nghiên cứu gồm: (i) sử dụng mô hình YOLOv8 để phát hiện và phân loại rác theo các nhóm vật liệu trong bộ dữ liệu *Garbage Detection – 6 classes* (biodegradable, cardboard, glass, metal, paper, plastic); (ii) thiết kế vòng lặp Active Learning dạng pool-based để lựa chọn các mẫu “hữu ích/khó” từ tập chưa gán nhãn (dựa trên độ không chắc chắn và/hoặc tính đa dạng), sau đó gán nhãn bổ sung và huấn luyện lại mô hình theo từng vòng; (iii) đánh giá theo các chỉ số Precision, Recall, mAP và tốc độ suy luận (FPS/latency), đồng thời phân tích hiệu quả theo ngân sách nhãn (mAP theo số lượng/% dữ liệu đã gán nhãn). Kết quả thực nghiệm cho thấy việc kết hợp Active Learning có thể giúp cải thiện hiệu năng và tăng khả năng thích nghi của mô hình khi gặp dữ liệu mới, đồng thời đạt độ chính xác mong muốn với lượng dữ liệu gán nhãn ít hơn so với cách huấn luyện truyền thống. Đề tài có tiềm năng ứng dụng trong các hệ thống phân loại rác thông minh như thùng rác tự động, dây chuyền băng tải phân loại và hỗ trợ robot gắp rác.

Từ khóa: YOLOv8, phát hiện đối tượng, phân loại rác tái chế, học chủ động, thị giác máy tính, tiết kiệm gán nhãn

Abstract

This report presents the topic *Recyclable waste detection and classification using YOLOv8 with Active Learning*, aiming to develop a real-time waste detection model and an active learning pipeline to reduce labeling cost when new data are introduced. The proposed methodology includes: (i) training a YOLOv8-based detector on the *Garbage Detection – 6 classes* dataset (biodegradable, cardboard, glass, metal, paper, plastic); (ii) designing a pool-based Active Learning loop to select the most informative samples from an unlabeled pool (via uncertainty and/or diversity criteria), then annotating and incrementally

fine-tuning the model across iterations; (iii) evaluating performance using Precision, Recall, mAP, and inference speed (FPS/latency), while analyzing label-efficiency through mAP versus labeling budget. Experimental results indicate that integrating Active Learning can improve robustness to newly collected data and reach competitive accuracy with fewer labeled samples compared to conventional static training. The study has potential applications in smart waste sorting systems, such as intelligent bins, conveyor-based sorting lines, and vision-guided robotic pick-and-place solutions.

Keywords: YOLOv8, object detection, recyclable waste classification, active learning, computer vision, label efficiency

Chương 1

Giới thiệu

1.1 Lý do chọn đề tài

Rác thải tái chế (nhựa, giấy, kim loại, thủy tinh, ...) ngày càng gia tăng cùng với đô thị hóa và tiêu dùng, trong khi hoạt động phân loại vẫn còn phụ thuộc nhiều vào thủ công, gây tốn kém nhân lực, không ổn định chất lượng và làm giảm hiệu quả tái chế. Trong bối cảnh đó, các hệ thống thị giác máy tính kết hợp học sâu được xem là hướng tiếp cận tiềm năng để tự động nhận diện và phân loại rác theo thời gian thực.

Trong 3 năm gần đây, nhiều nghiên cứu đã ứng dụng và cải tiến YOLOv8 cho bài toán phát hiện/phân loại rác. Chẳng hạn, Li và cộng sự (2024) đề xuất phiên bản YOLOv8 nhẹ hóa và tối ưu để phát hiện rác trong bối cảnh nền phức tạp, hướng tới cân bằng giữa độ chính xác và tốc độ suy luận [1]. Ở bối cảnh giám sát môi trường nước, Di và cộng sự (2025) đề xuất mô hình YOLOv8 tăng cường cho phát hiện rác nổi (floating waste), phục vụ các ứng dụng quan trắc và hỗ trợ thu gom [2]. Bên cạnh đó, hướng tích hợp thị giác máy tính với robot gắp/phân loại cũng được quan tâm; Paudel và cộng sự (2024) triển khai YOLOv8 kết hợp robot delta arm cho bài toán phân loại–gắp rác theo nhóm vật liệu, cho thấy tính khả thi của hệ thống thị giác–robot trong môi trường phân loại [3].

Tuy nhiên, các nghiên cứu trên đa phần được xây dựng theo quy trình *huấn luyện một lần và triển khai*, tức là mô hình được tối ưu trên một bộ dữ liệu gán nhãn cố định và giả định phân bố dữ liệu trong vận hành không thay đổi. Trong thực tế, hệ thống phân loại rác thường chịu ảnh hưởng mạnh bởi *domain shift* như thay đổi ánh sáng, nền chụp, góc camera, mức độ bẩn/biến dạng của vật thể, hiện tượng chồng lấp trên băng tải, hoặc sự xuất hiện của các kiểu rác mới chưa có trong dữ liệu huấn luyện. Những thay đổi này có thể làm giảm độ tin cậy của dự đoán và suy giảm các chỉ số như Precision, Recall và mAP theo thời gian. Nếu khắc phục bằng cách thu thập và gán nhãn lại một lượng lớn dữ liệu mới, chi phí nhân lực sẽ rất cao do bài toán detection yêu cầu vẽ bounding box chính xác và kiểm tra chất lượng nhãn.

Vì vậy, đề tài “*Phát hiện và phân loại rác thải tái chế bằng YOLOv8 kết hợp Active*

Learning” được lựa chọn nhằm giải quyết đồng thời hai yêu cầu quan trọng. Thứ nhất, sử dụng YOLOv8 để đảm bảo khả năng **suy luận thời gian thực**, đáp ứng ràng buộc tốc độ trong các kịch bản camera giám sát/băng tải/robot gắp. Thứ hai, tích hợp **Active Learning theo vòng lặp** để giảm chi phí cập nhật mô hình: thay vì gán nhãn tràn lan, hệ thống sẽ ưu tiên lựa chọn các mẫu dữ liệu “hữu ích” (ví dụ: mẫu có độ không chắc chắn cao, mẫu đại diện cho tình huống mới) từ tập chưa gán nhãn để đưa vào quy trình gán nhãn và huấn luyện bổ sung. Nhờ đó, mô hình có thể cải thiện hiệu năng và thích nghi dần với dữ liệu phát sinh trong quá trình vận hành, đồng thời đạt độ chính xác mong muốn với **ngân sách gán nhãn hạn chế**.

1.2 Mục tiêu nghiên cứu

Đề tài hướng tới các mục tiêu chính sau:

- **Xây dựng** mô hình baseline phát hiện và phân loại rác tái chế theo thời gian thực dựa trên YOLOv8.
- **Thiết kế** quy trình Active Learning để lựa chọn mẫu dữ liệu cần ưu tiên gán nhãn từ tập chưa gán nhãn, phục vụ cập nhật mô hình theo từng vòng lặp.
- **Đánh giá** hiệu quả theo: độ chính xác (Precision, Recall, mAP), tốc độ suy luận (FPS/latency), và hiệu quả theo ngân sách gán nhãn (đường cong mAP theo số mẫu/% dữ liệu đã gán nhãn).

1.3 Phạm vi nghiên cứu

Đối tượng nghiên cứu là dữ liệu ảnh chứa các vật thể rác tái chế trong điều kiện mô phỏng hoặc gần thực tế, được gán nhãn theo dạng *bounding box* và nhãn lớp phục vụ bài toán phát hiện đối tượng (object detection).

Dữ liệu sử dụng trong đề tài là bộ *Garbage Detection – 6 classes (YOLO labels sẵn)* [4], bao gồm 6 lớp: *biodegradable, cardboard, glass, metal, paper, plastic*. Bộ dữ liệu được cung cấp sẵn nhãn theo định dạng YOLO (tệp `.txt` tương ứng từng ảnh), thuận lợi cho việc huấn luyện và đánh giá mô hình YOLOv8 cũng như xây dựng quy trình Active Learning theo vòng lặp.

Phạm vi đề tài tập trung vào:

- Huấn luyện mô hình YOLOv8 để **phát hiện và phân loại** rác theo 6 lớp nêu trên trong bộ dữ liệu.
- Thiết kế và đánh giá quy trình **Active Learning (pool-based)**: lựa chọn mẫu từ tập chưa gán nhãn để ưu tiên gán nhãn bổ sung và huấn luyện lại theo từng vòng.

- Đánh giá hiệu quả theo các chỉ số: Precision, Recall, mAP và tốc độ suy luận (FPS/latency), đồng thời phân tích hiệu quả theo ngân sách nhân (mAP theo số lượng/% ảnh đã gán nhãn).

Giới hạn của đề tài:

- Đề tài không đi sâu vào tối ưu cơ khí, động học và điều khiển robot gấp; phần robot (nếu có) chỉ xem như hướng ứng dụng.
- Đề tài không tập trung vào các kỹ thuật học không giám sát hoàn toàn hoặc học tăng cường; trọng tâm là YOLOv8 và Active Learning để giảm chi phí gán nhãn.

Một số ảnh minh họa của bộ dữ liệu: Hình 1.1 và Hình 1.2 minh họa một số ảnh trong bộ dữ liệu sử dụng (trích từ tập huấn luyện và tập kiểm định).



Hình 1.1: Một số ảnh minh họa từ tập huấn luyện (train) của bộ dữ liệu.



Hình 1.2: Một số ảnh minh họa từ tập kiểm định (validation) của bộ dữ liệu.

1.4 Cấu trúc báo cáo

Báo cáo được tổ chức như sau:

- **Chương 1: Giới thiệu** – trình bày lý do chọn đề tài, mục tiêu, phạm vi và cấu trúc báo cáo.
- **Chương 2: Cơ sở lý thuyết** – tổng quan YOLOv8, bài toán phát hiện rác, Active Learning và các nghiên cứu liên quan.

- **Chương 3: Phương pháp đề xuất** – trình bày pipeline YOLOv8 kết hợp Active Learning, chiến lược chọn mẫu và quy trình cập nhật mô hình.
- **Chương 4: Thực nghiệm** – dữ liệu, thiết lập huấn luyện, kịch bản Active Learning và tiêu chí đánh giá.
- **Chương 5: Kết quả và thảo luận** – phân tích kết quả, so sánh theo ngân sách gán nhãn, phân tích lỗi và hướng phát triển.

Chương 2

Cơ sở lý thuyết

2.1 Tổng quan bài toán phát hiện và phân loại rác tái chế

Phân loại rác thải là bước tiền đề quan trọng trong quy trình tái chế nhằm giảm thiểu tác động đến môi trường. Việc ứng dụng thị giác máy tính vào bài toán này nhằm mục đích tự động hóa quá trình nhận diện, thay thế phương pháp thủ công tốn kém và hỗ trợ giám sát tại nhiều môi trường khác nhau (như trạm trung chuyển, thùng rác thông minh hoặc băng tải mô phỏng).

2.1.1 Định nghĩa bài toán

Bài toán được định nghĩa là một bài toán phát hiện đối tượng đa lớp (Multi-class Object Detection) dựa trên dữ liệu thị giác. Hệ thống được thiết kế để xử lý linh hoạt hai dạng đầu vào:

- **Ảnh tĩnh (Static Images):** Dữ liệu hình ảnh được thu thập từ các bộ dữ liệu hoặc chụp thủ công, phục vụ quá trình huấn luyện và đánh giá định lượng.
- **Luồng video (Video Stream):** Tín hiệu hình ảnh liên tục từ camera giám sát hoặc webcam, yêu cầu hệ thống phải xử lý theo thời gian thực.

Với mỗi khung hình đầu vào I , nhiệm vụ của mô hình là xác định đồng thời vị trí và loại vật liệu của tất cả các đối tượng rác xuất hiện. Đầu ra của mô hình là tập hợp các dự đoán $O = \{(b_i, c_i, p_i)\}_{i=1}^N$, trong đó:

- $b_i = (x, y, w, h)$: Tọa độ hộp bao (bounding box) định vị vật thể trong ảnh.
- c_i : Nhãn phân loại vật liệu (ví dụ: Nhựa, Giấy, Kim loại, Thủy tinh).
- p_i : Độ tin cậy (confidence score) của dự đoán, dùng để lọc bỏ các kết quả nhiễu.

Mục tiêu tối ưu hóa của bài toán là đạt được sự cân bằng giữa độ chính xác (để phân loại đúng vật liệu) và tốc độ suy luận (FPS - Frames Per Second) để đảm bảo tính ứng dụng thực tế khi triển khai trên camera [5].

2.1.2 Các thách thức đặc thù của dữ liệu rác thải

Việc nhận diện rác thải tái chế được đánh giá là phức tạp hơn nhiều so với nhận diện các đối tượng thông thường (như người, xe cộ) do các đặc tính vật lý và môi trường sau đây:

Biến dạng vật thể (Deformation)

Đây là đặc trưng phổ biến nhất của rác thải. Các vật thể như chai nhựa, lon nhôm hay hộp giấy thường xuyên bị nén, bẹp, xé rách hoặc méo mó trong quá trình thu gom và vận chuyển. Sự biến dạng này làm thay đổi hoàn toàn cấu trúc hình học ban đầu, khiến các đặc trưng thị giác (visual features) trở nên không nhất quán, gây khó khăn cho việc nhận dạng mẫu.

Sự chồng lấp và che khuất (Occlusion)

Trên băng tải xử lý, rác thải thường xuất hiện thành từng cụm lộn xộn (clutter). Các vật thể nằm chồng chất lên nhau khiến camera chỉ thu nhận được một phần thông tin của đối tượng. Mô hình cần có khả năng suy luận ngữ cảnh mạnh mẽ để định vị chính xác phần bị che khuất và tách biệt các đối tượng nằm sát nhau.

Đặc tính bề mặt và ánh sáng

- **Vật thể trong suốt:** Các loại chai nhựa PET hoặc thủy tinh trong suốt thường khó tách biệt khỏi nền băng tải hoặc làm lộ màu sắc của các vật thể nằm phía sau/bên dưới nó.
- **Phản xạ ánh sáng:** Các bề mặt kim loại hoặc nhựa bóng thường gây ra hiện tượng lóa (specular reflection) dưới ánh đèn công nghiệp, tạo ra nhiễu ảnh hưởng đến quá trình trích xuất đặc trưng.

Nhiễm bẩn (Contamination)

Rác thải tái chế thực tế hiếm khi ở trạng thái sạch sẽ mà thường bị bám bẩn, dính dầu mỡ hoặc lẫn các tạp chất khác. Lớp bẩn này làm thay đổi màu sắc và kết cấu bề mặt, dẫn đến sự sai lệch lớn giữa dữ liệu thực tế và dữ liệu lý tưởng, yêu cầu mô hình phải có khả năng khái quát hóa cao.



Hình 2.1: Minh họa các thách thức trong ảnh rác thải: (a) Biến dạng, (b) Chồng lấp, (c) Vật thể trong suốt (d) Nhiều bản.

2.1.3 Học sâu cho phát hiện đối tượng


Dựa trên định nghĩa bài toán ở Mục 2.1.1, phần này tập trung làm rõ vì sao các phương pháp học sâu là hướng tiếp cận phù hợp cho bài toán phát hiện và phân loại rác tái chế từ ảnh/camera. Theo tổng quan của Liu et al., ưu thế cốt lõi của các mô hình học sâu trong phát hiện đối tượng đến từ khả năng **học biểu diễn đặc trưng mạnh** và **tối ưu hóa end-to-end** trên cùng một kiến trúc, giúp mô hình đồng thời cải thiện chất lượng phân loại và định vị trong các bối cảnh phức tạp [6]. Trong ngữ cảnh rác tái chế, các đặc điểm như biến dạng, che khuất/chồng lấp, bám bẩn, điều kiện chiếu sáng thay đổi, hay bề mặt phản xạ và trong suốt làm cho tín hiệu thị giác thiếu ổn định và khó mô tả hiệu quả bằng các đặc trưng thủ công; do đó việc học trực tiếp từ dữ liệu giúp mô hình thích nghi tốt hơn với các biến thiên này [7].

Quy trình phát hiện rác theo hướng học sâu. Một hệ phát hiện đối tượng hiện đại thường gồm ba bước chính:

- Thứ nhất, *backbone* (thường là CNN sâu) trích xuất các bản đồ đặc trưng (feature maps) chứa đồng thời thông tin không gian và ngữ nghĩa.
- Thứ hai, *detection head* dựa trên các đặc trưng này để sinh ra các dự đoán hộp bao và xác suất lớp cho từng vị trí/anchor trên không gian đặc trưng.
- Cuối cùng, hệ thống áp dụng *hậu xử lý* (thường là Non-Maximum Suppression – NMS) nhằm loại bỏ các dự đoán trùng lặp và giữ lại tập kết quả có ý nghĩa.

Trong bài toán rác tái chế, quy trình này cho phép mô hình vừa định vị được nhiều vật thể trong cùng một khung hình, vừa phân loại vật liệu tương ứng, đồng thời có thể triển khai cho ảnh tĩnh hoặc xử lý liên tục theo khung hình video [6, 7].

Phân loại các hướng phát hiện đối tượng dựa trên học sâu. Theo hệ thống hóa trong tổng quan của Liu et al., các phương pháp phát hiện đối tượng học sâu thường được chia thành hai hướng chính [6]:



Hình 2.2: Phân loại tổng quan các hướng phát hiện đối tượng dựa trên học sâu (two-stage và one-stage) (trích Fig. 11 trong [6]).

- (i) *two-stage* — mô hình sinh các vùng ứng viên (region proposals), sau đó phân loại và tinh chỉnh hộp bao cho từng vùng;
- (ii) *one-stage* — mô hình dự đoán trực tiếp hộp bao và nhãn lớp trên toàn ảnh/feature maps mà không cần bước proposal riêng.

Đối với dữ liệu rác tái chế, two-stage thường có lợi thế khi cảnh phức tạp (nhiều che khuất, nền nhiễu) do cơ chế tinh lọc theo vùng, trong khi one-stage phù hợp khi cần tốc độ suy luận cao trên luồng camera. Hình 2.2 minh họa phân loại tổng quan các hướng tiếp cận, làm cơ sở để lựa chọn nhóm mô hình phù hợp trong phần thực nghiệm.


Hàm ý cho thiết kế mô hình trong bài toán rác tái chế. Từ các tổng quan, có thể rút ra ba điểm “thực dụng” khi chọn/thiết kế detector cho rác tái chế:

- (i) **backbone mạnh** và phù hợp tài nguyên triển khai là nền tảng quyết định chất lượng đặc trưng;
- (ii) cơ chế **đa tỉ lệ** giúp ổn định hơn khi kích thước rác thay đổi theo khoảng cách/góc chụp và khi vật thể nhỏ;
- (iii) **dữ liệu và cách chuẩn bị dữ liệu** (đa dạng bối cảnh, augmentation, fine-tuning từ mô hình tiền huấn luyện) thường quyết định khả năng tổng quát hóa khi đưa vào môi trường thật

Vì vậy, phần tiếp theo sẽ làm rõ nền tảng CNN/backbone và vai trò của đặc trưng đa tỉ lệ trong phát hiện đối tượng.

Backbone: Trích xuất đặc trưng (multi-scale theo FPN)

Trong các detector học sâu, *backbone* CNN biến đổi ảnh đầu vào I thành một **hệ phân cấp đặc trưng** (feature hierarchy) gồm nhiều mức $\{C_l\}$ khác nhau. FPN chỉ ra rằng cấu



Hình 2.3: So sánh các cách xây dựng pyramid và động cơ của FPN (Figure 1 trong [8]).


trúc phân cấp này có thể được khai thác như một *feature pyramid* hiệu quả, thay vì phải tạo pyramid theo ảnh đầu vào vốn tốn chi phí; đồng thời, việc chỉ dùng một feature map duy nhất thường làm suy giảm khả năng phát hiện đa tỉ lệ (Hình 2.3) [8].

Biểu diễn theo tầng và “khoảng cách ngữ nghĩa”: Do quá trình downsampling, các tầng sâu có ngữ nghĩa mạnh nhưng độ phân giải thấp, còn các tầng nông giữ chi tiết định vị tốt nhưng ngữ nghĩa yếu. FPN nhấn mạnh rằng nếu chỉ tái sử dụng feature hierarchy bottom-up thì sẽ xuất hiện *khoảng cách ngữ nghĩa* giữa các mức, khiến các mức phân giải cao (tầng nông) kém hiệu quả cho phân loại; trực giác này được minh họa trong Hình 2.3(c) và cách khắc phục trong Hình 2.3(d) [8].

Top-down + lateral: tạo đặc trưng có ngữ nghĩa mạnh ở mọi tỉ lệ: Đóng góp chính của FPN là cơ chế kết hợp **top-down pathway** và **lateral connections**: đặc trưng từ tầng sâu được upsample và hợp nhất với đặc trưng tầng nông tương ứng để vừa giữ chi tiết không gian vừa tăng ngữ nghĩa, như khối xây dựng minh họa ở Hình 2.4 [8]. Một mô tả gọn có thể viết:

$$P_5 = \text{Conv}_{1 \times 1}(C_5), \quad P_l = \text{Conv}_{1 \times 1}(C_l) + \text{Up}(P_{l+1}), \quad l \in \{4, 3, 2\},$$

và sau đó áp dụng $\text{Conv}_{3 \times 3}$ lên mỗi P_l để làm mượt đặc trưng.



Hình 2.4: Khối xây dựng FPN: upsample + lateral connection + làm mượt bằng 3×3 conv (Figure 3 trong [8]).

Dự đoán ở nhiều mức và lợi ích cho vật thể nhỏ: FPN không chỉ tạo đặc trưng đa mức mà còn cho phép dự đoán độc lập ở từng mức tỉ lệ, thay vì chỉ dự đoán ở mức mịn nhất; sự khác biệt này được minh họa trực quan ở Hình 2.5 [8]. Trong bài toán rác tái chế, cơ chế dự đoán đa mức giúp tăng khả năng phát hiện mảnh rác nhỏ hoặc vật thể ở xa trong khung hình.


Từ góc nhìn triển khai, FPN đem lại hai lợi ích sát với dữ liệu rác:

- (i) **bền vững theo tỉ lệ** nhờ dự đoán/đặc trưng đa mức (hữu ích cho rác nhỏ hoặc ở xa),
- (ii) **định vị tốt hơn trong cảnh lộn xộn** nhờ lateral connections truyền thông tin vị trí từ tầng nông lên tầng giàu ngữ nghĩa.

Detection Head: Dự đoán hộp bao và nhãn lớp

Từ các feature maps đa mức $\{F_l\}$ (thường đến từ backbone/FPN), *detection head* tạo ra các dự đoán thô tại từng vị trí trên không gian đặc trưng. Về chức năng, head thường gồm

- (i) nhánh *phân loại* để ước lượng xác suất lớp c_i ,
- (ii) nhánh *hồi quy* để dự đoán tham số hộp bao b_i ,
- trong một số thiết kế còn có (iii) nhánh *độ tin cậy/objectness* để biểu thị khả năng tồn tại đối tượng tại vị trí đó [6]




Hình 2.5: So sánh dự đoán chỉ ở mức mịn nhất và dự đoán ở nhiều mức trong FPN (Figure 2 trong [8]).

Trong bối cảnh rác tái chế, chất lượng head ảnh hưởng trực tiếp đến khả năng tách các vật thể nằm sát nhau và giảm nhầm lẫn vật liệu có ngoại hình tương đồng [7].

Head theo cơ chế anchor-based: ví dụ RetinaNet. Trong các detector one-stage dạng *dense*, một cách thiết kế phổ biến là đặt một tập anchor (kích thước/tỉ lệ khác nhau) tại mỗi vị trí trên feature map, sau đó dự đoán cho từng anchor. RetinaNet là ví dụ điển hình: mô hình gắn **hai subnet song song** lên mỗi mức FPN, gồm *classification subnet* và *box regression subnet* (Hình 2.6) [9]. Cụ thể, tại mỗi vị trí không gian với A anchor và K lớp, nhánh phân loại xuất ra $K \times A$ điểm (dạng sigmoid) và nhánh hồi quy xuất ra $4 \times A$ tham số hộp (dịch chuyển/tỉ lệ so với anchor) [9]. Thiết kế “tách nhánh” này giúp tối ưu đồng thời hai mục tiêu: phân loại vật liệu và định vị hình học.

Mất cân bằng mẫu và focal loss (liên quan trực tiếp đến head dense). Một vấn đề cốt lõi của head kiểu dense là số lượng anchor âm (background) áp đảo anchor dương, gây mất cân bằng mạnh khi huấn luyện. RetinaNet đề xuất *focal loss* để giảm đóng góp của các mẫu “dễ” và tập trung vào các mẫu “khó”, qua đó cải thiện chất lượng phân loại trong bối cảnh dense prediction [9]. Ý nghĩa thực tế với dữ liệu rác tái chế là: khi nền



Hình 2.6: Cấu trúc detection head anchor-based của RetinaNet: classification subnet (c) và box regression subnet (d) (trích Figure 3 trong [9]).

ảnh phức tạp và có nhiều vùng background, cơ chế loss phù hợp giúp head học phân biệt tín hiệu vật liệu tốt hơn thay vì bị chi phối bởi số lượng lớn mẫu âm.

Head theo cơ chế anchor-free: ví dụ FCOS. Thay vì dự đoán theo anchor, FCOS reformulate detection thành bài toán *per-pixel prediction*: tại mỗi vị trí (pixel) thuộc foreground trên feature map, mô hình hồi quy trực tiếp một vector 4 chiều (l, t, r, b) , tương ứng khoảng cách từ vị trí đó tới bốn biên của hộp bao [10]. Cách làm này loại bỏ các siêu tham số anchor (kích thước/tỉ lệ/số lượng), vốn thường nhạy với hiệu năng và phải tinh chỉnh theo dữ liệu [10].

Nhánh center-ness để giảm hộp chất lượng thấp. Do dự đoán theo pixel có thể tạo nhiều hộp “lệch tâm” (từ vị trí xa tâm vật thể) dẫn đến hộp chất lượng thấp, FCOS bổ sung một nhánh *center-ness* song song với nhánh phân loại để ước lượng mức “gần tâm” của vị trí dự đoán. Khi suy luận, điểm phân loại thường được nhân với center-ness để down-weight các hộp kém chất lượng [10].

Từ hai hướng thiết kế head trên, có thể xem đây là một đánh đổi thực dụng: anchor-based (như RetinaNet) có cấu trúc head rõ ràng và mạnh trong dense prediction nhưng có thể nhạy với cấu hình anchor, trong khi anchor-free (như FCOS) đơn giản hơn về siêu

tham số và phù hợp khi dữ liệu có biến thiên hình dạng/tỉ lệ lớn [9, 10]. Trong phần thực nghiệm, lựa chọn head/kiến trúc cụ thể sẽ được đánh giá theo các tiêu chí mAP, khả năng phát hiện vật thể nhỏ và tốc độ suy luận.

Hậu xử lý: Lọc kết quả và loại bỏ trùng lặp

Sau bước dự đoán của detection head, mô hình thường tạo ra **nhiều hộp ứng viên** cho cùng một vật thể (do dự đoán dày theo vị trí/anchor hoặc theo pixel). Vì vậy, cần một tầng hậu xử lý để:

- (i) lọc các dự đoán kém tin cậy
- (ii) hợp nhất các dự đoán trùng lặp, nhằm thu được tập kết quả cuối cùng $O = \{(b_i, c_i, p_i)\}$ ổn định cho triển khai [6].

Lọc theo ngưỡng độ tin cậy : Bước đầu tiên thường là loại bỏ các hộp có điểm tin cậy thấp $p_i < \tau_c$ (confidence threshold). Trong bài toán rác tái chế, nếu τ_c đặt quá cao, các vật thể nhỏ/mờ hoặc bị che khuất dễ bị loại sớm; ngược lại nếu đặt quá thấp, số lượng hộp đưa vào NMS tăng mạnh và làm tăng trùng lặp/FP trong cảnh *clutter* [7]. Vì vậy, τ_c thường cần được hiệu chỉnh theo dữ liệu và mục tiêu (ưu tiên recall hay precision).

Greedy-NMS và đánh đổi precision–recall : Sau khi lọc sơ bộ, phương pháp phổ biến nhất là **Non-Maximum Suppression** (NMS). Với hai hộp b_i, b_j , độ chồng lấp được đo bằng IoU:

$$\text{IoU}(b_i, b_j) = \frac{\text{area}(b_i \cap b_j)}{\text{area}(b_i \cup b_j)}.$$

Greedy-NMS sắp xếp các hộp theo điểm p_i giảm dần, chọn hộp có điểm cao nhất làm đại diện, sau đó *loại bỏ* (suppress) các hộp còn lại có $\text{IoU} > \tau_{nms}$ với hộp đã chọn, và lặp lại cho đến khi hết hộp. Điểm hạn chế cốt lõi là **một ngưỡng cố định** τ_{nms} buộc hệ thống phải đánh đổi:

- τ_{nms} *thấp* dễ loại nhầm hộp của các vật thể thật nằm sát nhau (giảm recall)
- τ_{nms} *cao* giữ nhiều hộp trùng (tăng FP, giảm precision).

nơi ngưỡng thấp gây mất đối tượng thật, còn ngưỡng cao làm tăng dự đoán sai [12]. Trong ảnh rác tái chế, tình huống tương tự xảy ra khi nhiều vật thể nằm gần nhau hoặc chồng lấp (*clutter*).

Soft-NMS: giảm điểm thay vì xoá hộp. Để giảm việc *bỏ sót* vật thể khi các hộp chồng lấp lớn, Soft-NMS đề xuất không đặt điểm của hộp lân cận về 0 như Greedy-NMS, mà **giảm điểm** của chúng theo một hàm liên tục của độ chồng lấp với hộp đang chọn

[11]. Trong bối cảnh rác tái chế, Soft-NMS thường hữu ích khi các vật thể nằm sát nhau, vì nó giảm xác suất loại nhầm các hộp thuộc những vật thể khác nhau.

Từ các phân tích trên, hậu xử lý không chỉ là bước “dọn kết quả” mà ảnh hưởng trực tiếp đến hiệu năng cuối cùng. Với dữ liệu rác có *clutter/che khuất*, cần hiệu chỉnh đồng thời (τ_c, τ_{nms}) theo mục tiêu ứng dụng. Ngoài Greedy-NMS, các biến thể như Soft-NMS có thể được cân nhắc để giảm bỏ sót khi vật thể nằm sát nhau, trong khi các hướng thích nghi theo mật độ (như Adaptive-NMS) gợi ý rằng một ngưỡng động có thể phù hợp hơn trong các cảnh “đông” [11, 12, 7].

Hàm mất mát (Loss) và tối ưu

Sau khi mô hình tạo ra các dự đoán thô ở detection head và được lọc bởi hậu xử lý (Mục 2.1.3), bài toán huấn luyện được quy về việc tối thiểu hoá một **hàm mất mát hợp phần** (compound loss) để đồng thời cải thiện

- (i) chất lượng định vị hộp bao
- (ii) độ đúng nhãn lớp

Trong các detector kiểu YOLO áp dụng cho rác thải, loss thường được viết dưới dạng tổng có trọng số:

$$\mathcal{L} = \lambda_{\text{box}}\mathcal{L}_{\text{box}} + \lambda_{\text{cls}}\mathcal{L}_{\text{cls}} + \lambda_{\text{obj}}\mathcal{L}_{\text{obj}}, \quad (2.1)$$


trong đó

- $\mathcal{L}_{\text{box}}$ phạt sai lệch hộp,
- $\mathcal{L}_{\text{cls}}$ phạt sai nhãn lớp,
- $\mathcal{L}_{\text{obj}}$ (objectness/confidence) học xác suất có/không có đối tượng tại vị trí dự đoán.

Với bài toán rác tái chế (ảnh/camera), thiết kế loss quyết định trực tiếp khả năng

- *tách vật thể sát nhau*,
- *giữ được vật thể nhỏ*
- *ổn định trong nền nhiễu/bẩn* [7].

Localization loss: phạt sai lệch vị trí hộp: Thành phần $\mathcal{L}_{\text{box}}$ thường dựa trên các biến thể của IoU để đưa hộp dự đoán tiến gần hộp thật một cách trực tiếp theo mục tiêu phát hiện đối tượng. Trong nghiên cứu phát hiện rác, Jiang et al. nhấn mạnh việc dùng **CIoU** để tối ưu hộp dự đoán sát ground-truth hơn, giúp giảm hiện tượng hộp “lệch xa” trong cảnh phức tạp [?]. Ngoài CIoU, Yang et al. (bài toán rác nổi trên sông) còn chỉ ra



Hình 2.7: Ví dụ minh họa hạn chế của CIoU trong một số cấu hình hộp (trích Figure 4 trong [14]).

nhược điểm của CIoU trong một số cấu hình hình học và đề xuất thay bằng **SIoU** để *tăng tốc hội tụ và cải thiện hồi quy hộp* (Hình 2.7) .

Trong ngữ cảnh rác tái chế, các vật thể có thể bị *méo/bẹp* hoặc *che khuất một phần*, vì vậy loss dựa trên IoU (và các biến thể có thêm phạt khoảng cách/tỉ lệ) thường cho tín hiệu học phù hợp hơn so với chỉ hồi quy tọa độ thuần túy, đặc biệt khi cần định vị ổn định để phục vụ phân loại vật liệu.

Classification loss: phạt sai nhãn lớp: Thành phần $\mathcal{L}_{cls}$ đo sai lệch giữa nhãn vật liệu thật và phân phối xác suất dự đoán. Trong các mô hình YOLOv5 được dùng cho bài toán rác, Yang et al. mô tả **classes loss** thường được tính bằng Binary Cross-Entropy dạng logits (BCEWithLogitsLoss) trong compound loss [14]. Về thực nghiệm, dữ liệu rác tái chế thường gặp *mất cân bằng lớp* (một số loại rác xuất hiện nhiều hơn), vì vậy có thể cân nhắc các biến thể như Focal Loss để giảm ảnh hưởng của các mẫu “dễ” và tập trung vào các mẫu khó (nhỏ/mờ/nhiều) khi cần tăng recall cho lớp hiếm [7].

Objectness loss: học xác suất có/không có đối tượng. Với các detector one-stage kiểu YOLO, $\mathcal{L}_{obj}$ giúp mô hình học *đâu là vị trí thật sự có vật thể*, nhằm giảm dự đoán rải rác trên nền. Yang et al. nêu rõ compound loss của YOLOv5 gồm **objectness loss** (cũng tính bằng BCEWithLogitsLoss) bên cạnh classes loss và location loss [14]. Trong ảnh rác tái chế nhiều nền nhiễu (sàn, cỏ, bề mặt bần, ánh sáng gắt), objectness loss là thành phần quan trọng để giảm false positives.

Tối ưu (optimization) và ổn định hội tụ. Sau khi xác định dạng loss, quá trình huấn luyện tối ưu các tham số mạng bằng các thuật toán như SGD/Adam. Trong bài

toán phát hiện rác, Jiang et al. lựa chọn **Adam** để xử lý hiện tượng *hội tụ chậm* và *dao động loss*, giúp quá trình học ổn định hơn trên dữ liệu rác trong bối cảnh phức tạp [?]. Đây là gợi ý thực dụng cho bài toán rác tái chế khi dữ liệu thường không quá lớn và phân phối ảnh đa dạng: khởi tạo từ mô hình tiền huấn luyện, kết hợp augmentation, và chọn bộ tối ưu phù hợp có thể cải thiện đáng kể độ tổng quát hoá khi triển khai trên ảnh/camera thực [13, 7].

2.1.4 Faster R-CNN

Faster R-CNN là mô hình phát hiện đối tượng thuộc nhóm *two-stage detectors*, trong đó việc phát hiện được tách thành:

- (i) sinh các vùng ứng viên có khả năng chứa vật thể (*region proposals*)
- (ii) phân loại + tinh chỉnh hộp bao trên từng vùng ứng viên [16]

Cách thiết kế hai giai đoạn giúp mô hình thường đạt độ chính xác tốt trong cảnh nền phức tạp và đối tượng nhỏ/che khuất, nên thường được dùng như một baseline mạnh trong các bài toán phát hiện rác ngoài môi trường thực [15].

Kiến trúc tổng quan: Faster R-CNN gồm ba khối chính:

- **Backbone CNN:** trích xuất đặc trưng toàn ảnh dưới dạng feature map F .
- **Region Proposal Network (RPN):** dự đoán nhanh các proposal dựa trên *anchors*, kèm điểm *objectness* và hồi quy hộp.
- **ROI head:** chuẩn hoá đặc trưng theo vùng (ROI pooling/ROI align), sau đó dự đoán nhãn lớp và tinh chỉnh hộp bao cuối cùng.


Hình 2.8 minh hoạ pipeline two-stage này trong bối cảnh bài toán phát hiện rác [15].

[15]) =====


RPN và anchor-based proposals: Trên feature map F , RPN xét mỗi vị trí và tạo một tập anchor với nhiều tỉ lệ/tỉ lệ cạnh. Với mỗi anchor a , RPN dự đoán: (i) xác suất foreground/background (*objectness*) và (ii) vector hiệu chỉnh hộp (*bbbox regression*) để tạo proposal [16]. Nhờ cơ chế này, Faster R-CNN có thể tập trung tính toán vào một số vùng có khả năng chứa vật thể rác, thay vì quét dày toàn ảnh ở bước phân loại.

ROI pooling và head phân loại/hồi quy: Các proposal có kích thước khác nhau được đưa qua ROI pooling (hoặc ROI align) để thu được đặc trưng vùng có kích thước cố định, từ đó head thực hiện:

- **Classification:** dự đoán nhãn lớp rác/vật liệu.



Hình 2.8: Kiến trúc Faster R-CNN (backbone $\rightarrow$ RPN $\rightarrow$ ROI head) (trích Figure 2 trong [15]).



Hình 2.9: Minh họa các phép tăng cường dữ liệu khi huấn luyện phát hiện rác (trích Figure 3 trong [15]).

- **Bounding box regression:** tính chỉnh hộp bao chính xác hơn theo từng lớp.

Thiết kế “tinh lọc theo vùng” là điểm khác biệt cốt lõi so với nhóm one-stage và thường giúp cải thiện độ chính xác định vị trong cảnh khó [16].

Huấn luyện và tăng tính tổng quát trong bài toán rác: Trong thực tế, dữ liệu rác thường đa dạng điều kiện chụp (ánh sáng, bóng đổ, nền phức tạp), vì vậy thực hành phổ biến là khởi tạo từ mô hình tiền huấn luyện (transfer learning) và tăng cường dữ liệu (augmentation) để giảm overfitting và tăng khả năng tổng quát hoá [15]. Hình 2.9 minh họa một số phép augmentation thường dùng trong bài toán phát hiện rác [15].

Từ góc nhìn hệ thống, Faster R-CNN đại diện cho hướng two-stage (proposal $\rightarrow$ ROI head), thường mạnh về độ chính xác trong cảnh khó. YOLOv8 (one-stage) sẽ được trình

bày ở phần sau như một hướng dự đoán trực tiếp trên feature maps nhằm tối ưu tốc độ suy luận cho ảnh/camera thời gian thực.

2.1.5 Các họ YOLO cho bài toán phát hiện rác tái chế và giới thiệu YOLOv8

Trong bài toán phát hiện và phân loại rác tái chế từ ảnh tĩnh hoặc luồng camera, yêu cầu triển khai thường hướng tới **thời gian thực** và **tính ổn định trong bối cảnh đa dạng** (nền nhiễu, ánh sáng thay đổi, vật thể nhỏ và dễ chồng lấp). Vì vậy, các mô hình thuộc nhóm *one-stage detectors* như YOLO thường được ưu tiên do dự đoán trực tiếp hộp bao và nhãn lớp trên toàn ảnh trong một lần suy luận [6].

2.1.6 Họ mô hình YOLO (You Only Look Once)


Các mô hình thuộc họ YOLO (You Only Look Once) là một trong những hướng tiếp cận quan trọng cho bài toán phát hiện đối tượng thời gian thực. YOLO được giới thiệu bởi Redmon và cộng sự với ý tưởng cốt lõi: **xem phát hiện đối tượng như một bài toán hồi quy một bước** (single-stage regression), tức là dùng *một* mạng nơ-ron duy nhất để dự đoán trực tiếp hộp bao và nhãn lớp trong *một lần suy luận* [17]. Nhờ thiết kế một giai đoạn, YOLO thường có tốc độ suy luận cao, phù hợp với bài toán nhận diện rác tái chế từ ảnh hoặc luồng camera khi cần xử lý liên tục theo khung hình.

Trong các nghiên cứu gần đây về nhận diện/phân loại rác tái chế, YOLO (đặc biệt là YOLOv8) thường được lựa chọn vì cân bằng tốt giữa tốc độ và độ chính xác trong bối cảnh nền phức tạp, vật thể đa dạng và dễ chồng lấp [20, 21, 22]. Bên cạnh đó, một tổng quan hệ thống về các phiên bản YOLO từ YOLOv1 đến YOLOv8 cho thấy họ YOLO liên tục được cải tiến theo hướng tăng chất lượng đặc trưng, cải thiện head dự đoán và tối ưu chiến lược gán nhãn/huấn luyện [18].

YOLOv1: Chia lưới và dự đoán đồng thời

Khái niệm nền tảng của YOLOv1 gồm ba ý chính [17, 18]:

- **Chia lưới (Grid system):** Ảnh đầu vào được chia thành lưới $S \times S$; mỗi ô chịu trách nhiệm cho các vật thể có *tâm* nằm trong ô đó.
- **Dự đoán đồng thời:** Tại mỗi ô lưới, mô hình dự đoán một số hộp bao (bounding boxes) kèm điểm tin cậy và xác suất lớp.
- **Hợp nhất đầu ra:** Các dự đoán được lọc/hợp nhất bằng hậu xử lý (thường là NMS) để tạo ra kết quả cuối.



Hình 2.10: Tổng quan tiến hoá các phiên bản YOLO (tham khảo hình timeline trong [18]).

Tiến hoá các phiên bản YOLO và liên hệ với bài toán rác tái chế

Từ YOLOv1, các phiên bản sau (YOLOv2/v3/v4/v5/v7/v8, ... Hình 2.10) được phát triển theo hướng cải thiện:


- (i) *backbone/neck* để trích xuất và hợp nhất đặc trưng tốt hơn,
- (ii) *head* để dự đoán ổn định hơn (đặc biệt với vật thể nhỏ/đông),
- (iii) *chiến lược huấn luyện* (gán nhãn, loss) để tối ưu hội tụ

Những cải tiến này phù hợp với dữ liệu rác tái chế vì vật thể thường có hình dạng không ổn định (bẹp/méo), dễ nhiễu nền, và có thể xuất hiện dày đặc trong cùng khung hình [20, 22].

Mô hình YOLOv8 và các cải tiến

YOLOv8 (Ultralytics) là một thể hệ YOLO mới hướng tới thiết kế gọn hơn, huấn luyện linh hoạt và hiệu năng tốt cho phát hiện thời gian thực. Trong các bài toán liên quan rác thải/rác tái chế, YOLOv8 đã được sử dụng như mô hình nền (baseline) hoặc được cải tiến thêm để tăng độ chính xác trong môi trường nhiễu nhiễu và vật thể đa dạng [20, 21, 22]. Theo tổng quan kiến trúc YOLO đến YOLOv8, các thay đổi quan trọng của YOLOv8 có thể tóm tắt như sau [18, 19]:

- **Thiết kế anchor-free:** chuyển từ dự đoán dựa trên anchor sang cơ chế không cần anchor, giúp đơn giản hoá không gian dự đoán và giảm phụ thuộc vào thiết kế anchor thủ công.
- **Backbone/khối C2f:** sử dụng biến thể CSP tối ưu luồng gradient (C2f) nhằm cải thiện trích xuất đặc trưng và hiệu quả tính toán.
- **Decoupled head:** tách nhánh dự đoán phân loại và hồi quy hộp bao để giảm xung đột tối ưu và cải thiện chất lượng dự đoán.



Hình 2.11: Sơ đồ biến thể dựa trên YOLOv8 hình mạng cải tiến từ nghiên cứu rác thải trong [22]).

- **Loss và huấn luyện:** kết hợp các lựa chọn loss/thiết kế huấn luyện hiện đại (ví dụ hồi quy hộp dựa trên IoU và loss kiểu phân phối như DFL) để nâng độ chính xác định vị [18].

Trong bối cảnh rác tái chế, các điểm trên có ý nghĩa thực tiễn: anchor-free và decoupled head thường giúp dự đoán ổn định hơn khi vật thể nằm sát nhau; backbone mạnh giúp phân biệt vật liệu trong nền phức tạp; và thiết kế loss tốt giúp hộp bao bám sát các vật thể có biên dạng khó (méo/bất quy tắc) [22, 21].

2.2 Học chủ động (Active Learning)

Trong bài toán phát hiện và phân loại rác tái chế, chi phí gán nhãn (vẽ bounding boxes và gán lớp) thường cao vì:

- (i) một ảnh có thể chứa nhiều vật thể rác,
- (ii) vật thể nhỏ và chồng lấp khiến thao tác vẽ hộp khó,
- (iii) dữ liệu thực tế đa dạng bối cảnh nên cần nhiều mẫu để mô hình tổng quát hoá tốt.

Học chủ động (Active Learning – AL) là hướng tiếp cận nhằm **giảm chi phí gán nhãn** bằng cách chỉ chọn một phần nhỏ các mẫu “giàu thông tin” để đưa đi gán nhãn, trong khi vẫn đạt chất lượng mô hình gần tương đương với gán nhãn toàn bộ [?].

2.2.1 Khái niệm và bài toán Active Learning

Trong thiết lập AL điển hình, tập dữ liệu được chia thành:

- Tập **labeled** $\mathcal{L}$: đã có nhãn (bbox + class).
- Tập **unlabeled** $\mathcal{U}$: chưa có nhãn (ảnh/camera thu thập được).

Mục tiêu của AL là, với ngân sách gán nhãn B (số ảnh hoặc số bbox được phép gán nhãn), tìm chiến lược chọn mẫu $\mathcal{Q}$ sao cho mô hình huấn luyện trên $\mathcal{L}$ được mở rộng từ $\mathcal{U}$ đạt hiệu năng cao nhất:

$$\mathcal{Q} = \arg \max_{\mathcal{Q} \subset \mathcal{U}, |\mathcal{Q}| \leq B} \Delta \text{Perf}(\mathcal{L} \cup \mathcal{Q}).$$

Ở bài toán phát hiện rác tái chế, AL đặc biệt phù hợp vì dữ liệu từ camera có thể rất nhiều, nhưng gán nhãn thủ công lại tốn kém và chậm.


2.2.2 Quy trình (pipeline) Active Learning cho Object Detection

Quy trình AL cho phát hiện đối tượng thường được triển khai theo vòng lặp (pool-based AL) [?]:

1. **Khởi tạo**: gán nhãn một tập nhỏ $\mathcal{L}_0$; phần còn lại là $\mathcal{U}_0$.
2. **Huấn luyện**: train detector (ví dụ YOLOv8) trên $\mathcal{L}_t$.
3. **Chọn mẫu**: dùng hàm truy vấn (query strategy) để chọn batch $\mathcal{Q}_t \subset \mathcal{U}_t$.
4. **Gán nhãn**: con người (hoặc công cụ hỗ trợ) gán nhãn cho $\mathcal{Q}_t$.
5. **Cập nhật**: $\mathcal{L}_{t+1} = \mathcal{L}_t \cup \mathcal{Q}_t$, $\mathcal{U}_{t+1} = \mathcal{U}_t \setminus \mathcal{Q}_t$, rồi lặp lại.

2.2.3 Các chiến lược chọn mẫu (Query Strategies)

Một chiến lược AL hiệu quả thường cố gắng chọn các mẫu sao cho **giàu thông tin** (informativeness) và/hoặc **đa dạng** (diversity). Trong object detection, việc đo độ không chắc chắn phức tạp hơn classification vì đầu ra gồm nhiều bbox và nhiều điểm dự đoán trên ảnh. Do đó, các chiến lược thường nhóm thành:



Hình 2.12: Vòng lặp học chủ động (pool-based active learning) cho bài toán phát hiện đối tượng [23]

Uncertainty-based sampling

Ý tưởng là chọn các ảnh mà mô hình không chắc chắn nhất. Một số thước đo phổ biến:

- **Least confidence / margin:** dựa trên xác suất lớp hoặc chênh lệch top-1 và top-2.
- **Entropy:** ảnh có entropy dự đoán cao thường khó, giàu thông tin.
- **Bayesian/MC Dropout:** lấy nhiều lần suy luận để ước lượng độ bất định (epistemic uncertainty).

Trong ảnh rác tái chế, uncertainty thường cao ở các trường hợp: vật thể nhỏ, che khuất, nền nhiễu, hoặc vật liệu có ngoại hình tương đồng (nhựa trong suốt vs thủy tinh).

Diversity-based sampling

Nếu chỉ chọn theo uncertainty, mô hình có thể chọn nhiều ảnh rất giống nhau (redundant). Vì vậy, diversity-based sampling chọn các ảnh **đa dạng** theo đặc trưng:

- Clustering theo embedding/feature (từ backbone).
- Core-set / k-center greedy: chọn tập mẫu bao phủ không gian đặc trưng.

Trong bài toán rác, diversity giúp đảm bảo dữ liệu được chọn bao quát nhiều điều kiện ánh sáng, nền và loại vật liệu.

Hybrid

Nhiều hệ AL thực tế kết hợp cả hai: trước tiên chọn một tập ứng viên có uncertainty cao, sau đó lọc để đảm bảo diversity (ví dụ clustering hoặc k-center trên tập ứng viên). Thiết kế lai thường hiệu quả hơn trong các bài toán thị giác có dữ liệu lớn và nhiều mẫu tương đồng.

2.2.4 Hàm ý cho bài toán phát hiện rác tái chế

Từ góc độ triển khai, Active Learning mang lại ba lợi ích chính cho bài toán rác tái chế:

- **Giảm chi phí gán nhãn:** tập trung vào các ảnh khó/giàu thông tin thay vì gán nhãn ngẫu nhiên.
- **Nâng khả năng tổng quát hoá:** chọn mẫu đa dạng giúp mô hình học tốt hơn các điều kiện môi trường thực.
- **Thích nghi theo thời gian:** khi camera thay đổi bối cảnh (mùa, ánh sáng, nền), AL có thể cập nhật tập nhãn theo vòng lặp.

Do đó, trong phần phương pháp đề xuất, luận văn sẽ xây dựng pipeline AL kết hợp YOLOv8/YOLOv8-like detector và chiến lược chọn mẫu phù hợp để tối ưu hiệu năng dưới ngân sách gán nhãn hữu hạn.

Chương 3


Phương pháp đề xuất

3.1 Kiến trúc hệ thống tổng thể

Chương này trình bày pipeline đề xuất nhằm giảm chi phí gán nhãn cho bài toán phát hiện và phân loại rác tái chế từ ảnh tĩnh hoặc luồng camera. Hệ thống kết hợp mô hình phát hiện YOLOv8 với vòng lặp học chủ động (Active Learning – AL) theo thiết lập *pool-based*: một tập nhỏ dữ liệu được gán nhãn ban đầu (*seed set*) dùng để huấn luyện mô hình nền, sau đó mô hình suy luận trên dữ liệu chưa gán nhãn (*unlabeled pool*) để chọn ra các mẫu giàu thông tin cho vòng gán nhãn tiếp theo (Hình 3.1).

Các bước của pipeline. Pipeline được triển khai theo vòng lặp gồm các bước chính:

1. **Thu thập dữ liệu** ảnh/video và chuẩn hóa định dạng nhãn về YOLO (bbox theo chuẩn (x_c, y_c, w, h) , chuẩn hóa về $[0, 1]$).
2. **Huấn luyện mô hình YOLOv8 baseline** trên tập nhãn ban đầu (seed set) $\mathcal{L}_0$.
3. **Suy luận** trên tập dữ liệu chưa gán nhãn $\mathcal{U}_t$ để thu các dự đoán bbox, lớp và độ tin cậy.
4. **Tính điểm chọn mẫu** (sample score) và chọn k ảnh/khung hình theo chiến lược Active Learning.
5. **Gán nhãn (human-in-the-loop)** và kiểm soát chất lượng nhãn trước khi đưa vào huấn luyện.
6. **Fine-tune/huấn luyện lại** YOLOv8 trên $\mathcal{L}_{t+1}$ và lặp lại cho các vòng AL tiếp theo.



Hình 3.1: Kiến trúc hệ thống tổng thể YOLOv8 kết hợp Active Learning cho phát hiện rác tái chế (seed set $\rightarrow$ train $\rightarrow$ score unlabeled $\rightarrow$ chọn mẫu $\rightarrow$ gán nhãn $\rightarrow$ retrain).

Thiết lập pool-based active learning. Ký hiệu $\mathcal{L}_t$ là tập đã gán nhãn tại vòng t và $\mathcal{U}_t$ là tập chưa gán nhãn. Mỗi vòng, hệ thống chọn một batch $Q_t \subset \mathcal{U}_t$ với ngân sách $|Q_t| = k$ để gán nhãn và cập nhật:

$$\mathcal{L}_{t+1} = \mathcal{L}_t \cup Q_t, \quad \mathcal{U}_{t+1} = \mathcal{U}_t \setminus Q_t.$$

Thiết kế này phù hợp với bối cảnh dữ liệu camera liên tục và chi phí gán nhãn bbox cao, khi không thể gán nhãn toàn bộ dữ liệu ngay từ đầu.

3.2 Thiết kế lớp đối tượng và bộ dữ liệu

3.2.1 Danh sách lớp rác tái chế

Tập lớp được xác định theo nhãn trong bộ dữ liệu và phù hợp với mục tiêu phân loại vật liệu. Với dataset sử dụng trong luận văn, có C lớp: BIODEGRADABLE, CARDBOARD, GLASS, METAL, PAPER, PLASTIC. Các lớp này phản ánh nhóm vật liệu/loại rác phổ biến, phục vụ

Vòng lặp Active Learning cho phát hiện rác tái chế (YOLOv8)

Input: Seed set $\mathcal{L}_0$, unlabeled pool $\mathcal{U}_0$, ngân sách mỗi vòng k , số vòng T .

Output: Mô hình YOLOv8 sau vòng T .

for $t = 0$ **to** $T - 1$ **do**

1. Huấn luyện / fine-tune YOLOv8 trên $\mathcal{L}_t$.
2. Suy luận YOLOv8 trên $\mathcal{U}_t$ để thu các dự đoán.
3. Tính điểm chọn mẫu $s(x)$ cho từng ảnh $x \in \mathcal{U}_t$.
4. Chọn $\mathcal{Q}_t \leftarrow \text{Top-}k$ ảnh theo $s(x)$ (hoặc hybrid).
5. Gán nhãn (bbox + class) cho $\mathcal{Q}_t$ và kiểm soát chất lượng (QA).
6. Cập nhật: $\mathcal{L}_{t+1} = \mathcal{L}_t \cup \mathcal{Q}_t$, $\mathcal{U}_{t+1} = \mathcal{U}_t \setminus \mathcal{Q}_t$.

end for

Hình 3.2: Giả mã vòng lặp Active Learning (pool-based) kết hợp YOLOv8.

cả đánh giá định lượng (mAP theo lớp) và triển khai thực tế.

3.2.2 Quy ước bounding box và hướng dẫn gán nhãn

Hệ thống sử dụng định dạng nhãn YOLO: mỗi dòng trong file `.txt` gồm

`class_id xc yc w h`

với (x_c, y_c, w, h) được chuẩn hóa theo kích thước ảnh và nằm trong $[0, 1]$. Để đảm bảo nhất quán khi gán nhãn (human-in-the-loop), luận văn áp dụng các quy tắc: (i) bbox phải bao phủ sát biên vật thể, (ii) không gán nhãn trùng lặp cho cùng một vật thể, (iii) xử lý vật thể bị che khuất bằng cách bao phần nhìn thấy và duy trì quy tắc nhất quán trên toàn bộ tập nhãn.

3.2.3 Quản lý dữ liệu cho Active Learning

Dữ liệu được chia thành ba phần phục vụ AL:

- **Seed set $\mathcal{L}_0$:** một tập nhỏ ảnh đã gán nhãn ban đầu để huấn luyện mô hình nền.
- **Unlabeled pool $\mathcal{U}_0$:** phần dữ liệu còn lại chưa dùng trong huấn luyện, dùng làm nguồn chọn mẫu.
- **Validation cố định:** tập validation được giữ cố định qua các vòng để đánh giá công bằng.

Thiết kế này cho phép đo mAP theo % dữ liệu gán nhãn, phản ánh hiệu quả sử dụng nhãn của AL.

3.3 Mô hình nền (Baseline) YOLOv8

3.3.1 Lựa chọn biến thể YOLOv8

YOLOv8 cung cấp nhiều kích thước mô hình (n/s/m/l/x). Trong luận văn, biến thể được lựa chọn dựa trên ràng buộc tài nguyên (GPU/CPU) và yêu cầu thời gian thực khi chạy trên luồng camera. Nguyên tắc chung là: mô hình lớn hơn thường tăng mAP nhưng giảm FPS. Các thí nghiệm được triển khai với biến thể phù hợp để cân bằng giữa độ chính xác và tốc độ.

3.3.2 Cấu hình huấn luyện

Mô hình baseline được huấn luyện với các thiết lập chính: kích thước ảnh đầu vào (`imgsz`), batch size, số epoch, augmentation mặc định của Ultralytics/YOLOv8, optimizer và learning rate schedule theo cấu hình tiêu chuẩn của YOLOv8. Các thông số này được giữ ổn định giữa baseline và các vòng AL để đảm bảo tính công bằng khi so sánh.

3.3.3 Thiết lập suy luận và NMS

Khi suy luận, các dự đoán được lọc bởi ngưỡng confidence τ_c và NMS với ngưỡng IoU τ_{nms} . Hai tham số này ảnh hưởng mạnh đến precision–recall, đặc biệt trong cảnh có nhiều đối tượng rác và chồng lấp. Trong thực nghiệm, các ngưỡng được hiệu chỉnh theo validation để cân bằng bỏ sót và dự đoán trùng lặp.

3.4 Chiến lược Active Learning đề xuất

3.4.1 Uncertainty sampling

Chiến lược uncertainty chọn các ảnh mà mô hình còn *không chắc chắn*. Trong bài toán phát hiện đối tượng, độ không chắc chắn có thể xuất phát từ: (i) confidence thấp của các bbox, (ii) entropy phân phối lớp cao, hoặc (iii) bất định mô hình khi suy luận nhiều lần. Luận văn sử dụng điểm số cấp ảnh (*image-level score*) bằng cách tổng hợp độ không chắc chắn của các bbox trong ảnh:

$$s_{\text{unc}}(x) = \frac{1}{N_x} \sum_{i=1}^{N_x} (1 - p_i),$$

trong đó N_x là số bbox dự đoán trong ảnh x và p_i là confidence của bbox thứ i . Ảnh có s_{unc} cao được ưu tiên đưa đi gán nhãn.

3.4.2 Diversity sampling

Nếu chỉ chọn theo uncertainty, hệ thống có thể chọn nhiều ảnh tương tự nhau (redundant). Diversity sampling giải quyết bằng cách chọn các ảnh đại diện trong không gian đặc trưng (embedding), ví dụ lấy embedding từ backbone và dùng clustering/k-center để chọn các mẫu bao phủ tốt dữ liệu.

3.4.3 Hybrid: kết hợp uncertainty và diversity

Luận văn sử dụng chiến lược lai nhằm chọn các ảnh vừa *khó* vừa *đa dạng*: trước tiên lấy tập ứng viên theo s_{unc} cao, sau đó áp dụng clustering trong không gian embedding để chọn đại diện mỗi cụm. Thiết kế này giảm trùng lặp dữ liệu được gán nhãn và tăng hiệu quả ngân sách nhãn.

3.5 Quy trình gán nhãn và kiểm soát chất lượng

3.5.1 Công cụ gán nhãn và quy trình human-in-the-loop

Các ảnh được chọn từ AL được xuất ra công cụ gán nhãn (ví dụ CVAT/Label Studio/Roboflow). Người gán nhãn vẽ bbox và gán lớp theo guideline (Mục 3.2.2), sau đó xuất về định dạng YOLO để đưa vào tập $\mathcal{L}_{t+1}$.

3.5.2 Kiểm soát chất lượng nhãn (QA)

Để giảm sai số do nhãn nhiều, luận văn áp dụng các kiểm tra:

- (i) kiểm tra `class_id` hợp lệ trong $[0, C - 1]$,
- (ii) kiểm tra bbox nằm trong miền $[0, 1]$ và $w, h > 0$,
- (iii) rà soát nhãn sai lớp/box lệch thông qua kiểm tra thống kê và xem mẫu ngẫu nhiên. Các bước QA giúp tránh lan truyền lỗi nhãn qua các vòng AL.

3.6 Tiêu chí dừng và tiêu chí đánh giá

3.6.1 Tiêu chí dừng

Hệ thống dừng vòng lặp AL theo một trong hai điều kiện:

- (i) đạt ngân sách nhãn tối đa (số ảnh/bbox được phép gán nhãn), hoặc
- (ii) mAP tăng không đáng kể giữa các vòng liên tiếp (hội tụ theo lợi ích cận biên).

3.6.2 Tiêu chí đánh giá

Luận văn đánh giá theo các tiêu chí:

- **Độ chính xác phát hiện:** mAP@0.5:0.95 và AP theo lớp trên tập validation cố định.
- **Tốc độ:** FPS/latency khi suy luận trên ảnh hoặc luồng camera.
- **Hiệu quả sử dụng nhãn:** đường cong mAP theo % dữ liệu đã gán nhãn, so sánh Active Learning với baseline chọn mẫu ngẫu nhiên.

Chương 4

Thực nghiệm

4.1 Thiết lập môi trường và dữ liệu

4.1.1 Môi trường thực nghiệm

Toàn bộ thí nghiệm được triển khai trên nền tảng **Google Colab** với GPU NVIDIA Tesla T4 (15GB VRAM). Cấu hình phần mềm sử dụng:

- Python 3.12
- PyTorch 2.9.0 (CUDA 12.6)
- Ultralytics YOLOv8 (phiên bản 8.3.0)

Các ảnh đầu vào được resize về kích thước 640×640 trong quá trình huấn luyện và đánh giá.

4.1.2 Dữ liệu và định dạng nhãn

Bộ dữ liệu **Garbage Classification** được tổ chức theo định dạng YOLO với các thư mục: `train/images`, `train/labels`, `valid/images` và file cấu hình `data.yaml`. Bài toán gồm 6 lớp rác tái chế: `BIODEGRADABLE`, `CARDBOARD`, `GLASS`, `METAL`, `PAPER`, `PLASTIC`.

Tổng số ảnh: tập huấn luyện có 7324 ảnh, validation có 2098 ảnh. Để mô phỏng kịch bản Active Learning, dữ liệu được chia thành:

- **Seed set (Round 0)**: 732 ảnh có nhãn (dữ liệu gốc ban đầu).
- **Unlabeled pool**: 6592 ảnh còn lại, giả định chưa có nhãn.
- **Validation**: 2098 ảnh cố định, dùng để đánh giá xuyên suốt các vòng.

Bảng 4.1: Thống kê dữ liệu sử dụng trong các thí nghiệm.

Tập dữ liệu	Số lượng ảnh
Train (tổng)	7324
Validation (cố định)	2098
Seed set (Round 0)	732
Unlabeled pool	6592

Bảng 4.2: Kết quả theo lớp trên tập validation (Round 0, checkpoint `round0.pt`).

Lớp	mAP50	mAP50–95
all	0.117	0.062
BIODEGRADABLE	0.473	0.263
CARDBOARD	0.015	0.007
GLASS	0.183	0.085
METAL	0.029	0.013
PAPER	0.000	0.000
PLASTIC	0.002	0.001

4.1.3 Kết quả theo lớp trên tập validation (Round 0)

Bảng 4.2 trình bày kết quả theo lớp trên tập validation ở Round 0 (checkpoint `round0.pt`).

4.2 Kịch bản và cấu hình huấn luyện

4.2.1 Round 0 (Baseline)

Round 0 đóng vai trò baseline.

- Mô hình: **YOLOv8s pretrained**.
- Số epoch: 50, batch size = 16, imgsz = 640.
- Tập train: seed set gồm 732 ảnh.

Kết quả checkpoint `best.pt` được sử dụng làm điểm khởi đầu cho các vòng Active Learning và Random Sampling.

4.2.2 Các vòng Active Learning (Round 1–3)

Các vòng Active Learning theo pipeline:

$$\textit{Train} \rightarrow \textit{Infer pool} \rightarrow \textit{Scoring} \rightarrow \textit{Select top-}K \rightarrow \textit{Fine-tune}.$$

Mỗi vòng chọn thêm $K = 200$ ảnh mới từ pool, fine-tune 15 epoch. Hàm đánh giá: `model.val()` với `iou=0.7`, `conf=0.001` trên validation cố định.

4.3 Chiến lược chọn mẫu

4.3.1 Uncertainty Sampling

Chiến lược chính sử dụng độ không chắc chắn của dự đoán:

$$U(x) = \frac{1}{N} \sum_{i=1}^N (1 - c_i),$$

với c_i là confidence của từng box dự đoán. Ảnh không có box nào được xem là có uncertainty cao nhất. Mô hình ưu tiên chọn các ảnh có $U(x)$ lớn nhất để gán nhãn trong vòng kế tiếp.

4.3.2 Random Sampling (đối chứng)

Nhánh đối chứng thực hiện chọn ngẫu nhiên $K = 200$ ảnh mỗi vòng. Các điều kiện huấn luyện, fine-tune, đánh giá hoàn toàn giống với Uncertainty Sampling để đảm bảo so sánh công bằng (cùng seed, batch size, epoch, v.v.).

4.4 Quản lý thí nghiệm và lưu trạng thái

Thí nghiệm được thiết kế để có thể resume khi gián đoạn Colab:

- `al_state_uncertainty.json`: lưu round hiện tại, danh sách labeled/pool và checkpoint tốt nhất theo vòng.
- `al_history_uncertainty.csv`: lưu các chỉ số (Precision, Recall, mAP50, mAP50–95) sau mỗi vòng.

Cấu trúc này giúp dễ dàng vẽ biểu đồ và so sánh đường cong hiệu quả nhãn (label efficiency) giữa các chiến lược.


4.5 Đánh giá và ghi log

4.5.1 Chỉ số đánh giá

Đánh giá tuân theo chuẩn COCO, gồm:

- Precision (P), Recall (R)
- mAP@0.5 (mAP50) và mAP@0.5:0.95 (mAP50–95)

Kết quả được lưu tự động trong thư mục `runs/detect/` của YOLOv8.



Hình 4.1: Đồ thị loss và mAP trong quá trình huấn luyện Round 0 (Baseline).

4.5.2 Biểu đồ huấn luyện

YOLOv8 tự sinh các biểu đồ:

- `results.png` (loss và mAP theo epoch) (Hình 4.1)
- `PR_curve.png` (đường Precision–Recall)
- `confusion_matrix.png` (ma trận nhầm lẫn)

Các biểu đồ này được trích để trình bày ở Chương 5 cho việc phân tích xu hướng và hiện tượng cold-start.

Chương 5

Kết quả, thảo luận và kết luận

5.1 Kết quả định lượng

5.1.1 Thiết lập thực nghiệm

Hai chiến lược được so sánh gồm: **Active Learning (Uncertainty Sampling)** và **Random Sampling**. Cả hai nhánh dùng cùng cấu hình YOLOv8, cùng seed set ban đầu $|L_0| = 732$ ảnh và cùng ngân sách gán nhãn mỗi vòng $K = 200$ ảnh. Tổng số vòng thực nghiệm là 3 vòng (Round 1–3), do đó số ảnh gán nhãn lần lượt là: $732 \rightarrow 932 \rightarrow 1132 \rightarrow 1332$. Tất cả các mô hình được đánh giá trên tập validation cố định, sử dụng các chỉ số **Precision**, **Recall**, **mAP@0.5** và **mAP@0.5:0.95**.

5.1.2 Baseline Round 0

Round 0 đóng vai trò baseline, mô hình được huấn luyện trên seed set 732 ảnh và đánh giá trên validation cố định. Bảng 5.1 trình bày kết quả baseline làm mốc để so sánh mức cải thiện ở các vòng tiếp theo.

Nhận xét: Baseline có *precision* rất cao nhưng *recall* rất thấp. Điều này cho thấy mô hình ở giai đoạn đầu dự đoán khá “thận trọng”: ít phát hiện sai (precision cao) nhưng bỏ sót nhiều đối tượng (recall thấp), dẫn tới mAP50–95 còn hạn chế.

5.1.3 Active Learning (Uncertainty Sampling): Round 1–3

Từ Round 1 trở đi, ở mỗi vòng hệ thống chọn thêm $K = 200$ ảnh từ pool bằng chiến lược uncertainty sampling, sau đó fine-tune mô hình từ checkpoint tốt nhất của vòng trước. Bảng 5.2 tổng hợp kết quả theo vòng của nhánh Active Learning.

Nhận xét: So với baseline, nhánh Uncertainty cải thiện đều theo số lượng nhãn: mAP50–95 tăng từ 0.061678 (Round 0) lên 0.213148 (Round 3), tương đương tăng khoảng 0.151470 điểm. Đồng thời recall tăng mạnh từ 0.082496 lên 0.332149, cho thấy mô hình giảm đáng kể hiện tượng bỏ sót.

Bảng 5.1: Kết quả tổng quan Round 0 (Baseline, 732 ảnh).

Round	Precision	Recall	mAP50	mAP50–95
0	0.926118	0.082496	0.117225	0.061678

Bảng 5.2: Kết quả theo vòng – nhánh Active Learning (Uncertainty).

Round	#Labeled	Precision	Recall	mAP50	mAP50–95
0	732	0.926118	0.082496	0.117225	0.061678
1	932	0.238980	0.259597	0.195928	0.118056
2	1132	0.309485	0.302723	0.272203	0.162022
3	1332	0.412126	0.332149	0.337726	0.213148

5.1.4 Random Sampling: Round 1–3 (đối chứng)

Để đánh giá hiệu quả Active Learning một cách công bằng, nhánh đối chứng Random Sampling được triển khai với: cùng seed set, cùng ngân sách $K = 200$ ảnh/vòng, cùng số vòng và cùng cấu hình huấn luyện. Bảng 5.3 tổng hợp kết quả nhánh Random.

Nhận xét: Nhánh Random cải thiện mAP50–95 từ 0.061678 lên 0.211120 (Round 3), tăng khoảng 0.149442 điểm. Precision tăng dần theo vòng và đạt 0.440704 ở Round 3, trong khi recall đạt 0.309530.

5.1.5 So sánh Active Learning và Random Sampling

So sánh tập trung vào **label-efficiency**: tại cùng số lượng ảnh gán nhãn (#Labeled), phương pháp nào đạt mAP cao hơn sẽ được xem là hiệu quả hơn. Bảng 5.4 trình bày so sánh trực tiếp theo từng vòng. Cột Δ thể hiện mức chênh lệch mAP50–95 giữa Active Learning và Random tại cùng #Labeled.

Thảo luận kết quả so sánh:

- Ở Round 1–2, nhánh Random cho mAP50–95 cao hơn nhánh Uncertainty (tương ứng $\Delta = -0.007909$ và $\Delta = -0.033277$).
- Đến Round 3, nhánh Uncertainty *nhỉnh hơn nhẹ* Random về mAP50–95 ($\Delta = +0.002028$), cho thấy hai phương pháp gần như hội tụ về hiệu năng khi số nhãn tăng lên 1332.
- Về xu hướng Precision–Recall ở Round 3: Random có precision cao hơn (0.440704 so với 0.412126), trong khi Uncertainty có recall cao hơn (0.332149 so với 0.309530). Điều này phản ánh *sự đánh đổi*: Uncertainty có xu hướng giảm bỏ sót (tăng recall) nhưng có thể làm tăng nhầm lẫn (giảm precision).

Giải thích khả dĩ: Trong các vòng đầu, uncertainty sampling thường ưu tiên các mẫu “khó”/biên quyết định. Nếu dữ liệu có nhiều nhãn, mất cân bằng lớp, hoặc các mẫu khó

Bảng 5.3: Kết quả theo vòng – nhánh Random Sampling (đối chứng).

Round	#Labeled	Precision	Recall	mAP50	mAP50–95
0	732	0.926118	0.082496	0.117225	0.061678
1	932	0.226532	0.295439	0.206586	0.125965
2	1132	0.417145	0.304051	0.307078	0.195299
3	1332	0.440704	0.309530	0.329488	0.211120

Bảng 5.4: So sánh trực tiếp mAP50–95 giữa Active Learning (Uncertainty) và Random Sampling.

Round	#Labeled	mAP50–95 (AL)	mAP50–95 (Random)	Δ (AL–Random)
0	732	0.061678	0.061678	0.000000
1	932	0.118056	0.125965	-0.007909
2	1132	0.162022	0.195299	-0.033277
3	1332	0.213148	0.211120	+0.002028


không đại diện cho phân phối chung, mô hình có thể học chậm hơn so với việc lấy mẫu ngẫu nhiên. Khi số nhãn đủ lớn (Round 3), việc tập trung vào các mẫu khó bắt đầu phát huy hiệu quả và giúp nhánh Uncertainty bắt kịp (thậm chí nhỉnh hơn nhẹ).

Khuyến nghị để kết luận chắc chắn hơn: Do Random Sampling phụ thuộc seed, nên để kết luận mạnh, nên chạy Random với nhiều seed và báo cáo trung bình $\pm$ độ lệch chuẩn. Tuy nhiên, trong thiết lập hiện tại, kết quả cho thấy Uncertainty *không vượt trội rõ rệt* so với Random ở các vòng đầu, và hai chiến lược *tiệm cận* ở vòng cuối.


5.1.6 So sánh trực quan bằng đồ thị

Hình 5.1 minh họa đường cong mAP50–95 theo số lượng ảnh gán nhãn. Có thể quan sát giai đoạn Round 1–2, Random đạt mAP cao hơn, nhưng đến Round 3 hai phương pháp hội tụ và Uncertainty nhỉnh hơn nhẹ.

Hình 5.2 thể hiện Precision và Recall theo số lượng ảnh gán nhãn. Kết quả cho thấy ở Round 3, Uncertainty có recall cao hơn Random, trong khi Random có precision nhỉnh hơn.



Hình 5.1: So sánh mAP50–95 theo số lượng ảnh gán nhãn (Uncertainty vs Random).



Hình 5.2: So sánh Precision và Recall theo chiến lược gán nhãn (Uncertainty vs Random).

5.2 Phân tích lỗi: Hiện tượng Cold-Start trong Active Learning

Kết quả ở các Round đầu cho thấy chiến lược Active Learning theo độ không chắc chắn (Uncertainty Sampling) cho hiệu năng mAP50–95 thấp hơn hoặc tương đương với Random Sampling. Hiện tượng này đã được ghi nhận trong nghiên cứu của Jin et al. [?], trong đó các tác giả chỉ ra rằng ở giai đoạn *cold-start*, mô hình học sâu chưa có biểu diễn đặc trưng ổn định, nên các ước lượng độ không chắc chắn (uncertainty) không phản ánh chính xác độ "thông tin" của mẫu dữ liệu. Do đó, chiến lược chọn mẫu theo uncertainty có thể tập trung vào các mẫu nhiễu hoặc không đại diện cho phân phối tổng thể, làm cho hiệu năng học có giám sát giảm và thậm chí thua cả chọn mẫu ngẫu nhiên trong vài vòng đầu.

Trong thí nghiệm của chúng tôi, hiện tượng này thể hiện rõ ở Round 1 và 2: Δ mAP50–95 (AL–Random) lần lượt là -0.0079 và -0.0333 . Đến Round 3, khi mô hình đã được fine-tune trên nhiều dữ liệu hơn, uncertainty trở nên đáng tin cậy hơn, giúp mô hình bắt kịp và nhỉnh hơn Random ($\Delta = +0.0020$). Quan sát này củng cố lập luận rằng độ tin cậy của hàm uncertainty phụ thuộc mạnh vào năng lực biểu diễn ban đầu của mô hình (cold-start effect). Tương tự, Chen et al. [?] cũng nhận thấy hiện tượng này trong các bài toán y khoa, và đề xuất các phương pháp kết hợp ngẫu nhiên để làm ổn định việc chọn mẫu ở giai đoạn đầu.

5.3 Kết luận chương

Với cùng ngân sách gán nhãn ($K = 200$ ảnh/vòng), cả hai chiến lược đều cải thiện đáng kể so với baseline. Nhánh Random cho kết quả tốt hơn ở Round 1–2, trong khi nhánh Uncertainty bắt kịp và nhỉnh hơn nhẹ ở Round 3. Ở mức 1332 ảnh gán nhãn, hai phương pháp đạt hiệu năng tương đương (mAP50–95 xấp xỉ 0.21), cho thấy mô hình đã tiến gần vùng hội tụ. Trong các nghiên cứu tiếp theo, nên lặp lại Random với nhiều seed, đồng thời thử kết hợp Uncertainty với các yếu tố diversity để tăng tính ổn định và hiệu quả lựa chọn mẫu ở các vòng đầu.

Tài liệu tham khảo

- [1] Li, P., Xu, J. & Liu, S., 2024. Solid Waste Detection Using Enhanced YOLOv8 Lightweight Convolutional Neural Networks. *Mathematics*, 12(14), 2185. <https://www.mdpi.com/2227-7390/12/14/2185/pdf>
- [2] Di, J., Xi, K. & Yang, Y., 2025. An enhanced YOLOv8 model for accurate detection of solid floating waste. *Scientific Reports*. <https://www.nature.com/articles/s41598-025-10163-2.pdf>
- [3] Paudel, P., *et al.*, 2024. Automated Waste Sorting with Delta Arm and YOLOv8 Detection. *AI and Capsule Networks (IRO Journals)*. <https://irojournals.com/aicn/article/pdf/6/3/4>
- [4] viswaprakash1990, (n.d.). Garbage Detection – 6 Waste Categories (Dataset in YOLO format). Kaggle. <https://www.kaggle.com/datasets/viswaprakash1990/garbage-detection> (Truy cập: 03/01/2026).
- [5] Thielmann, P., Zhou, Y., Mirbach, B., Stricker, D., & Rambach, J., 2025. A Review of Computer Vision for Industrial-Grade Waste Classification. *IEEE Access*, Vol. 13.
- [6] Liu, L., Ouyang, W., Wang, X., Fieguth, P., Chen, J., Liu, X., & Pietikäinen, M., 2020. Deep Learning for Generic Object Detection: A Survey. *International Journal of Computer Vision*, Vol. 128, No. 2, pp. 261–318. DOI: 10.1007/s11263-019-01247-4.
- [7] Abdu, H., & Mohd Noor, M. H., 2022. A Survey on Waste Detection and Classification Using Deep Learning. *IEEE Access*, Vol. 10, pp. 128151–128165.
- [8] Lin, T.-Y., Dollár, P., Girshick, R., He, K., Hariharan, B., & Belongie, S., 2017. Feature Pyramid Networks for Object Detection. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 2117–2125. doi:10.1109/CVPR.2017.106.
- [9] Lin, T.-Y., Goyal, P., Girshick, R., He, K., & Dollár, P., 2017. Focal Loss for Dense Object Detection. *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pp. 2980–2988.

- [10] Tian, Z., Shen, C., Chen, H., & He, T., 2019. FCOS: Fully Convolutional One-Stage Object Detection. *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pp. 9627–9636.
- [11] Bodla, N., Singh, B., Chellappa, R., & Davis, L. S., 2017. Soft-NMS – Improving Object Detection With One Line of Code. In *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, pp. 5562–5570. DOI: 10.1109/ICCV.2017.593.
- [12] Liu, S., Huang, D., & Wang, Y., 2019. Adaptive NMS: Refining Pedestrian Detection in a Crowd. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 6459–6468. DOI: 10.1109/CVPR.2019.00662.
- [13] Jiang, X., Hu, H., Qin, Y., Hu, Y., et al., 2022. A real-time rural domestic garbage detection algorithm with an improved YOLOv5s network model. *Scientific Reports*, Vol. 12, Article 16802. DOI: 10.1038/s41598-022-20983-1.
- [14] Yang, X., Feng, L., Guo, X., Huang, H., & Pu, H., 2022. Detection of River Floating Garbage Based on Improved YOLOv5. *Mathematics*, 10(22), 4366. DOI: 10.3390/math10224366.
- [15] Ping, P., Xu, G., Kumala, E., & Gao, J., 2020. Smart Street Litter Detection and Classification Based on Faster R-CNN and Edge Computing. *International Journal of Software Engineering and Knowledge Engineering*, Vol. 30, No. 4, pp. 537–553. DOI: 10.1142/S0218194020400045.
- [16] Ren, S., He, K., Girshick, R., & Sun, J., 2015. Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks. *Advances in Neural Information Processing Systems (NeurIPS)*.
- [17] Redmon, J., Divvala, S., Girshick, R., & Farhadi, A., 2016. You Only Look Once: Unified, Real-Time Object Detection. *Proceedings of CVPR 2016*. doi:10.1109/CVPR.2016.91.
- [18] Terven, J., Córdova-Esparza, D.-M., & Romero-González, J.-A., 2023. A Comprehensive Review of YOLO Architectures in Computer Vision: From YOLOv1 to YOLOv8 and YOLO-NAS. *Machine Learning and Knowledge Extraction*, 5(4), 1680–1716. doi:10.3390/make5040083.
- [19] Ultralytics, 2023. YOLOv8 Documentation (Models, Training, Inference). *Ultralytics Docs*.
- [20] Zambri, A. F., 2024. A Recyclable Waste Image Recognition System with YOLOv8 for Children’s Environmental Education. *Engineering, Technology & Applied Science Research*, 14(5), 16492–16498.

- [21] Li, H., Liu, S., & Feng, Y., 2024. Solid Waste Detection Based on Enhanced YOLOv8s. *Mathematics*, 12(14), 2185. doi:10.3390/math12142185.
- [22] Di, S., Yu, J., Chen, L., & Guo, J., 2025. An enhanced YOLOv8 model for accurate detection of solid waste on water surfaces. *Scientific Reports*, 15, 25015. doi:10.1038/s41598-025-08743-9.
- [23] Raja, K., Senthilselvi, A., Anandaperumal, E., Senthil Pandi, S., Abhishek, M. B., & Kaavya, R., 2024. A Novel Approach for Waste Classification Using Active Deep Learning. In *Proceedings of the 2024 International Conference on Smart Technologies for Sustainable Development Goals (ICSTSDG)* (IEEE), pp. 1–5. doi:10.1109/ICSTSDG61998.2024.11026525.